ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



BÁO CÁO IMAGE

CO5177 · Nền tảng lập trình cho phân tích và trực quan dữ liệu

Học kỳ 261 · Năm học 2026–2027

Phân loại CIFAR-100 bằng ResNet18 và Swin-T

Nhóm CTG

Huỳnh Thành Đạt	2570161 · 50%
Lương Minh Duy	2570083 · 50%
Giảng viên	Lê Thành Sách

Thành phố Hồ Chí Minh, tháng 11 năm 2026

Tóm tắt

Thực nghiệm so sánh ResNet18 và Swin-T pretrained ImageNet ở ba mức fine-tuning trên CIFAR-100. Các ảnh trùng pixel chính xác được loại trước khi train; mỗi cấu hình chạy 20 epoch với ba seed. Swin-T full cho accuracy test cao nhất, đạt $86{,}59 \pm 0{,}24\%$. So với ResNet18 full, mức tăng là $7{,}61 \pm 0{,}42$ điểm phần trăm khi ghép cặp cùng seed. Đổi lại, thời gian train gấp 1,46 lần và peak memory gấp 5,11 lần. Phân tích ảnh sai cho thấy ngay cả cấu hình tốt nhất vẫn có nhiều lỗi với confidence cao.

Tổng quan báo cáo

Dữ liệu	CIFAR-100, 100 lớp; ảnh gốc 32×32, đầu vào 96×96.
Split	44.976 train, 5.000 validation, 9.998 test sau loại ảnh trùng chính xác.
Mô hình	ResNet18 và Swin-T pretrained; head-only, partial và full fine-tuning.
Kết quả chính	Swin-T full đạt $86{,}59 \pm 0{,}24\%$ accuracy và $0{,}8658 \pm 0{,}0025$ macro-F1.
Chi phí	Swin-T full dùng 1,46 lần thời gian và 5,11 lần peak memory của ResNet18 full.

Mục lục

Tóm tắt **i**

Tổng quan báo cáo **ii**

1 Bài toán và dữ liệu **1**

1.1 Mục tiêu 1

1.2 Dữ liệu và kích thước ảnh 1

1.3 Tiền xử lý và normalization 3

2 Mô hình và thiết lập thực nghiệm **4**

2.1 Đặc trưng ảnh và cơ chế phân loại 4

2.2 Các mức fine-tuning 4

2.3 Huấn luyện và đánh giá 5

3 Kết quả và thảo luận **7**

3.1 Accuracy và macro-F1 trên test 7

3.2 Accuracy và cross-entropy qua 20 epoch 7

3.3 Accuracy so với thời gian và bộ nhớ 10

3.4 Những cặp lớp dễ bị nhầm 11

3.5 Dự đoán sai dù confidence cao 11

3.6 Kết luận 13

3.7 Giới hạn 13

Tài liệu tham khảo **14**

Danh sách hình vẽ

1.1 Số ảnh của 100 lớp CIFAR-100 sau loại trùng pixel chính xác, với seed chia tập 2026. Mỗi lớp còn 441–450 ảnh train, 50 ảnh validation và 99–100 ảnh test; việc loại trùng giữ được phân bố lớp gần cân bằng. 2

1.2 Mười ảnh RGB 32×32 từ tập train CIFAR-100 sau loại trùng, lấy mẫu với seed 2026. Ảnh nhỏ giữ được màu và hình dạng tổng thể nhưng nhiều chi tiết vật thể khó quan sát. 2

1.3 Ảnh train CIFAR-100 trước xử lý và sau augmentation ở epoch 1–4, với seed train 42. Padding, random crop và horizontal flip thay đổi khung nhìn; kích thước đầu vào sau resize là 96×96. 3

1.4 Phân phối giá trị R/G/B của một ảnh train CIFAR-100, lấy mẫu với seed 2026, trước và sau normalization ImageNet. Mean kênh R đổi từ 0,3746 thành $-0{,}4822$, SD từ 0,2284 thành 0,9974. Phép biến đổi thay đổi thang đo từng kênh; đầu ra có thể âm và không bị giới hạn trong $[0, 1]$. 3

3.1 Accuracy và cross-entropy train/validation của ResNet18 ở ba chế độ fine-tuning qua 20 epoch. Đường là trung bình của seed 42, 43 và 44; vùng tô là ± SD mẫu. Full đạt validation accuracy cao hơn head-only và partial. 8

3.2 Accuracy và cross-entropy train/validation của Swin-T ở ba chế độ fine-tuning qua 20 epoch. Đường là trung bình của seed 42, 43 và 44; vùng tô là ± SD mẫu. Full duy trì validation accuracy cao nhất trong ba chế độ. 9

3.3 Accuracy test và thời gian train 20 epoch của sáu cấu hình trên RTX 5090; accuracy là trung bình ± SD mẫu qua seed 42, 43 và 44. Swin-T full đạt 86,59%, cao hơn ResNet18 full 7,61 điểm phần trăm, với thời gian train gấp 1,46 lần. 10

3.4 Confusion matrix trên test của ResNet18 full (trái) và Swin-T full (phải), trung bình qua seed 42, 43 và 44. Hàng là nhãn đúng, cột là nhãn dự đoán; màu biểu diễn số ảnh trung bình tại mỗi ô. 11

3.5 12 lỗi có confidence cao nhất của Swin-T full, seed 42, trên test CIFAR-100. Mô hình sai 1.324/9.998 ảnh (13,24%), trong đó 390 ảnh sai có confidence từ 95% trở lên. Confidence cao vẫn có thể đi kèm nhãn sai; giá trị 100,0% trên hình là kết quả làm tròn. 12

Danh sách bảng

1.1 Thống kê pixel của 44.976 ảnh train CIFAR-100, sau loại trùng và trước resize, trên thang $[0, 1]$. Kênh R có mean cao hơn B khoảng 0,0663; SD ba kênh nằm trong 0,2563–0,2762. Đây là thống kê mô tả, còn mô hình dùng normalization ImageNet. 2

2.1 Phạm vi tham số được cập nhật ở ba chế độ fine-tuning. Cả hai kiến trúc dùng cùng cách chia dữ liệu, tiền xử lý và seed. 5

2.2 Thiết lập chung cho hai kiến trúc. Learning rate khác nhau giữa head-only và các chế độ cập nhật backbone. 5

3.1 Accuracy và macro-F1 trên 9.998 ảnh test CIFAR-100, trung bình ± SD mẫu qua seed 42, 43 và 44. Full fine-tuning cho kết quả cao nhất ở cả ResNet18 và Swin-T. 7

3.2 Chi phí train 20 epoch trên RTX 5090, batch size 128, số worker nạp dữ liệu bằng 0; trung bình ± SD mẫu qua seed 42, 43 và 44. Full dùng nhiều bộ nhớ hơn head-only ở cả hai kiến trúc. 10

3.3 Số lỗi trung bình trên test qua seed 42, 43 và 44 tại bốn hướng nhầm của hai mô hình full. Swin-T giảm lỗi ở cả bốn hướng, nhưng oak_tree sang maple_tree vẫn có khoảng 20 lỗi mỗi lượt. Chỉ số lớp bắt đầu từ 0. . . . 11

Chương 1

Bài toán và dữ liệu

1.1 Mục tiêu

Thực nghiệm khảo sát ảnh hưởng của mức độ cập nhật backbone khi phân loại CIFAR-100. Hai kiến trúc ResNet18 và Swin-T sử dụng trọng số ImageNet-1K phiên bản V1. Mỗi kiến trúc được đánh giá ở ba chế độ pretrained: chỉ học lớp phân loại (head-only), fine-tuning một phần backbone (partial) và fine-tuning toàn bộ (full). Tất cả sáu cấu hình được chạy với seed 42, 43 và 44.

Mục tiêu là xác định mức cập nhật backbone nào cho chất lượng dự đoán tốt hơn trong cùng 20 epoch, đồng thời đo phần thời gian và bộ nhớ cần thêm.

1.2 Dữ liệu và kích thước ảnh

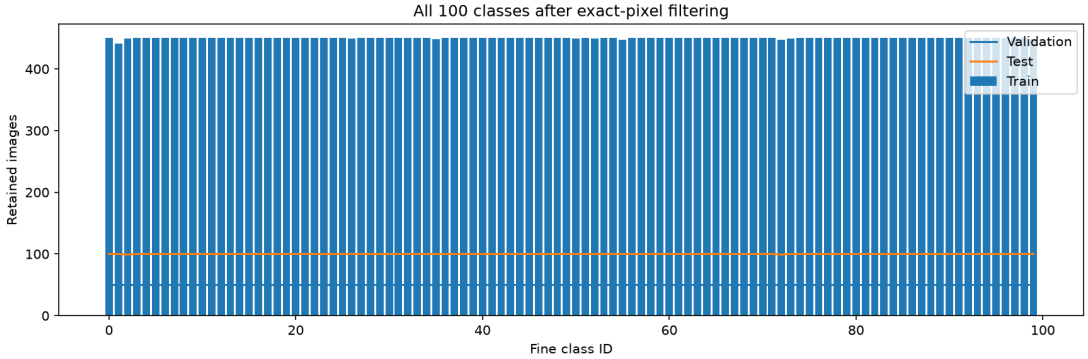
CIFAR-100 do Đại học Toronto công bố, gồm 60.000 ảnh màu thuộc 100 lớp chi tiết (fine label), được nhóm thành 20 lớp tổng quát (coarse label): 50.000 ảnh train chính thức và 10.000 ảnh test chính thức [2]. Bản Python được phân phối dưới dạng tệp pickle `train`, `test` và `meta`; hai tệp dữ liệu chứa các mảng pixel cùng nhãn fine/coarse, còn `meta` chứa tên lớp. Thực nghiệm phân loại theo 100 fine label. Kiểm tra mảng dữ liệu xác nhận ảnh có ba kênh RGB, kiểu uint8, giá trị pixel từ 0 đến 255; không có pixel thiếu hoặc nhãn ngoài khoảng 0–99.

Ảnh gốc có kích thước 32×32; toàn bộ dữ liệu nguồn được đưa vào bước chia và loại trùng. Đề bài khuyến nghị, không bắt buộc, cạnh ngắn ít nhất 128 px [1]. Thực nghiệm dùng đầu vào 96×96 cho cả hai kiến trúc và mọi mức fine-tuning để kiểm soát điều kiện so sánh. Kích thước này phóng lớn ảnh ba lần theo mỗi chiều và dùng ít điểm ảnh hơn đầu vào 128 px. Nội suy giúp tạo đầu vào phù hợp cho backbone nhưng không khôi phục chi tiết vốn thiếu ở ảnh gốc.

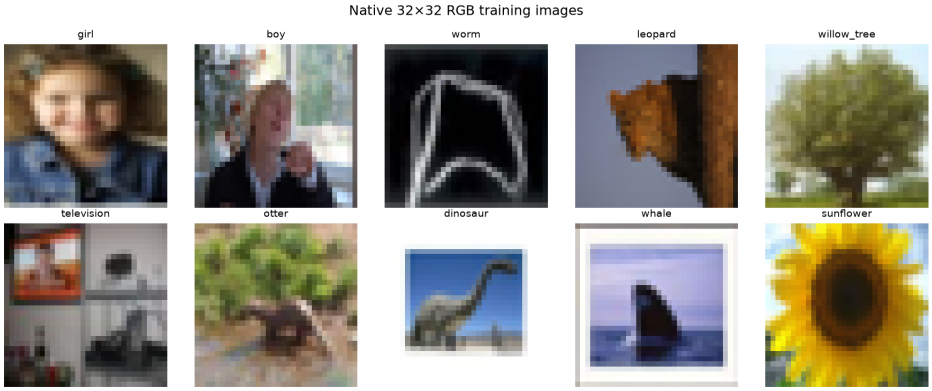
Từ 50.000 ảnh train, phép chia phân tầng với seed 2026 ban đầu tạo 45.000 ảnh train và 5.000 ảnh validation. Trước khi train, các ảnh có nội dung pixel RGB giống hệt nhau được nhóm lại trong cả ba tập. Mỗi nhóm giữ một ảnh theo thứ tự ưu tiên test, validation, rồi train. Chính sách này loại 24 ảnh khỏi train và 2 khỏi test; validation không đổi. Tập cuối gồm 44.976/5.000/9.998 ảnh. Đối chiếu sau lọc xác nhận không còn nội dung RGB trùng chính xác giữa các tập.

Kênh	Mean	SD	Min	Max
R	0,5074	0,2671	0	1
G	0,4869	0,2563	0	1
B	0,4412	0,2762	0	1

Bảng 1.1: Thống kê pixel của 44.976 ảnh train CIFAR-100, sau loại trùng và trước resize, trên thang $[0, 1]$. Kênh R có mean cao hơn B khoảng 0,0663; SD ba kênh nằm trong 0,2563–0,2762. Đây là thống kê mô tả, còn mô hình dùng normalization ImageNet.



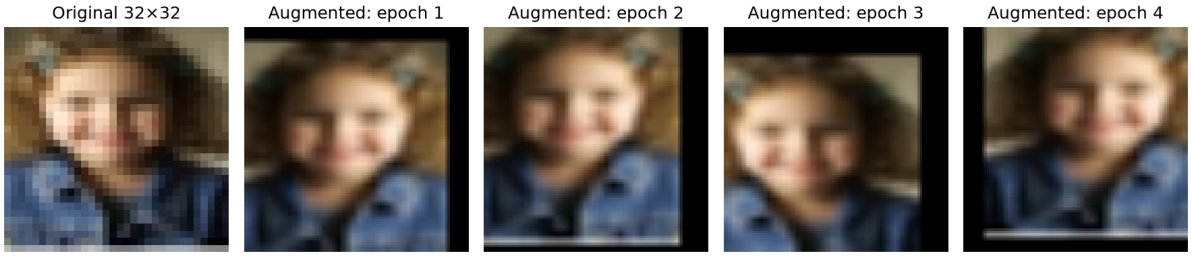
Hình 1.1: Số ảnh của 100 lớp CIFAR-100 sau loại trùng pixel chính xác, với seed chia tập 2026. Mỗi lớp còn 441–450 ảnh train, 50 ảnh validation và 99–100 ảnh test; việc loại trùng giữ được phân bố lớp gần cân bằng.



Hình 1.2: Mười ảnh RGB 32×32 từ tập train CIFAR-100 sau loại trùng, lấy mẫu với seed 2026. Ảnh nhỏ giữ được màu và hình dạng tổng thể nhưng nhiều chi tiết vật thể khó quan sát.

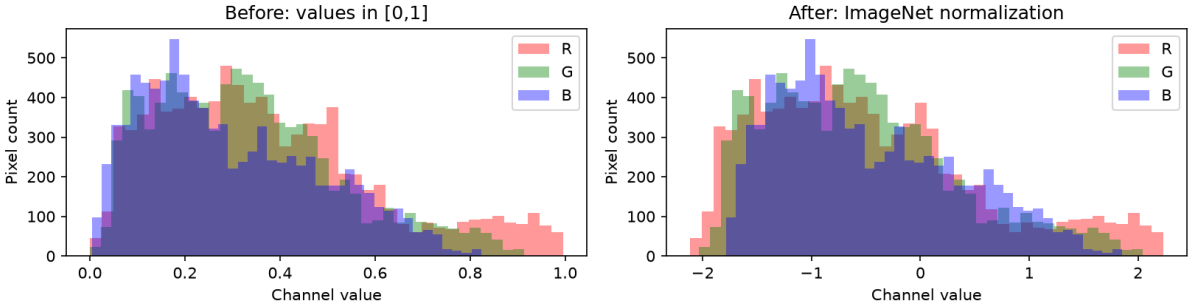
1.3 Tiền xử lý và normalization

Ảnh train được padding 4 pixel, random crop về 32×32, random horizontal flip với xác suất 0,5 rồi resize lên 96×96 bằng nội suy song tuyến tính. Random crop thay đổi vị trí vật thể trong khung ảnh; phép lật ngang tạo thêm cách quan sát cùng vật thể. Validation và test chỉ được resize để kết quả đánh giá ổn định.



Hình 1.3: Ảnh train CIFAR-100 trước xử lý và sau augmentation ở epoch 1–4, với seed train 42. Padding, random crop và horizontal flip thay đổi khung nhìn; kích thước đầu vào sau resize là 96×96.

Pixel được chuyển về $[0, 1]$ rồi normalization theo từng kênh: $x'_c = (x_c - \mu_c)/\sigma_c$, với $\mu = (0{,}485; 0{,}456; 0{,}406)$ và $\sigma = (0{,}229; 0{,}224; 0{,}225)$. Các hằng số ImageNet này đưa đầu vào về thang giá trị mà backbone pretrained sử dụng. Chúng được cố định cho mọi split.



Hình 1.4: Phân phối giá trị R/G/B của một ảnh train CIFAR-100, lấy mẫu với seed 2026, trước và sau normalization ImageNet. Mean kênh R đổi từ 0,3746 thành −0,4822, SD từ 0,2284 thành 0,9974. Phép biến đổi thay đổi thang đo từng kênh; đầu ra có thể âm và không bị giới hạn trong $[0, 1]$.

Augmentation chỉ áp dụng cho train. Validation dùng để chọn checkpoint sau mỗi epoch; test được giữ riêng và chỉ đánh giá khi toàn bộ 18 lượt train đã hoàn tất.

Chương 2

Mô hình và thiết lập thực nghiệm

2.1 Đặc trưng ảnh và cơ chế phân loại

ResNet18 trích xuất đặc trưng bằng các lớp convolution và các khối residual [3]. Khi kích thước phù hợp, một khối có dạng $h_{l+1} = \mathrm{ReLU}(F_l(h_l) + h_l)$: nhánh convolution học phần biến đổi F_l, còn nhánh shortcut giữ đường truyền trực tiếp cho đặc trưng và gradient. Sau các khối này, global average pooling tổng hợp đặc trưng không gian trước lớp phân loại.

Swin-T chia ảnh thành các patch và tính self-attention trong từng cửa sổ, đồng thời luân phiên dịch cửa sổ để trao đổi thông tin giữa các vùng lân cận [4]. Với một attention head, phép tính có dạng

$$\mathrm{Attention}(Q, K, V) = \mathrm{softmax}\left(\frac{QK^{\mathsf{T}}}{\sqrt{d}} + B\right)V,$$

trong đó Q, K, V là các phép chiếu của đặc trưng patch, d là số chiều của key và B biểu diễn độ lệch vị trí tương đối. Qua các stage, patch merging giảm độ phân giải không gian và tăng số kênh đặc trưng. Cửa sổ dịch chuyển giúp các patch ở hai phía ranh giới cửa sổ trao đổi thông tin qua các khối liên tiếp.

Với đặc trưng ảnh $h_\theta(x)$, lớp phân loại mới tạo 100 logit $z = Wh_\theta(x) + b$. Xác suất lớp c là $p_c = \exp(z_c)/\sum_{k=1}^{100}\exp(z_k)$ và nhãn dự đoán là $\arg\max_c p_c$. Cả hai mô hình thay head ImageNet bằng lớp Linear có 100 đầu ra để phù hợp với nhãn CIFAR-100.

2.2 Các mức fine-tuning

ResNet18 sử dụng backbone torchvision pretrained [3, 5]. Head-only chỉ cập nhật lớp Linear 100 chiều; partial cập nhật khối residual cuối và head; full cập nhật toàn bộ mô hình. Swin-T cũng dùng pretrained ImageNet [4, 5]: head-only chỉ cập nhật head, partial cập nhật stage cuối, normalization cuối và head, còn full cập nhật toàn bộ backbone.

Head-only kiểm tra khả năng phân loại từ đặc trưng pretrained khi chỉ học ranh giới quyết định mới. Partial cho phép điều chỉnh đặc trưng ở khối cuối, còn full cho phép thích nghi ở mọi tầng. Các phần đóng băng được giữ ở chế độ đánh giá để không cập nhật thống kê BatchNorm hoặc kích hoạt stochastic depth trong những phần đó. Nhờ vậy, head-only thực sự giữ cố định backbone trong quá trình train.

Chế độ	Khởi tạo	Tham số được cập nhật
Head-only	ImageNet pretrained	Lớp phân loại 100 chiều
Partial	ImageNet pretrained	Khối cuối và lớp phân loại; Swin-T thêm normalization cuối
Full	ImageNet pretrained	Toàn bộ mô hình

Bảng 2.1: Phạm vi tham số được cập nhật ở ba chế độ fine-tuning. Cả hai kiến trúc dùng cùng cách chia dữ liệu, tiền xử lý và seed.

2.3 Huấn luyện và đánh giá

Cả sáu cấu hình dùng cùng ngân sách 20 epoch và batch size 128. AdamW được dùng để cập nhật các tham số được phép học; learning rate giảm theo cosine trong suốt quá trình huấn luyện. Các tham số chính được tóm tắt trong bảng, còn checkpoint được chọn bằng kết quả validation sau mỗi epoch.

Tham số	Giá trị
Số epoch / batch size	20 / 128
Optimizer / weight decay	AdamW / 10^{-4}
Learning rate head-only	10^{-3}
Learning rate partial và full	10^{-4}
Learning-rate schedule	Cosine
Giới hạn gradient norm	1

Bảng 2.2: Thiết lập chung cho hai kiến trúc. Learning rate khác nhau giữa head-only và các chế độ cập nhật backbone.

Loss là cross-entropy không label smoothing. Huấn luyện dùng BF16 trên GPU hỗ trợ định dạng này; tham số và trạng thái optimizer được giữ ở FP32, còn TF32 tắt. Checkpoint có validation accuracy cao nhất được giữ lại; nếu accuracy bằng nhau, chọn checkpoint có validation cross-entropy thấp hơn. Sau khi hoàn tất huấn luyện, checkpoint đã chọn mới được đánh giá trên test.

Với batch gồm m ảnh và nhãn đúng y_i, hàm mất mát được tối thiểu hóa là

$$\mathcal{L}_{\mathrm{CE}} = -\frac{1}{m}\sum_{i=1}^{m} \log p_{i,y_i}.$$

Cross-entropy phạt dự đoán gán xác suất thấp cho nhãn đúng, trong khi accuracy chỉ xét nhãn có xác suất lớn nhất. Vì thế, hai đại lượng có thể biến đổi khác nhau khi mô hình trở nên tự tin hơn. Learning rate nhỏ hơn ở partial/full nhằm hạn chế thay đổi quá mạnh các tham số pretrained.

Accuracy là tỷ lệ ảnh được phân loại đúng. Macro-F1 tính $F1_c = 2TP_c/(2TP_c + FP_c + FN_c)$ cho từng lớp rồi lấy trung bình $\frac{1}{100}\sum_c F1_c$, nên mỗi lớp có trọng số như nhau. Dù

các lớp CIFAR-100 gần cân bằng, báo cáo đồng thời hai chỉ số giúp kiểm tra mức độ nhất quán giữa chất lượng dự đoán chung và chất lượng trung bình theo lớp.

Kết quả được đo trên RTX 5090, PyTorch 2.10.0+cu130 và torchvision 0.25.0+cu130. Số worker nạp dữ liệu bằng 0: ảnh được đọc và augmentation ngay trong tiến trình notebook. Cách này chạy trực tiếp trên môi trường notebook mà không cần tạo tiến trình con.

Thời gian train được cộng từ 20 epoch, gồm nạp dữ liệu, augmentation và tính toán cập nhật tham số, có đồng bộ CUDA. Validation, khởi tạo mô hình và ghi checkpoint được tính riêng. Peak memory là bộ nhớ GPU cấp phát cực đại trong train và validation. Bảng kết quả dùng trung bình và SD mẫu qua seed 42, 43 và 44.

Chương 3

Kết quả và thảo luận

3.1 Accuracy và macro-F1 trên test

Bảng 3.1 trả lời câu hỏi: cập nhật thêm backbone có cải thiện phân loại CIFAR-100 hay không? Ở cả hai kiến trúc, partial tốt hơn head-only và full cho kết quả cao nhất. Swin-T full đạt 86,59 ± 0,24% accuracy, còn ResNet18 full đạt 78,98 ± 0,34%.

Cấu hình	Accuracy test (%)	Macro-F1
ResNet18 head-only	61,08 ± 0,09	0,6095 ± 0,0007
ResNet18 partial	74,18 ± 0,25	0,7418 ± 0,0024
ResNet18 full	78,98 ± 0,34	0,7897 ± 0,0033
Swin-T head-only	71,64 ± 0,14	0,7150 ± 0,0015
Swin-T partial	78,28 ± 0,02	0,7821 ± 0,0005
Swin-T full	86,59 ± 0,24	0,8658 ± 0,0025

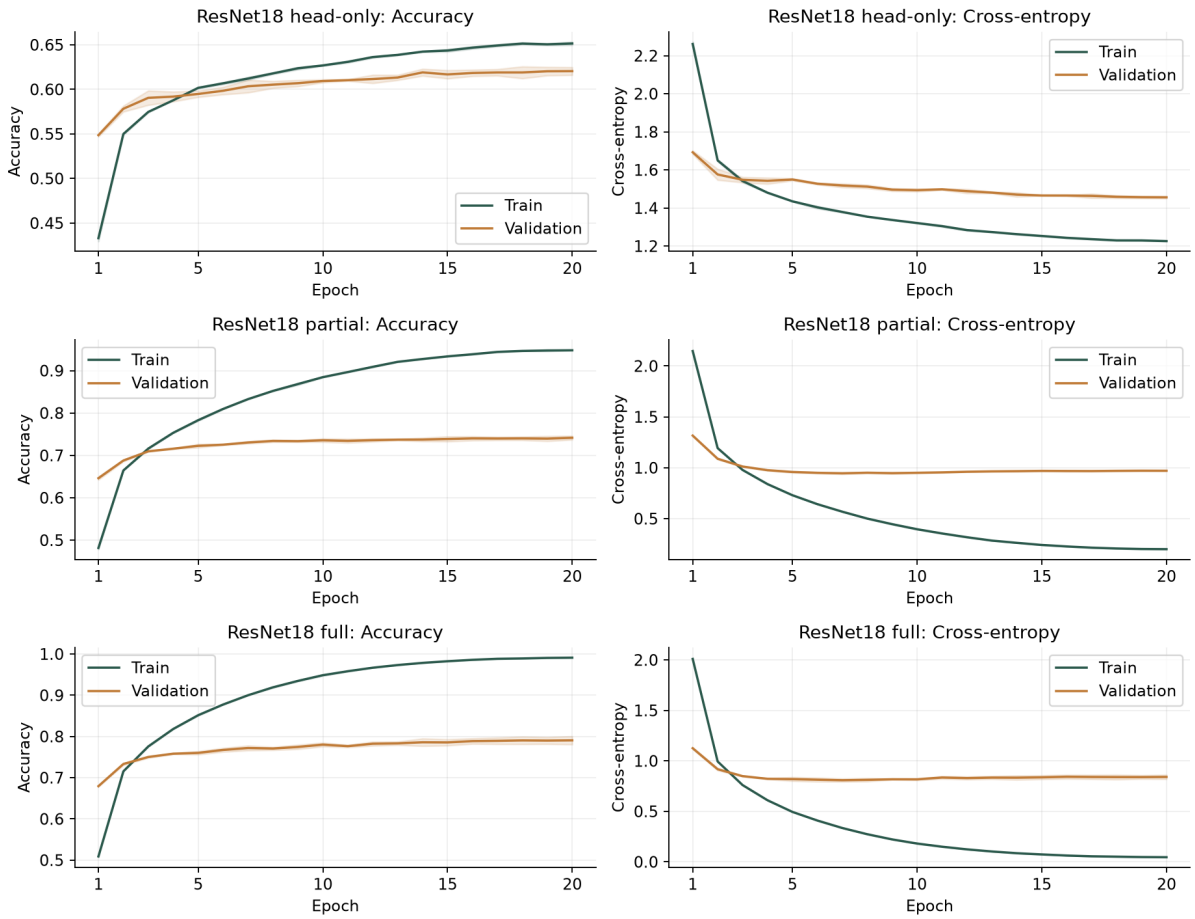
Bảng 3.1: Accuracy và macro-F1 trên 9.998 ảnh test CIFAR-100, trung bình ± SD mẫu qua seed 42, 43 và 44. Full fine-tuning cho kết quả cao nhất ở cả ResNet18 và Swin-T.

Với ResNet18, mở khối cuối làm accuracy tăng 13,10 điểm phần trăm so với head-only. Cập nhật toàn bộ mô hình tăng thêm 4,80 điểm. Với Swin-T, hai bước tăng tương ứng là 6,63 và 8,31 điểm. Vì vậy, partial đã đem lại phần lớn mức tăng của ResNet18, còn Swin-T hưởng lợi nhiều hơn khi được điều chỉnh toàn bộ backbone.

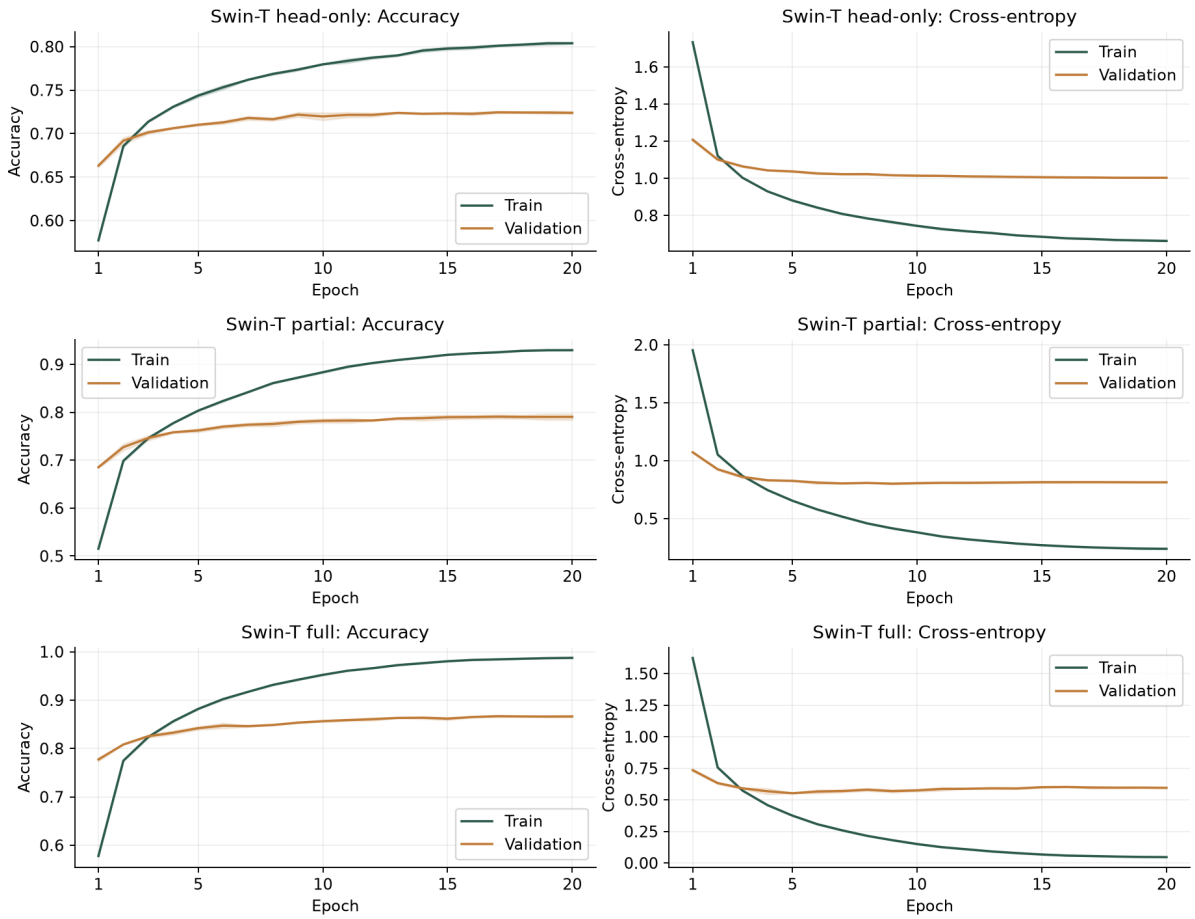
Macro-F1 cho cùng thứ tự như accuracy. Cấu hình cải thiện tỷ lệ dự đoán đúng cũng cải thiện F1 trung bình theo lớp. Phần phân tích confusion matrix bên dưới xem cụ thể những lớp nào vẫn dễ bị nhầm.

3.2 Accuracy và cross-entropy qua 20 epoch

Ở epoch cuối, ResNet18 full đạt 99,11% accuracy train và 79,05% trên validation; Swin-T full đạt 98,73% và 86,62%. Mô hình học rất tốt các ảnh train, trong khi ảnh validation vẫn khó hơn. Khoảng cách này là lý do cần theo dõi validation để chọn checkpoint. Số đo train được tích lũy trong lúc cập nhật tham số và có augmentation, còn validation được đo bằng mô hình cố định sau mỗi epoch.



Hình 3.1: Accuracy và cross-entropy train/validation của ResNet18 ở ba chế độ fine-tuning qua 20 epoch. Đường là trung bình của seed 42, 43 và 44; vùng tô là ± SD mẫu. Full đạt validation accuracy cao hơn head-only và partial.



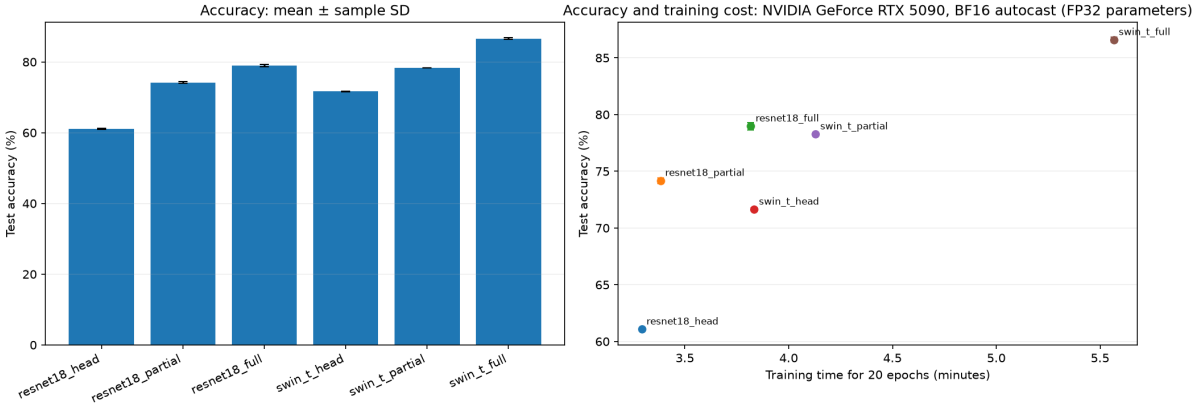
Hình 3.2: Accuracy và cross-entropy train/validation của Swin-T ở ba chế độ fine-tuning qua 20 epoch. Đường là trung bình của seed 42, 43 và 44; vùng tô là ± SD mẫu. Full duy trì validation accuracy cao nhất trong ba chế độ.

3.3 Accuracy so với thời gian và bộ nhớ

So sánh cùng seed, Swin-T full cao hơn ResNet18 full 7,61±0,42 điểm phần trăm accuracy. Độ lệch chuẩn ở đây được tính từ ba chênh lệch ghép cặp, giúp giữ nguyên seed khi đối chiếu hai kiến trúc.

Cấu hình	Thời gian train (s)	Peak allocated memory (MiB)
ResNet18 head-only	197,5 ± 0,7	203,8 ± 0,5
ResNet18 partial	202,9 ± 0,3	300,4 ± 0,0
ResNet18 full	229,1 ± 0,1	472,0 ± 0,0
Swin-T head-only	230,0 ± 0,0	455,6 ± 0,0
Swin-T partial	247,7 ± 0,4	616,2 ± 0,0
Swin-T full	334,0 ± 0,6	2409,6 ± 0,0

Bảng 3.2: Chi phí train 20 epoch trên RTX 5090, batch size 128, số worker nạp dữ liệu bằng 0; trung bình ± SD mẫu qua seed 42, 43 và 44. Full dùng nhiều bộ nhớ hơn head-only ở cả hai kiến trúc.

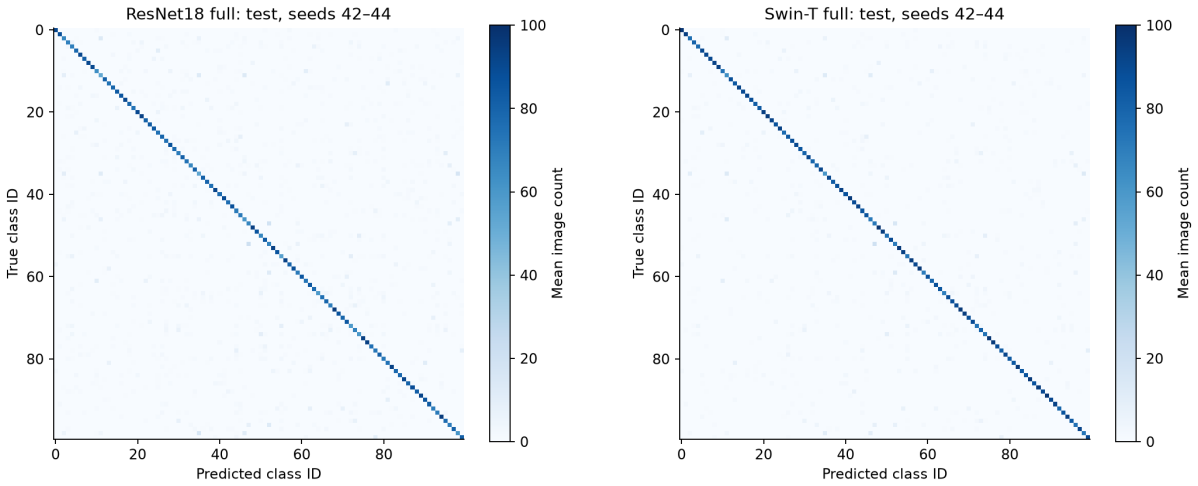


Hình 3.3: Accuracy test và thời gian train 20 epoch của sáu cấu hình trên RTX 5090; accuracy là trung bình ± SD mẫu qua seed 42, 43 và 44. Swin-T full đạt 86,59%, cao hơn ResNet18 full 7,61 điểm phần trăm, với thời gian train gấp 1,46 lần.

Swin-T full mất trung bình 334,0 giây, so với 229,1 giây của ResNet18 full. Bộ nhớ cấp phát cực đại gấp 5,11 lần. Đây là mức chi phí đổi lấy accuracy cao hơn trong thiết lập này. Nếu ưu tiên bộ nhớ, head-only dùng ít nhất; nếu ưu tiên chất lượng dự đoán, full là lựa chọn tốt hơn trong cả hai kiến trúc.

ResNet18 partial và Swin-T partial tốn thời gian chỉ nhiều hơn head-only lần lượt khoảng 2,7% và 7,7%. Thời gian đo bao gồm cả đọc ảnh và augmentation trong cùng tiến trình do số worker bằng 0. Vì vậy, giảm số tham số học không làm tổng thời gian giảm theo cùng tỷ lệ; các bước chuẩn bị dữ liệu vẫn phải thực hiện với mọi ảnh.

3.4 Những cặp lớp dễ bị nhầm



Hình 3.4: Confusion matrix trên test của ResNet18 full (trái) và Swin-T full (phải), trung bình qua seed 42, 43 và 44. Hàng là nhãn đúng, cột là nhãn dự đoán; màu biểu diễn số ảnh trung bình tại mỗi ô.

Đường chéo của confusion matrix ghi nhận dự đoán đúng. Các ô ngoài đường chéo cho biết mô hình nhầm từ lớp nào sang lớp nào. Bảng 3.3 ghi tên và số lượng của bốn hướng nhầm nổi bật để dễ đọc hơn hình 100 lớp.

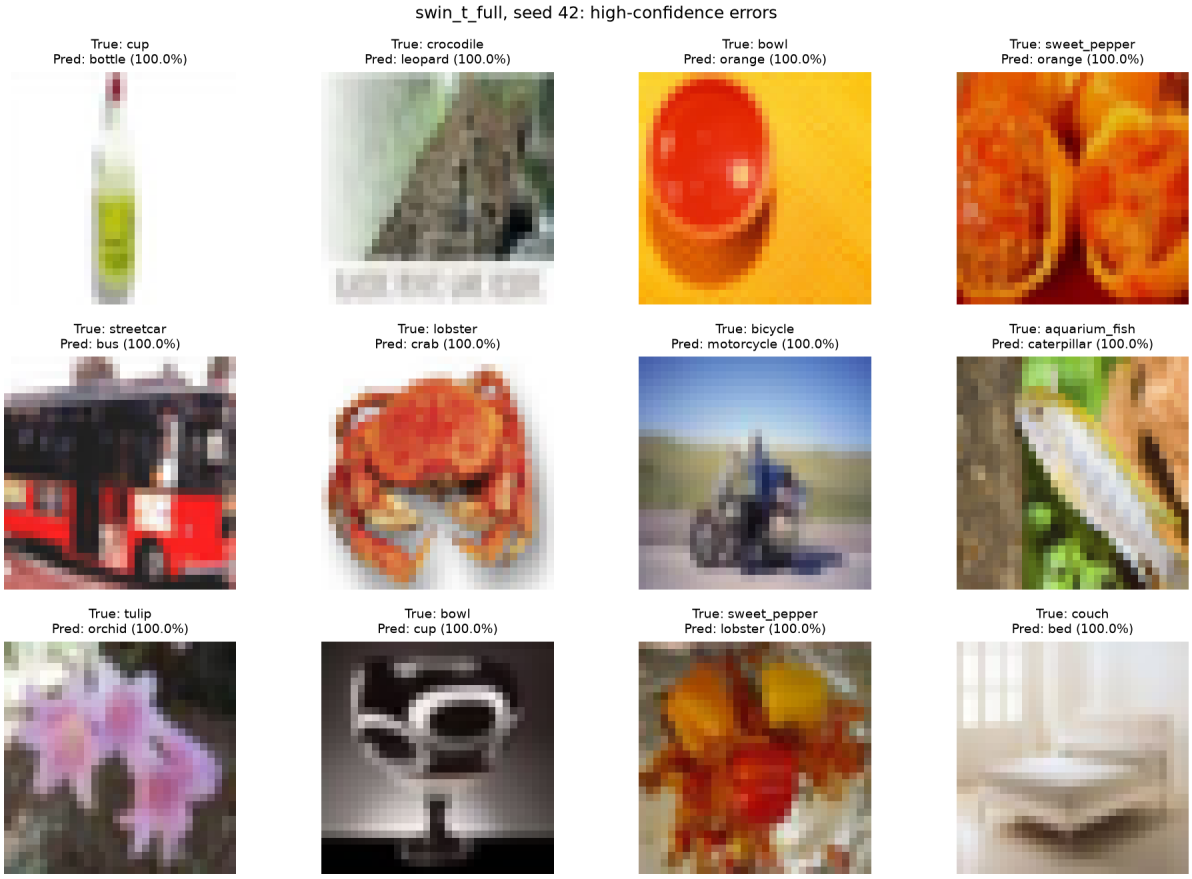
Nhãn đúng (hàng)	Nhãn dự đoán (cột)	ResNet18 full	Swin-T full
oak_tree (52)	maple_tree (47)	20,33	20,00
maple_tree (47)	oak_tree (52)	18,67	15,33
woman (98)	girl (35)	15,33	10,33
girl (35)	woman (98)	16,67	12,67

Bảng 3.3: Số lỗi trung bình trên test qua seed 42, 43 và 44 tại bốn hướng nhầm của hai mô hình full. Swin-T giảm lỗi ở cả bốn hướng, nhưng oak_tree sang maple_tree vẫn có khoảng 20 lỗi mỗi lượt. Chỉ số lớp bắt đầu từ 0.

Hai loại cây oak_tree và maple_tree vẫn khó phân biệt nhất trong các hướng này. Swin-T giảm lỗi ở cả hai chiều, nhưng mức giảm từ oak_tree sang maple_tree nhỏ. Với woman và girl, số lỗi giảm rõ hơn. Kết quả cho thấy phần accuracy tăng thêm của Swin-T đi cùng mức cải thiện khác nhau giữa các cặp lớp.

3.5 Dự đoán sai dù confidence cao

Hình 3.5 xem câu hỏi: mô hình tốt nhất theo validation còn mắc lỗi như thế nào? Swin-T full được chọn theo accuracy validation trung bình, sau đó lấy các dự đoán của seed 42. Trên test, lượt này dự đoán sai 1.324 ảnh và đúng 8.674 ảnh, tương ứng accuracy 86,76%.



Hình 3.5: 12 lỗi có confidence cao nhất của Swin-T full, seed 42, trên test CIFAR-100. Mô hình sai 1.324/9.998 ảnh (13,24%), trong đó 390 ảnh sai có confidence từ 95% trở lên. Confidence cao vẫn có thể đi kèm nhãn sai; giá trị 100,0% trên hình là kết quả làm tròn.

Các ví dụ gồm streetcar bị nhận thành bus, bicycle thành motorcycle và bowl thành cup. Những cặp này có hình dạng hoặc bối cảnh gần nhau trong ảnh nhỏ. Confidence là xác suất softmax của lớp dự đoán, được tính từ logit của mô hình. Trung bình confidence ở ảnh đúng là 97,03%, còn ở ảnh sai là 76,94%. Nhóm sai nhìn chung ít tự tin hơn, nhưng vẫn có 390 lỗi vượt ngưỡng 95%. Vì vậy, chỉ dùng confidence cao để chấp nhận dự đoán sẽ bỏ sót một phần lỗi.

3.6 Kết luận

Full fine-tuning cho accuracy cao nhất ở cả ResNet18 và Swin-T. Partial đã tăng đáng kể chất lượng so với chỉ học head, đặc biệt ở ResNet18. Swin-T full tiếp tục cải thiện rõ khi mở toàn bộ backbone và đạt kết quả tốt nhất trong sáu cấu hình.

Lựa chọn mô hình còn phụ thuộc vào tài nguyên. ResNet18 full dùng ít thời gian và bộ nhớ hơn Swin-T full, còn Swin-T đổi phần chi phí tăng thêm lấy accuracy cao hơn. Các lỗi giữa những lớp cây và các ví dụ sai với confidence cao cho thấy chất lượng tổng thể tốt vẫn cần được kiểm tra ở từng nhóm ảnh.

3.7 Giới hạn

Thực nghiệm dùng một cách chia dữ liệu cố định, ba seed và ngân sách 20 epoch. SD mô tả biến động giữa các lượt train trên cách chia này. Kết quả chưa bao quát thời lượng dài hơn, train from scratch làm baseline hoặc tìm kiếm siêu tham số riêng cho từng kiến trúc. Head-only cũng dùng learning rate khác partial/full, nên đối chiếu đánh giá cả thiết lập fine-tuning.

Ảnh gốc chỉ có 32 px; resize lên 96 px giúp thống nhất đầu vào nhưng không thêm chi tiết. Chưa có phép so sánh trực tiếp với 128 px hoặc kiểm tra ảnh gần trùng. Chi phí được đo trên một RTX 5090 với số worker bằng 0, do đó cần đo lại khi đổi phần cứng hoặc cách nạp dữ liệu.

Thông tin sử dụng AI được trình bày trong AI_USE_REPORT.md.

Tài liệu tham khảo

[1] Lê Thành Sách. *Course Assignment: Nền tảng lập trình cho phân tích và trực quan dữ liệu*. CO5177, v4.0, 14/09/2026.

[2] A. Krizhevsky. *Learning Multiple Layers of Features from Tiny Images*. 2009. `https://www.cs.toronto.edu/~kriz/cifar.html`.

[3] K. He và cộng sự. *Deep Residual Learning for Image Recognition*. CVPR 2016. `https://arxiv.org/abs/1512.03385`.

[4] Z. Liu và cộng sự. *Swin Transformer: Hierarchical Vision Transformer using Shifted Windows*. ICCV 2021. `https://arxiv.org/abs/2103.14030`.

[5] Torchvision. ResNet18 và Swin-T; trọng số IMAGENET1K_V1. `https://docs.pytorch.org/vision/stable/models.html`.