ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



NỀN TẢNG LẬP TRÌNH CHO PHÂN TÍCH
VÀ TRỰC QUAN DỮ LIỆU
Mã môn học: CO5177

BÁO CÁO IMAGE

CNN vs Transformer trên CIFAR-100

ResNet18 và Swin-T

Học kỳ 261 · Năm học 2026–2027

Giảng viên: Lê Thành Sách

Nhóm: CTG

Thành viên: Huỳnh Thành Đạt · 2570161
Lương Minh Duy · 2570083

Thành phố Hồ Chí Minh, tháng 10 năm 2026

Mục lục

1 Bài toán và dữ liệu **1**
1.1 Mục tiêu và phạm vi . . . 1
1.2 Dữ liệu CIFAR-100 . . . 1
1.3 Chia tập và tiền xử lý . . . 1
1.4 Phạm vi thực nghiệm . . . 2
1.5 Khám phá dữ liệu và kiểm tra ảnh trùng . . . 2

2 Kiến trúc và chế độ huấn luyện **4**
2.1 ResNet18: đối chứng CNN . . . 4
2.2 Swin-T: đối chứng Transformer . . . 4
2.3 Ma trận đối chứng . . . 5

3 Thiết lập thực nghiệm và phép đo **6**
3.1 Thiết lập huấn luyện . . . 6
3.2 Chọn mô hình và đánh giá . . . 6
3.3 Chi phí và môi trường . . . 7

4 Kết quả thực nghiệm và thảo luận **8**
4.1 So sánh các chế độ huấn luyện . . . 8
4.2 Thời gian, bộ nhớ và số tham số . . . 8
4.3 Thảo luận kết quả . . . 8
4.4 Đường cong học và các lớp dễ nhầm . . . 9

5 Kết luận và giới hạn **14**
5.1 Kết luận . . . 14
5.2 Giới hạn . . . 14

Tài liệu tham khảo **15**

Chương 1

Bài toán và dữ liệu

1.1 Mục tiêu và phạm vi

Phần Image so sánh CNN và Transformer trên CIFAR-100, tập trung vào ảnh hưởng của khởi tạo pretrained và mức độ đóng băng backbone. Hai kiến trúc được chọn là ResNet18 và Swin-T của torchvision. Mỗi kiến trúc có bốn chế độ huấn luyện, chạy với ba seed 42, 43 và 44, tổng cộng 24 lượt chạy.

So sánh chính của bài Image gồm sáu cấu hình pretrained: head-only, partial và full fine-tuning của mỗi kiến trúc, tương ứng 18 lượt chạy. Hai cấu hình scratch với sáu lượt chạy còn lại là đối chứng bổ sung. Accuracy, macro-F1, thời gian và bộ nhớ được dùng để đánh giá hiệu quả cùng chi phí của từng chế độ.

1.2 Dữ liệu CIFAR-100

CIFAR-100 gồm 60.000 ảnh màu 32×32, 100 nhãn chi tiết (fine classes) và 20 nhóm coarse classes. Bài này dự đoán toàn bộ 100 fine classes; không chọn subset ảnh hoặc lớp. Mỗi lớp có 500 ảnh official train và 100 ảnh official test [2]. Ảnh độ phân giải thấp có thể làm những lớp gần nhau khó phân biệt.

Nguồn chính là trang CIFAR của Toronto, của Alex Krizhevsky, Vinod Nair và Geoffrey Hinton. Trang này không nêu license tường minh; thẻ dataset chính thức `uoft-cs/cifar100` trên Hugging Face ghi *license: unknown* [2, 3]. Vì vậy, tình trạng license của dữ liệu được ghi là chưa rõ. Ảnh gốc được tải từ Toronto để thực hiện thí nghiệm và lưu ngoài repository.

1.3 Chia tập và tiền xử lý

Từ 50.000 ảnh train gốc, shuffle indices riêng từng lớp bằng NumPy `default_rng(2026)`. Lấy 50 ảnh/lớp làm validation, 450 ảnh/lớp làm train: 45.000 train và 5.000 validation. Indices được sắp tăng sau khi chọn và lưu cùng hash. Official test 10.000 ảnh nằm riêng, không dùng cập nhật tham số hoặc chọn checkpoint. Train seed 42/43/44 không thay split seed 2026.

Train dùng RandomCrop 32×32 với padding 4, horizontal flip xác suất 0,5, sau đó bilinear resize 96×96 có antialias. Val/test chỉ resize, không crop ngẫu nhiên hoặc flip. Cả hai họ và mọi chế độ dùng ImageNet mean $(0{,}485, 0{,}456, 0{,}406)$, std $(0{,}229, 0{,}224, 0{,}225)$ sau ToTensor. Không dùng trực tiếp recipe `weights.transforms()` của pretrained.

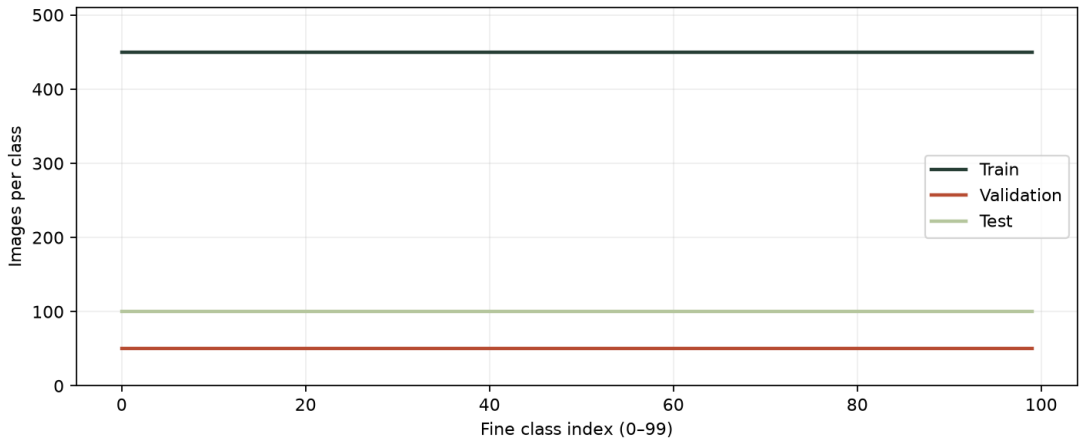
1.4 Phạm vi thực nghiệm

CIFAR-100 đáp ứng số ảnh và số lớp quy định cho bài Image [1]. Cạnh ngắn 32 px của ảnh gốc thấp hơn mức khuyến nghị 128 px. Đầu vào được nội suy lên 96 px để giữ điều kiện của thí nghiệm A1, với cùng độ phân giải cho cả hai kiến trúc. Phép nội suy điều chỉnh kích thước lưới ảnh nhưng giữ giới hạn chi tiết của ảnh gốc.

Sáu cấu hình tiền huấn luyện là đối chứng chính, gồm ba mức cập nhật tham số cho mỗi kiến trúc. Hai cấu hình học từ đầu cho thấy kết quả khi không có khởi tạo ImageNet trong cùng ngân sách 20 epoch. Các chỉ số, thời gian và bộ nhớ thuộc cùng 24 lượt chạy đã công bố trong A1 CO5085.

1.5 Khám phá dữ liệu và kiểm tra ảnh trùng

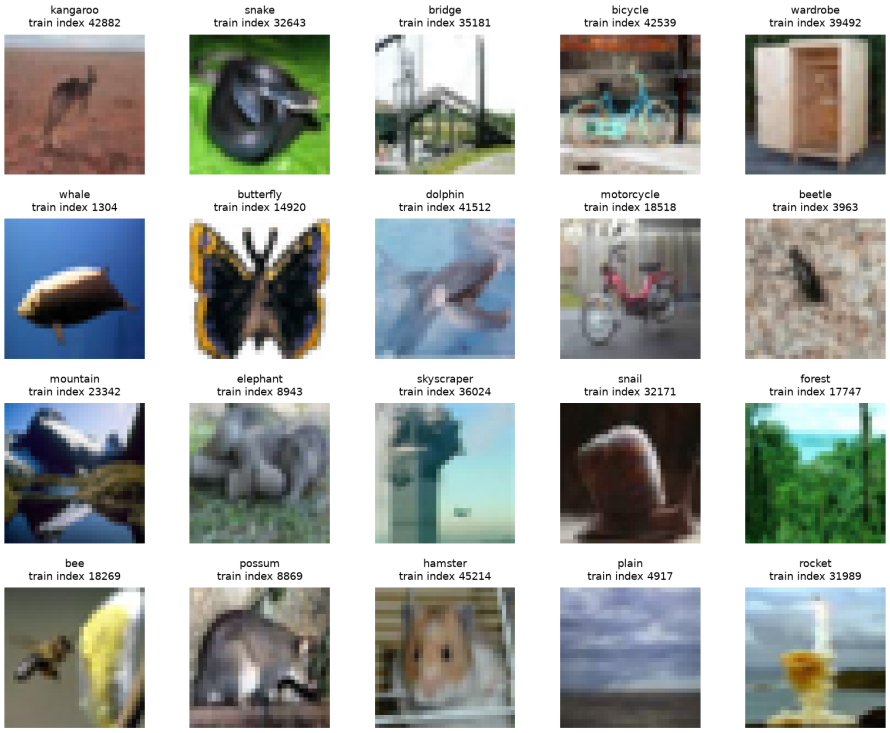
Tập CIFAR-100 cân bằng theo số ảnh. Mỗi lớp có 450 ảnh huấn luyện, 50 ảnh xác thực và 100 ảnh kiểm tra. Tuy vậy, các lớp có hình dáng hoặc kết cấu gần nhau vẫn có thể khó phân biệt ở kích thước ảnh gốc. Bản dữ liệu dùng để khám phá có cùng thứ tự, pixel và nhãn với bản dùng trong thí nghiệm A1.



Hình 1.1: Số ảnh từng fine class sau split. Các lớp có cùng số ảnh trong mỗi split.

Đối chiếu theo pixel phát hiện 14 ảnh lặp nội dung trong 50.000 ảnh dùng để huấn luyện và xác thực. Hai ảnh xác thực và mười ảnh kiểm tra có nội dung trùng với ảnh huấn luyện. Phép đối chiếu chỉ bao gồm ảnh trùng pixel chính xác.

Trong kiểm tra độ nhạy, loại 10 ảnh test trùng train và tính lại chỉ số trên 9.990 dự đoán còn lại của cùng checkpoint. ResNet18 tinh chỉnh toàn bộ đạt 79,009%, so với 78,970% ban đầu. Swin-T đạt 86,677%, so với 86,630%. Chênh lệch nhỏ này không loại trừ ảnh hưởng của hai nội dung trùng train–validation đến việc chọn checkpoint, cũng không đánh giá ảnh gần trùng. Đây là phân tích trên dự đoán đã lưu, không phải phép đo huấn luyện mới.



Hình 1.2: Hai mươi ảnh train chọn bằng seed 2026, kèm nhãn và chỉ số gốc. Ảnh được phóng lớn để quan sát; chi tiết phân biệt một số lớp vẫn hạn chế.

Chương 2

Kiến trúc và chế độ huấn luyện

2.1 ResNet18: đối chứng CNN

Giữ kiến trúc ResNet18 chuẩn torchvision, gồm stem convolution 7×7, max pooling và bốn residual stages. Một residual block cập nhật

$$h_{l+1} = \text{ReLU}\left(F_l(h_l) + S_l(h_l)\right), \tag{2.1}$$

trong đó S_l là identity hoặc projection khi đổi số kênh/stride. Kernel convolution chia sẻ trọng số theo vị trí và khai thác quan hệ cục bộ. Sau adaptive average pooling, head Linear được thay để dự đoán 100 lớp; không thay stem thành biến thể ResNet chuyên cho CIFAR.

Bản pretrained dùng `ResNet18_Weights.IMAGENET1K_V1`. Ba chế độ là chỉ học `fc`; học `layer4` và `fc`; học toàn bộ. Bản scratch khởi tạo mới và học toàn bộ. BatchNorm trong phần frozen ở eval, nên cả tham số lẫn running mean/variance và bộ đếm batch được giữ nguyên.

2.2 Swin-T: đối chứng Transformer

Swin-T dùng patch embedding stride4, các stage Transformer theo cấp độ và patch merging. Attention trên cửa sổ có dạng

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d}} + B + M\right)V, \tag{2.2}$$

trong đó B là relative position bias, M là mask của shifted windows. Dịch cửa sổ giúp trao đổi thông tin giữa cửa sổ qua các block; việc giới hạn attention trong cửa sổ khác với global attention của ViT cổ điển.

Swin-T giữ kiến trúc chuẩn torchvision, với `head` được thay bằng Linear 100 lớp. Đầu vào 96×96 tạo lưới patch đầu 24×24; các stage muộn có lưới nhỏ hơn. Kích thước cửa sổ mặc định là 7, với padding nội bộ ở những stage có kích thước không chia hết cho cửa sổ.

Bản pretrained dùng `Swin_T_Weights.IMAGENET1K_V1`. Chế độ partial chỉ học stage cuối `features.7`, `norm` cuối và `head`; patch merging đứng trước stage cuối vẫn frozen. Head-only chỉ học head. Frozen stages được giữ ở eval, bao gồm stochastic depth, để đặc trưng của phần đóng băng ổn định trong quá trình học head. Full và scratch cập nhật toàn bộ mô hình.

2.3 Ma trận đối chứng

Chế độ	Khởi tạo backbone	Phần được cập nhật
Scratch	Ngẫu nhiên	Toàn bộ
Head-only	ImageNet pretrained	Head100
Partial	ImageNet pretrained	Stage cuối và head; Swin thêm norm
Full	ImageNet pretrained	Toàn bộ

Bảng 2.1: Bốn chế độ cho mỗi họ kiến trúc, cùng split và ba seed.

Scratch cập nhật toàn bộ mô hình từ khởi tạo ngẫu nhiên. Số tham số tổng và trainable được đếm trực tiếp từ từng mô hình và lưu trong metadata. ResNet18 và Swin-T khác nhau về kiến trúc, capacity và recipe pretrained; các kết quả phản ánh tổng thể những khác biệt này trong cùng thiết lập.

Chương 3

Thiết lập thực nghiệm và phép đo

3.1 Thiết lập huấn luyện

Mỗi lượt huấn luyện có 20 epoch, batch 128 (giữ batch cuối), vòng lặp huấn luyện trực tiếp, AdamW với weight decay 10^{-4}, $\beta = (0{,}9, 0{,}999)$, epsilon 10^{-8}. Learning rate ban đầu là 10^{-3} cho scratch/head và 10^{-4} cho pretrained partial/full. Cosine scheduler bước một lần sau epoch:

$$\eta_e = \frac{\eta_0}{2}\left[1 + \cos\left(\frac{\pi e}{20}\right)\right], \tag{3.1}$$

với $e = 0$ trước epoch đầu. Loss cross-entropy không label smoothing:

$$\mathcal{L} = -\frac{1}{B}\sum_{i=1}^{B} \log \frac{\exp z_{i,y_i}}{\sum_{c=1}^{100} \exp z_{i,c}}. \tag{3.2}$$

Clip global gradient norm ở 1 trước optimizer.step. BF16 autocast áp dụng cho tất cả chế độ; tham số và Adam moments giữ FP32, không GradScaler, TF32 tắt và không dùng compile. Các phép đo được thiết lập trên RTX 5090 với 8 workers và 4 CPU threads.

Ngân sách 20 epoch được giữ cố định giữa các chế độ. Learning rate của head/scratch và partial/full được đặt khác nhau để phù hợp với mức độ cập nhật backbone. Kết quả vì vậy được phân tích theo từng thiết lập đầy đủ; mức hội tụ còn được đối chiếu qua đường cong train/validation.

3.2 Chọn mô hình và đánh giá

Best chọn bằng val accuracy lớn nhất; hòa accuracy thì lấy CE nhỏ nhất, hòa cả hai giữ epoch trước. Chỉ val được dùng ra quyết định trong train. Test được đánh giá ở một bước riêng sau khi hoàn tất các lượt huấn luyện. Các cấu hình, learning rate và seed được cố định trước bước này.

Accuracy và macroF1 đều tính trên 100 lớp. Với mỗi lớp c,

$$F1_c = \frac{2TP_c}{2TP_c + FP_c + FN_c}, \qquad F1_{macro} = \frac{1}{100}\sum_{c=1}^{100} F1_c. \tag{3.3}$$

Trường hợp mẫu số bằng0 có F1 bằng0. Confusion matrix, support, precision, recall, F1 theo lớp và từng prediction được lưu để kiểm tra. Gallery lấy tối đa 8 lỗi confidence cao nhất của seed 42.

3.3 Chi phí và môi trường

Training time bao gồm data loading/augmentation và train pass, có CUDA synchronize trước/sau. Epoch time thêm validation. Model construction, checkpoint và report export nằm ngoài hai khoảng đo; không gọi training time là tổng wall time của job. Peak GPU memory là peak allocated trong train và validation của mỗi epoch, không phải reserved memory hoặc VRAM toàn hệ thống.

Metadata lưu GPU, torch/torchvision, CUDA/cuDNN, workers, CPU threads và chế độ deterministic. Các phép đo thời gian của cùng cấu hình được gộp khi những thông số môi trường này thống nhất.

Chương 4

Kết quả thực nghiệm và thảo luận

4.1 So sánh các chế độ huấn luyện

Kiến trúc	Chế độ	Val (%)	Test (%)	Macro-F1
ResNet18	Scratch	63.83 ± 0.51	64.35 ± 0.11	0.6422 ± 0.0012
ResNet18	Head-only	61.89 ± 0.24	60.95 ± 0.29	0.6081 ± 0.0030
ResNet18	Partial	74.50 ± 0.31	73.96 ± 0.12	0.7396 ± 0.0011
ResNet18	Full	79.29 ± 0.10	78.97 ± 0.04	0.7898 ± 0.0006
Swin-T	Scratch	2.81 ± 1.40	2.76 ± 1.26	0.0093 ± 0.0069
Swin-T	Head-only	72.45 ± 0.10	71.67 ± 0.09	0.7154 ± 0.0009
Swin-T	Partial	78.99 ± 0.31	78.25 ± 0.22	0.7818 ± 0.0021
Swin-T	Full	86.89 ± 0.02	86.63 ± 0.22	0.8663 ± 0.0020

Bảng 4.1: Accuracy và macro-F1 của tám cấu hình, trung bình và SD mẫu qua ba seed. Accuracy theo phần trăm, F1 theo thang 0–1.

Kết quả được tổng hợp bằng trung bình và độ lệch chuẩn mẫu qua các seed.

4.2 Thời gian, bộ nhớ và số tham số

Kiến trúc	Chế độ	Tổng (M)	Học (M)	Train (s)	VRAM (MiB)
ResNet18	Scratch	11.228	11.228	253.4 ± 1.2	522.5
ResNet18	Head-only	11.228	0.051	155.9 ± 2.9	252.1
ResNet18	Partial	11.228	8.445	194.1 ± 0.2	347.3
ResNet18	Full	11.228	11.228	257.6 ± 3.2	522.4
Swin-T	Scratch	27.596	27.596	727.1 ± 4.8	2456.9
Swin-T	Head-only	27.596	0.077	265.3 ± 2.1	502.2
Swin-T	Partial	27.596	14.262	347.5 ± 0.4	663.6
Swin-T	Full	27.596	27.596	724.4 ± 1.7	2456.9

Bảng 4.2: Tổng tham số và tham số được học theo triệu (M); thời gian train đủ 20 epoch; peak allocated memory trung bình theo MiB. Phạm vi phép đo ở Mục 3.3.

4.3 Thảo luận kết quả

Ở cả hai kiến trúc, cập nhật khối cuối cho kết quả cao hơn chỉ học lớp phân loại. ResNet18 tăng từ 60,95% lên 73,96%; Swin-T tăng từ 71,67% lên 78,25%. Khi tinh chỉnh toàn bộ, hai mô hình

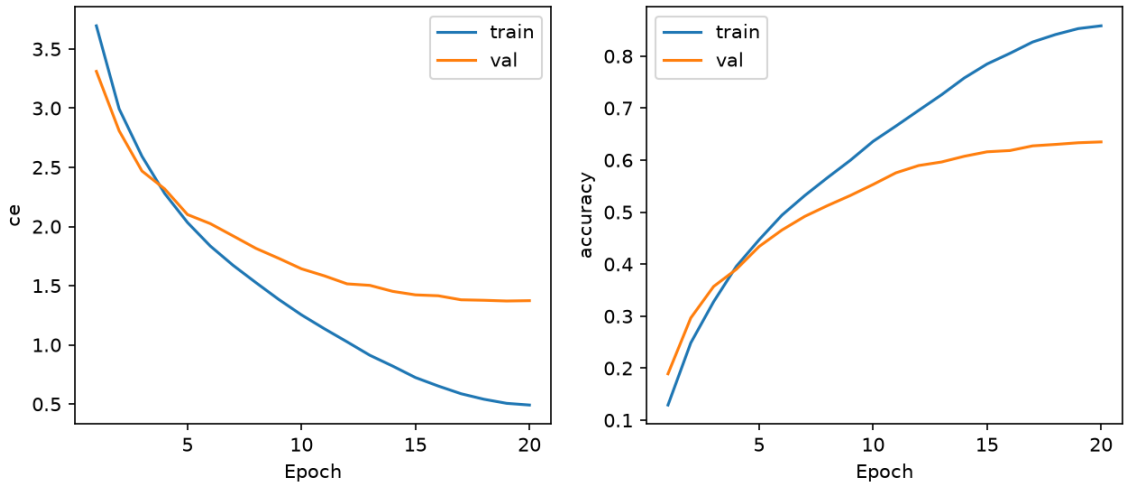
đạt lần lượt 78,97% và 86,63%. Kết quả phù hợp với việc các tầng cuối cần thích nghi từ biểu diễn ImageNet sang CIFAR-100.

Swin-T tinh chỉnh toàn bộ cao hơn ResNet18 tinh chỉnh toàn bộ $7{,}66 \pm 0{,}18$ điểm phần trăm khi ghép cùng hạt giống. Trong điều kiện đo, thời gian huấn luyện gấp 2,81 lần và bộ nhớ cấp phát cực đại gấp 4,70 lần. Chỉ học đầu ra giảm bộ nhớ từ 522,4 xuống 252,1 MiB với ResNet18 và từ 2.456,9 xuống 502,2 MiB với Swin-T.

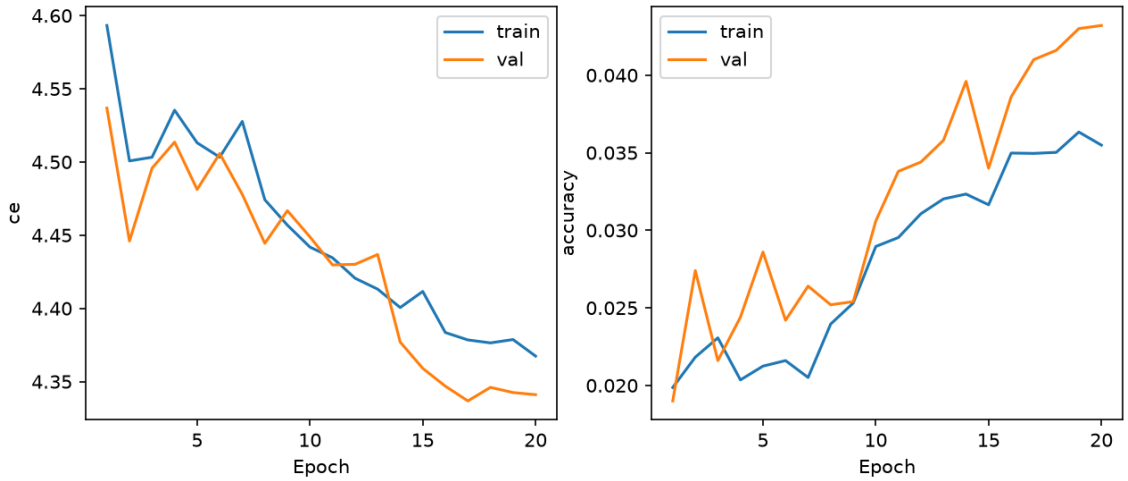
Swin-T học từ đầu đạt $2{,}76 \pm 1{,}26\%$. Ở hai hạt giống 43 và 44, độ chính xác xác thực ở epoch cuối khoảng 1%, gần mức dự đoán đều trên 100 lớp. Điểm này mô tả đối chứng với 20 epoch và lịch tốc độ học đã chọn. Phép so sánh chưa khảo sát thời lượng huấn luyện dài hơn cho Swin-T học từ đầu.

4.4 Đường cong học và các lớp dễ nhầm

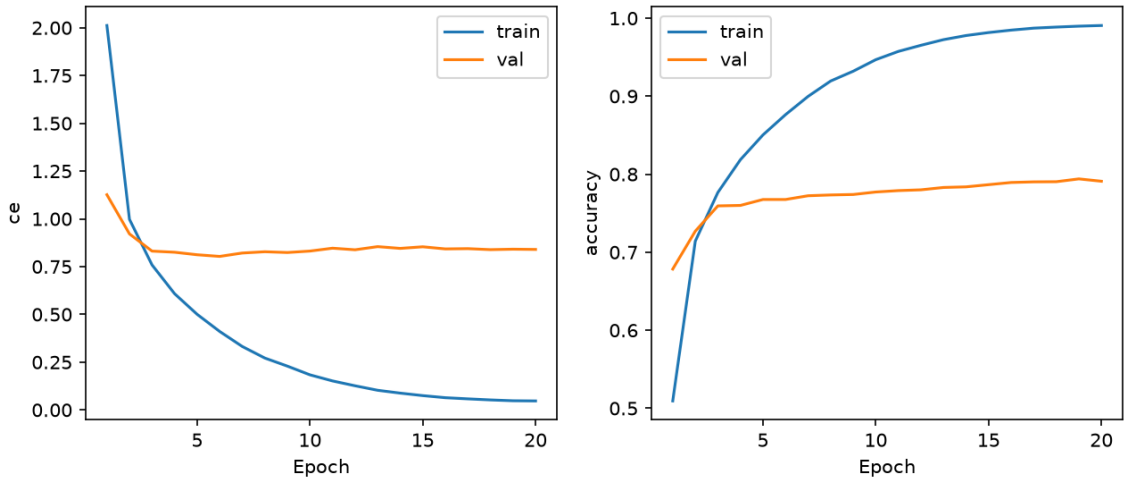
Các hình dùng seed 42 đã định trước, không chọn seed theo kết quả test. Ma trận lỗi dùng chỉ số lớp 0–99; danh sách tên lớp và số đếm đầy đủ nằm trong các tệp CSV kèm báo cáo. Các hình so sánh mô hình học từ đầu và tinh chỉnh toàn bộ ở hạt giống 42. Khi tinh chỉnh toàn bộ, độ chính xác huấn luyện tiếp tục tăng sau giai đoạn đầu, còn độ chính xác xác thực tăng chậm hơn. Khoảng cách giữa hai đường cong cho thấy mô hình khớp dữ liệu huấn luyện tốt hơn dữ liệu xác thực.



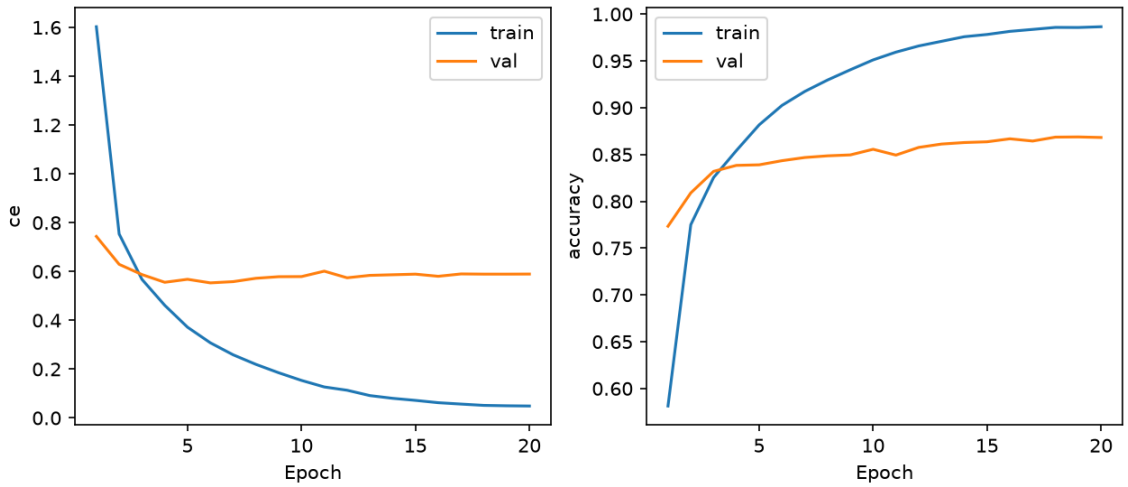
Hình 4.1: ResNet18 scratch: train/val CE và accuracy ở seed 42.



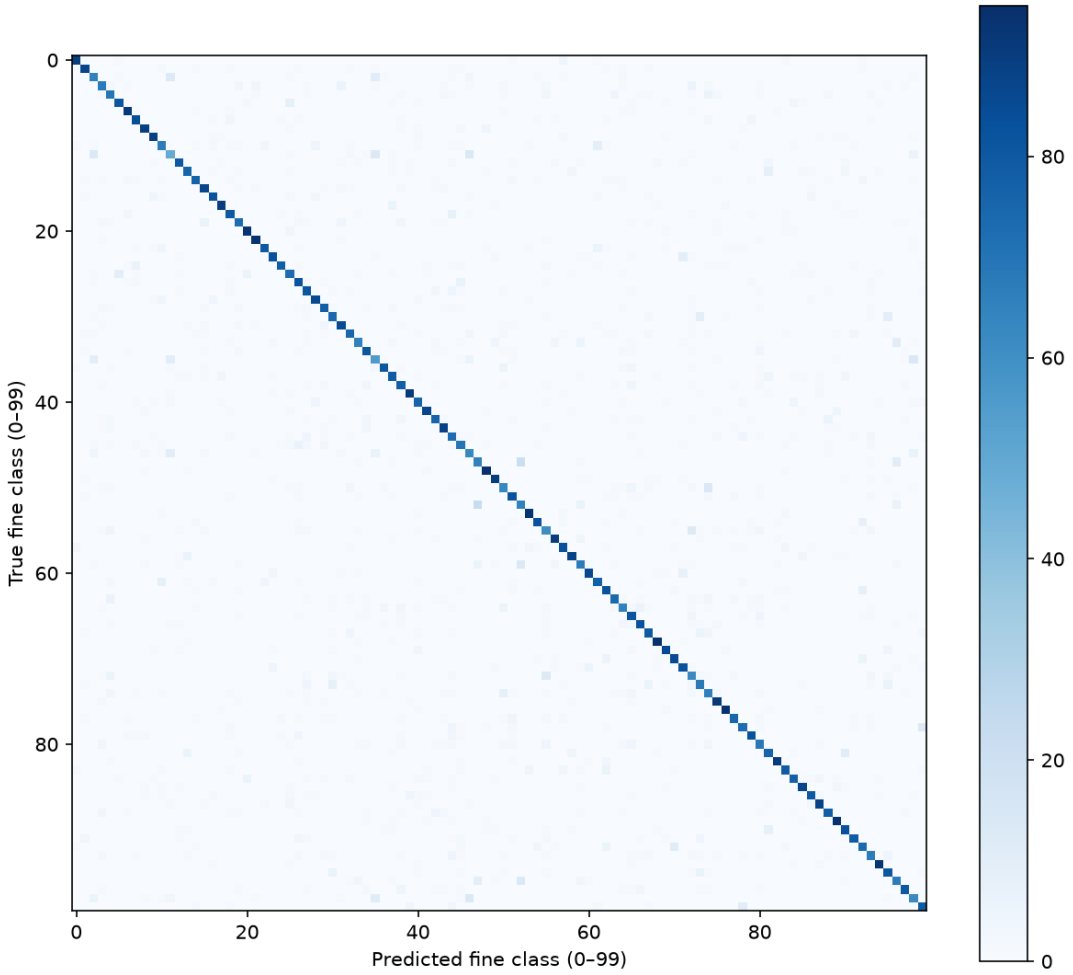
Hình 4.2: Swin-T scratch: train/val CE và accuracy ở seed 42.



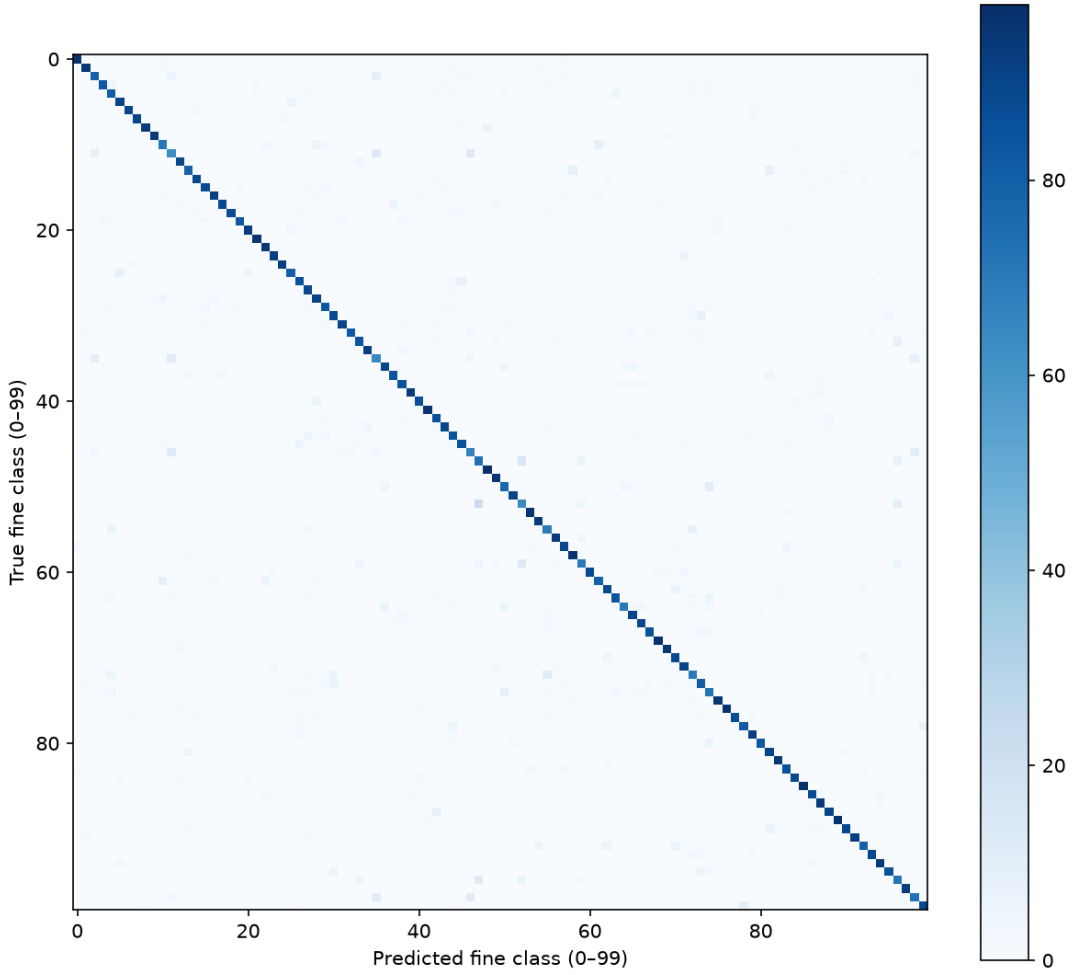
Hình 4.3: ResNet18 pretrained full: đường cong ở seed 42.



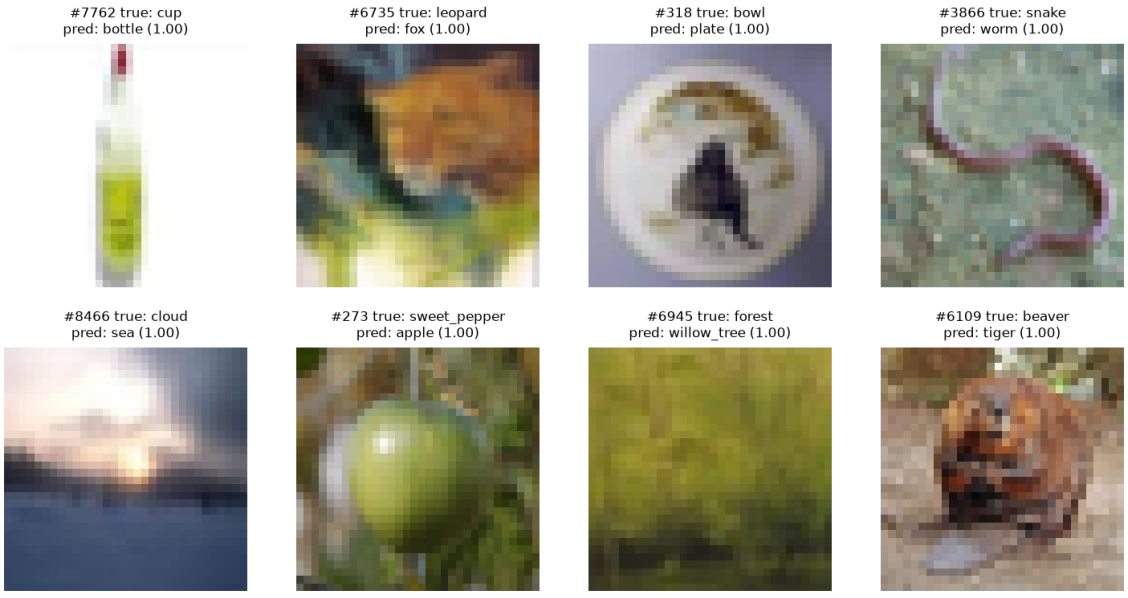
Hình 4.4: Swin-T pretrained full: đường cong ở seed 42.



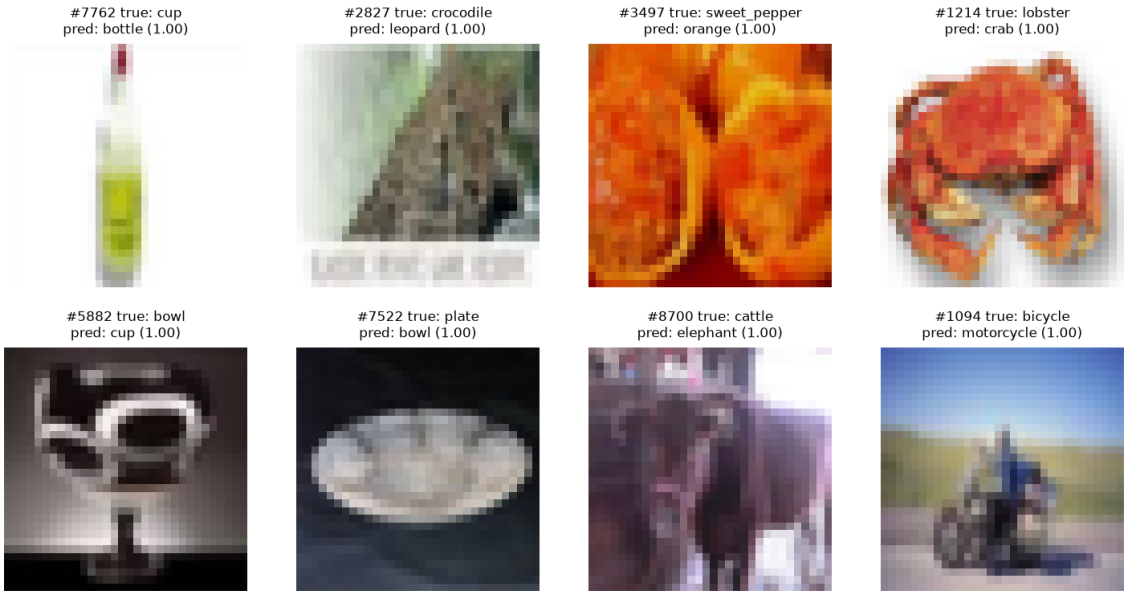
Hình 4.5: Confusion matrix test của ResNet18 full ở seed 42; hàng là nhãn thực tế.



Hình 4.6: Confusion matrix test của Swin-T full ở seed 42.



Hình 4.7: Các dự đoán sai có confidence cao của ResNet18 full ở seed 42, hiển thị ảnh gốc 32×32.



Hình 4.8: Các dự đoán sai có confidence cao của Swin-T full ở seed 42.

Chương 5

Kết luận và giới hạn

5.1 Kết luận

Tinh chỉnh nhiều tầng hơn cải thiện kết quả của cả ResNet18 và Swin-T trên CIFAR-100. Tinh chỉnh khối cuối đem lại phần lớn mức tăng so với chỉ học đầu ra ở ResNet18. Với Swin-T, việc cập nhật toàn bộ tiếp tục nâng độ chính xác từ 78,25% lên 86,63% và cần thêm thời gian, bộ nhớ. Kết luận áp dụng cho cách chia dữ liệu và ngân sách 20 epoch đã đo.

5.2 Giới hạn

Ảnh gốc 32×32 và đầu vào 96×96 khác với kích thước phổ biến 224×224 của pretrained. Thực nghiệm chỉ khảo sát CIFAR-100, hai kiến trúc và ngân sách 20 epoch; đặc biệt, scratch có thể tiếp tục cải thiện nếu được huấn luyện lâu hơn. Hai họ còn khác capacity và recipe ImageNet. Ba seed mô tả biến thiên giữa các lượt khởi tạo, với cùng phần cứng và thiết lập workers. Tình trạng license của dữ liệu vẫn là chưa rõ.

Thông tin sử dụng AI được trình bày trong AI_USE_REPORT.md.

Tài liệu tham khảo

[1] Lê Thành Sách. *Course Assignment: Nền tảng lập trình cho phân tích và trực quan dữ liệu*. CO5177, v4.0, 14/09/2026.

[2] A. Krizhevsky. *Learning Multiple Layers of Features from Tiny Images*. 2009. Trang dataset: `https://www.cs.toronto.edu/~kriz/cifar.html`.

[3] uoft-cs. *CIFAR100 dataset card*; license: unknown. `https://huggingface.co/datasets/uoft-cs/cifar100`.

[4] K. He và cộng sự. *Deep Residual Learning for Image Recognition*. CVPR2016. `https://arxiv.org/abs/1512.03385`.

[5] Z. Liu và cộng sự. *Swin Transformer: Hierarchical Vision Transformer using Shifted Windows*. ICCV2021. `https://arxiv.org/abs/2103.14030`.

[6] Torchvision. ResNet18 và Swin-T model API; sử dụng weight enum IMAGENET1K_V1. `https://docs.pytorch.org/vision/stable/models.html`.