ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



BÁO CÁO IMAGE

CO5177 · Nền tảng lập trình cho phân tích và trực quan dữ liệu

Học kỳ 261 · Năm học 2026–2027

Phân loại CIFAR-100 bằng ResNet18 và Swin-T

Nhóm CTG

Huỳnh Thành Đạt	2570161
Lương Minh Duy	2570083
Giảng viên	Lê Thành Sách

Thành phố Hồ Chí Minh, tháng 11 năm 2026

Tóm tắt

Thực nghiệm so sánh ba mức tinh chỉnh của ResNet18 và Swin-T pretrained ImageNet trên CIFAR-100. Trước khi huấn luyện, các ảnh trùng pixel chính xác được loại giữa các tập theo một chính sách ưu tiên cố định, tạo tập train/validation/test gồm 44.976/5.000/9.998 ảnh. Sáu cấu hình pretrained được huấn luyện 20 epoch với ba seed. Swin-T tinh chỉnh toàn bộ đạt accuracy test $86{,}81 \pm 0{,}02\%$, cao hơn ResNet18 cùng chế độ $7{,}66 \pm 0{,}41$ điểm phần trăm khi so sánh theo cặp seed. Thời gian train trung bình của Swin-T full gấp 2,41 lần và bộ nhớ cấp phát cực đại gấp 4,72 lần ResNet18 full.

Tổng quan báo cáo

Dữ liệu	CIFAR-100, 100 lớp; ảnh gốc 32×32, đầu vào 96×96.
Split	44.976 train, 5.000 validation, 9.998 test sau khi loại ảnh trùng chính xác.
Mô hình	ResNet18 và Swin-T pretrained ImageNet; head-only, partial và full fine-tuning.
Kết quả chính	Swin-T full đạt $86{,}81 \pm 0{,}02\%$ accuracy và macro-F1 $0{,}8681 \pm 0{,}0001$.
Đánh đổi	Accuracy cao hơn đi kèm 2,41 lần thời gian và 4,72 lần bộ nhớ so với ResNet18 full.

Mục lục

Tóm tắt **i**

Tổng quan báo cáo **ii**

1 Bài toán và dữ liệu **1**

1.1 Mục tiêu 1

1.2 Dữ liệu và kích thước ảnh 1

1.3 Tiền xử lý và nguồn phép đo 1

2 Mô hình và thiết lập thực nghiệm **3**

2.1 Các mức tinh chỉnh 3

2.2 Huấn luyện và đánh giá 3

3 Kết quả và thảo luận **4**

3.1 Kết quả trên tập test 4

3.2 Chi phí và so sánh ghép cặp 4

3.3 Phân tích nhầm lẫn 7

3.4 Kiểm tra giao thức và nguồn gốc 7

3.5 Kết luận 8

3.6 Giới hạn 8

Tài liệu tham khảo **9**

Danh sách hình vẽ

1.1 Số ảnh theo fine class sau khi loại nội dung trùng chính xác. Các lớp vẫn có quy mô gần tương đương; việc loại bỏ được xác định theo hash ảnh, không theo kết quả mô hình. 2

1.2 Mẫu ảnh CIFAR-100 trong tập train sau khử trùng lặp. Ảnh nguồn 32×32 có một số lớp khó phân biệt khi chỉ quan sát hình dạng và kết cấu tổng thể. 2

3.1 Accuracy và cross-entropy trên train/validation của ba cấu hình ResNet18 qua 20 epoch; đường cong tổng hợp từ các seed 42, 43 và 44. 5

3.2 Accuracy và cross-entropy trên train/validation của ba cấu hình Swin-T qua 20 epoch; đường cong tổng hợp từ các seed 42, 43 và 44. 6

3.3 Confusion matrix test trung bình qua các seed 42, 43 và 44: ResNet18 full (trái), Swin-T full (phải). Số ảnh trung bình ở mỗi ô được làm tròn để hiển thị. 7

Danh sách bảng

2.1 Các chế độ so sánh chính. Cả hai kiến trúc dùng cùng split, preprocessing và seed. 3

3.1 Accuracy và macro-F1 trên test, trung bình ± SD mẫu qua seed 42, 43 và 44. 4

3.2 Trung bình ± SD mẫu qua ba seed; đo trên cùng RTX 5090 và bốn workers. Peak memory gần như cố định theo cấu hình nên SD hiển thị làm tròn về 0,0 MiB. 4

Chương 1

Bài toán và dữ liệu

1.1 Mục tiêu

Thực nghiệm khảo sát ảnh hưởng của mức độ cập nhật backbone khi phân loại CIFAR-100. Hai kiến trúc gồm ResNet18 và Swin-T với trọng số ImageNet-1K phiên bản V1. Mỗi kiến trúc được đánh giá ở ba chế độ pretrained: chỉ học lớp phân loại (head-only), tinh chỉnh một phần backbone (partial) và tinh chỉnh toàn bộ (full). Tất cả sáu cấu hình được chạy với seed 42, 43 và 44.

Mục tiêu là so sánh chất lượng dự đoán và chi phí thực thi trong cùng ngân sách 20 epoch. Đây là so sánh giữa hai cấu hình kiến trúc và pretrained cụ thể, không nhằm khái quát ưu thế của CNN hay Transformer nói chung.

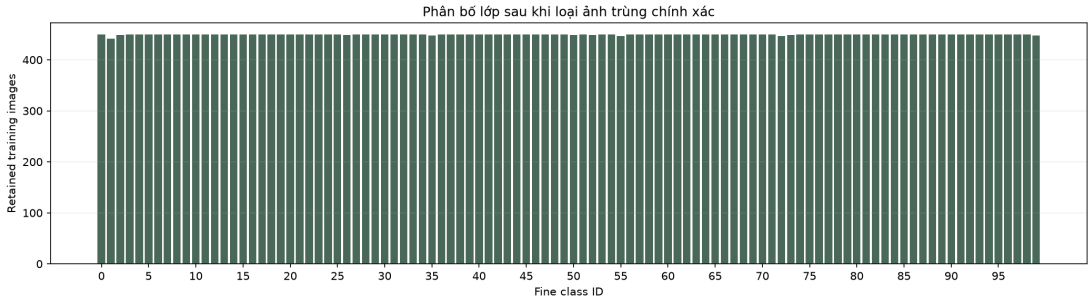
1.2 Dữ liệu và kích thước ảnh

CIFAR-100 gồm 60.000 ảnh màu thuộc 100 lớp chi tiết: 50.000 ảnh train chính thức và 10.000 ảnh test chính thức [2]. Ảnh gốc có kích thước 32×32. Đề bài khuyến nghị cạnh ngắn ít nhất 128 px [1]; vì ảnh nguồn nhỏ hơn mức này, đầu vào được bilinear resize lên 96×96 để giữ giao thức đã chọn cho hai kiến trúc. Nội suy điều chỉnh lưới đầu vào nhưng không bổ sung chi tiết ngoài ảnh gốc.

Từ 50.000 ảnh train, phép chia phân tầng với seed 2026 ban đầu tạo 45.000 ảnh train và 5.000 ảnh validation. Trước khi huấn luyện, SHA256 trên RGB bytes được dùng để nhóm các ảnh trùng pixel chính xác trong cả ba partition. Mỗi nhóm giữ một ảnh theo thứ tự ưu tiên test, validation, rồi train. Chính sách này loại 24 ảnh khỏi train và 2 khỏi test; validation không đổi. Tập cuối gồm 44.976/5.000/9.998 ảnh. Đối chiếu sau lọc xác nhận không còn nội dung RGB trùng chính xác giữa các tập. Phép kiểm tra không phát hiện ảnh gần trùng nên không loại trừ hoàn toàn khả năng tương đồng thị giác cao.

1.3 Tiền xử lý và nguồn phép đo

Train được random crop 32×32 với padding 4, lật ngang xác suất 0,5 rồi resize bilinear lên 96×96. Validation và test chỉ resize cố định. Các ảnh được chuẩn hóa theo mean và độ lệch chuẩn ImageNet. Augmentation chỉ áp dụng cho train; validation dùng chọn



Hình 1.1: Số ảnh theo fine class sau khi loại nội dung trùng chính xác. Các lớp vẫn có quy mô gần tương đương; việc loại bỏ được xác định theo hash ảnh, không theo kết quả mô hình.



Hình 1.2: Mẫu ảnh CIFAR-100 trong tập train sau khử trùng lặp. Ảnh nguồn 32×32 có một số lớp khó phân biệt khi chỉ quan sát hình dạng và kết cấu tổng thể.

checkpoint và test chỉ được đánh giá sau khi giao thức đã cố định.

Mã nguồn và giao thức huấn luyện ban đầu được chuyển từ A1 CO5085 tại commit đo gốc. Các kết quả trong báo cáo này đến từ 18 lượt huấn luyện mới của CO5177 sau khi áp dụng chính sách loại ảnh trùng; chúng không phải phép đo CO5085 và không trộn với 24 lượt được lưu từ nghiên cứu trước. Archive chỉ được dẫn làm tham chiếu nguồn mã và giao thức.

Chương 2

Mô hình và thiết lập thực nghiệm

2.1 Các mức tinh chỉnh

ResNet18 sử dụng backbone torchvision pretrained [3, 5]. Head-only chỉ cập nhật lớp Linear 100 chiều; partial cập nhật layer4 và head; full cập nhật toàn bộ mô hình. Swin-T cũng dùng pretrained ImageNet [4, 5]: head-only chỉ cập nhật head, partial cập nhật stage cuối, normalization cuối và head, còn full cập nhật toàn bộ backbone.

Chế độ	Khởi tạo	Tham số được cập nhật
Head-only	ImageNet pretrained	Lớp phân loại 100 chiều
Partial	ImageNet pretrained	Khối cuối và lớp phân loại; Swin-T thêm normalization cuối
Full	ImageNet pretrained	Toàn bộ mô hình

Bảng 2.1: Các chế độ so sánh chính. Cả hai kiến trúc dùng cùng split, preprocessing và seed.

2.2 Huấn luyện và đánh giá

Mỗi lượt chạy 20 epoch, batch size 128, AdamW với weight decay 10^{-4} và cosine learning-rate schedule. Learning rate ban đầu là 10^{-3} cho head-only và 10^{-4} cho partial/full. Loss là cross-entropy không label smoothing; gradient norm được clip ở 1. Autocast BF16 dùng trên GPU hỗ trợ BF16 native; tham số và trạng thái optimizer ở FP32, TF32 tắt. Checkpoint được chọn theo validation accuracy cao nhất; khi hòa chọn validation cross-entropy thấp hơn.

Kết quả được đo trên RTX 5090 với bốn data-loading workers, PyTorch 2.10.0, torchvision 0.25.0, CUDA 13.0, NumPy 2.4.1, Matplotlib 3.11.2 và Pillow 12.0.0. Thời gian train gồm data loading, augmentation và train pass, có đồng bộ CUDA; không gồm validation, khởi tạo mô hình, ghi checkpoint hoặc xuất báo cáo. Peak memory là bộ nhớ GPU cấp phát cực đại trong train và validation của mỗi lượt. Accuracy và macro-F1 được tính trên toàn bộ lớp; các giá trị tổng hợp là trung bình và độ lệch chuẩn mẫu qua ba seed.

Chương 3

Kết quả và thảo luận

3.1 Kết quả trên tập test

Bảng 3.1 tổng hợp accuracy và macro-F1 trên 9.998 ảnh test độc lập theo chính sách loại trùng chính xác. Ở cả hai kiến trúc, chế độ partial vượt head-only; full tiếp tục cải thiện kết quả. ResNet18 full đạt $79{,}16 \pm 0{,}39\%$, còn Swin-T full đạt $86{,}81 \pm 0{,}02\%$.

Cấu hình	Accuracy test (%)	Macro-F1
ResNet18 head-only	$60{,}91 \pm 0{,}14$	$0{,}6077 \pm 0{,}0012$
ResNet18 partial	$73{,}84 \pm 0{,}23$	$0{,}7382 \pm 0{,}0018$
ResNet18 full	$79{,}16 \pm 0{,}39$	$0{,}7915 \pm 0{,}0038$
Swin-T head-only	$71{,}69 \pm 0{,}07$	$0{,}7156 \pm 0{,}0008$
Swin-T partial	$78{,}44 \pm 0{,}16$	$0{,}7837 \pm 0{,}0015$
Swin-T full	$86{,}81 \pm 0{,}02$	$0{,}8681 \pm 0{,}0001$

Bảng 3.1: Accuracy và macro-F1 trên test, trung bình ± SD mẫu qua seed 42, 43 và 44.

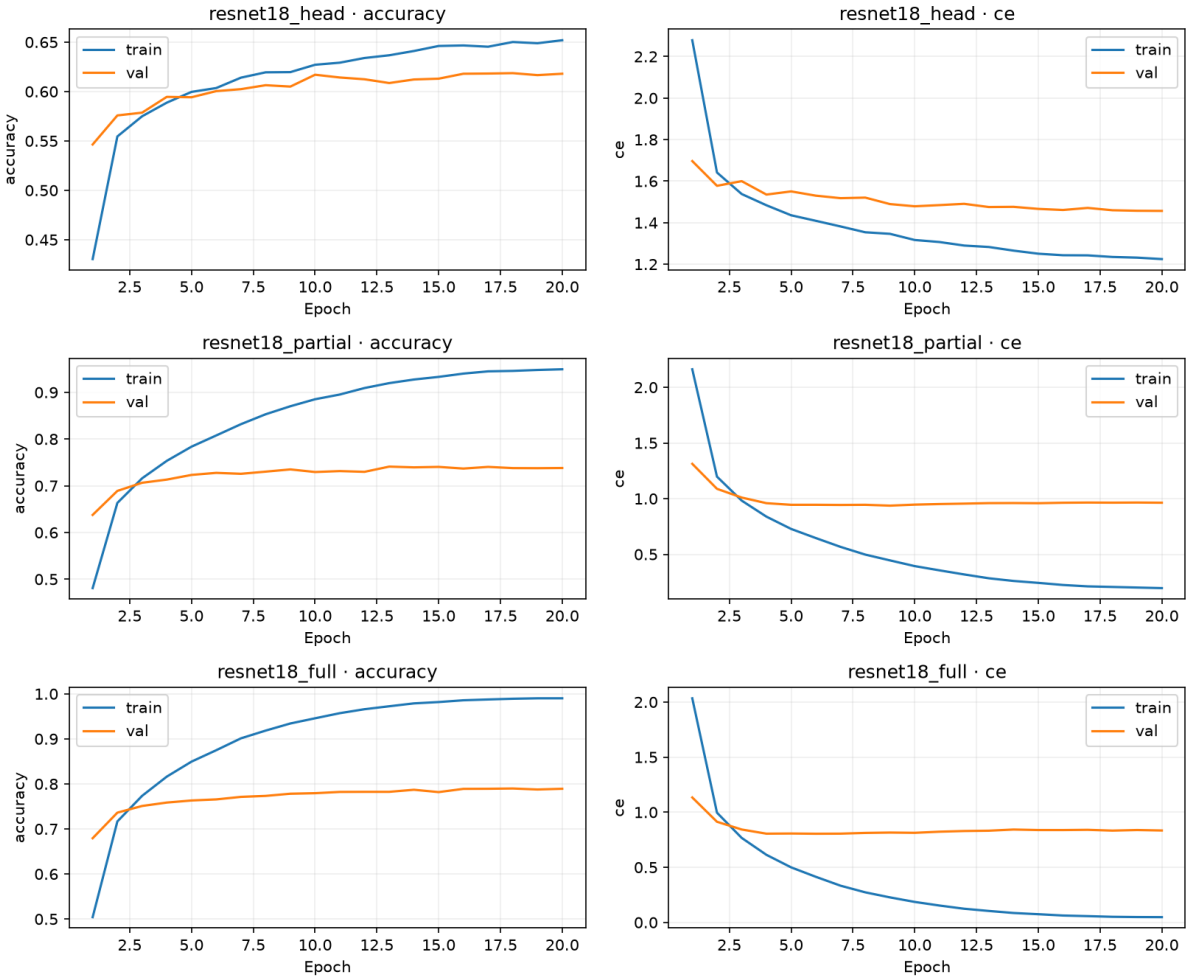
3.2 Chi phí và so sánh ghép cặp

Swin-T full cao hơn ResNet18 full $7{,}66 \pm 0{,}41$ điểm phần trăm theo chênh lệch ghép cặp cùng seed; độ lệch chuẩn được tính trên ba chênh lệch seed-wise. Macro-F1 của hai cấu hình lần lượt là $0{,}8681 \pm 0{,}0001$ và $0{,}7915 \pm 0{,}0038$.

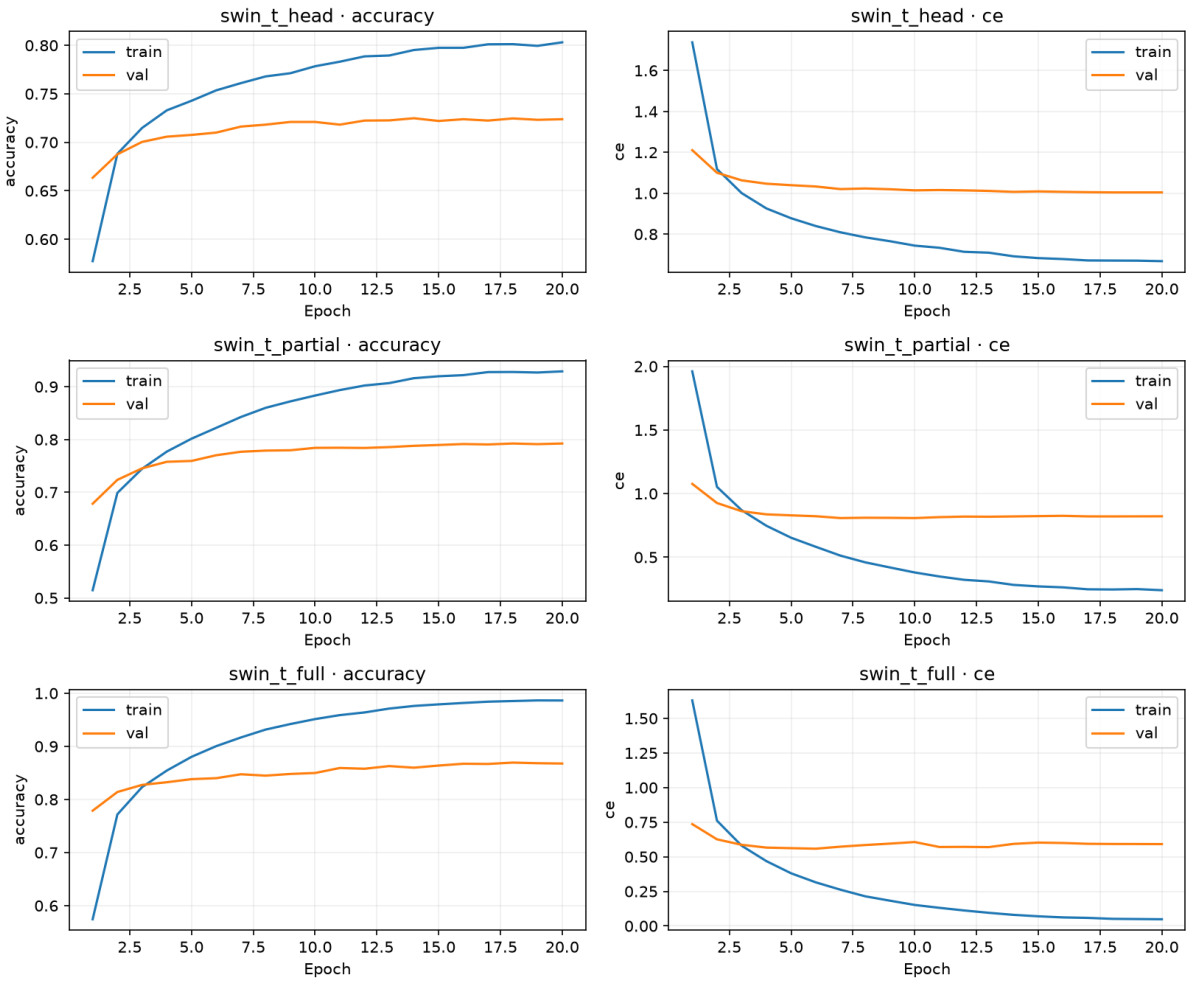
Cấu hình	Thời gian train (s)	Peak allocated memory (MiB)
ResNet18 head-only	$88{,}3 \pm 0{,}3$	$252{,}1 \pm 0{,}0$
ResNet18 partial	$87{,}9 \pm 0{,}3$	$347{,}4 \pm 0{,}0$
ResNet18 full	$88{,}1 \pm 0{,}7$	$520{,}4 \pm 0{,}0$
Swin-T head-only	$88{,}4 \pm 0{,}4$	$501{,}9 \pm 0{,}0$
Swin-T partial	$109{,}1 \pm 0{,}3$	$662{,}9 \pm 0{,}0$
Swin-T full	$212{,}5 \pm 1{,}6$	$2454{,}2 \pm 0{,}0$

Bảng 3.2: Trung bình ± SD mẫu qua ba seed; đo trên cùng RTX 5090 và bốn workers. Peak memory gần như cố định theo cấu hình nên SD hiển thị làm tròn về 0,0 MiB.

Trong chế độ full, Swin-T mất thời gian gấp 2,41 lần và dùng peak memory gấp 4,72 lần ResNet18. Chỉ học head giảm chi phí so với full ở từng backbone; tuy vậy Swin-T head



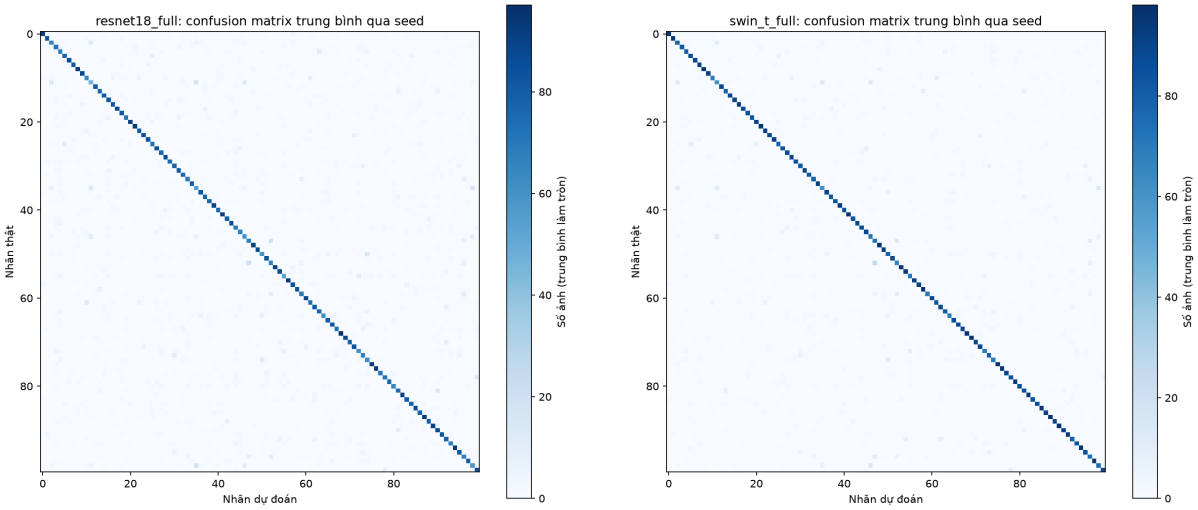
Hình 3.1: Accuracy và cross-entropy trên train/validation của ba cấu hình ResNet18 qua 20 epoch; đường cong tổng hợp từ các seed 42, 43 và 44.



Hình 3.2: Accuracy và cross-entropy trên train/validation của ba cấu hình Swin-T qua 20 epoch; đường cong tổng hợp từ các seed 42, 43 và 44.

vẫn cấp phát bộ nhớ gần bằng ResNet18 full do khác biệt kiến trúc và kích thước mô hình. Đây là tương quan chi phí trong runtime và giao thức đã đo, không phải so sánh hiệu năng trên nhiều loại phần cứng.

3.3 Phân tích nhầm lẫn



Hình 3.3: Confusion matrix test trung bình qua các seed 42, 43 và 44: ResNet18 full (trái), Swin-T full (phải). Số ảnh trung bình ở mỗi ô được làm tròn để hiển thị.

Ở cả hai mô hình full, cặp nhầm lẫn oak_tree và maple_tree xuất hiện nhiều lần qua các seed. Đây là quan sát nhất quán từ các ô ngoài đường chéo lớn nhất, gợi ý các hình ảnh cây có thể khó tách bằng đặc trưng ở độ phân giải này. Confusion matrix không đo trực tiếp độ tương đồng thị giác và không đủ để quy nguyên nhân cho kiến trúc.

3.4 Kiểm tra giao thức và nguồn gốc

Ba cấu hình seed hoàn tất cho mỗi kiến trúc. Tập train giữ 44.976/45.000 ảnh ban đầu sau khi loại 24 bản trùng với validation hoặc test; validation giữ đủ 5.000 ảnh; test giữ 9.998/10.000 ảnh sau khi gộp hai nội dung trùng. Sau bước này không có nội dung RGB trùng chính xác giữa các split. Near-duplicates chưa được đánh giá.

Hash notebook và digest code cell được lưu đầy đủ trong metadata; tiền tố lần lượt là `5f9ce3335d9c` và `d74c090d011c`. Metadata theo seed, cấu hình, split, history, metrics test và log nằm trong `notebook-evidence/`. Dữ liệu được tải từ máy chủ Toronto; hash pixel theo thứ tự được lưu trong cấu hình seed để kiểm tra nguồn. Các số liệu lịch sử CO5085 không được dùng trong bảng hoặc hình của phần kết quả mới.

3.5 Kết luận

Trong sáu cấu hình pretrained được đo, fine-tuning sâu hơn cải thiện accuracy ở cả ResNet18 và Swin-T. Swin-T full đạt accuracy và macro-F1 cao nhất, đồng thời tốn thêm thời gian và bộ nhớ so với ResNet18 full. Hai mô hình thường nhầm oak_tree với maple_tree, dù đây chỉ là quan sát từ confusion matrix chứ không phải phép đo riêng về độ tương đồng thị giác. Kết luận áp dụng cho CIFAR-100, đầu vào 96 px, giao thức 20 epoch và phần cứng được mô tả ở trên.

3.6 Giới hạn

Ảnh gốc 32×32 thấp hơn mức 128 px được khuyến nghị; resize lên 96 px không khôi phục chi tiết đã mất. Phân tích ảnh trùng chỉ phát hiện trùng pixel chính xác, chưa xét ảnh gần trùng; license của dataset không được ghi rõ. Thực nghiệm giới hạn ở một tập dữ liệu, hai kiến trúc, ba mức tinh chỉnh, ba seed và một GPU; không khảo sát scratch như đối chứng trong lượt mới hoặc thời lượng dài hơn.

Thông tin sử dụng AI được trình bày trong AI_USE_REPORT.md.

Tài liệu tham khảo

[1] Lê Thành Sách. *Course Assignment: Nền tảng lập trình cho phân tích và trực quan dữ liệu*. CO5177, v4.0, 14/09/2026.

[2] A. Krizhevsky. *Learning Multiple Layers of Features from Tiny Images*. 2009. `https://www.cs.toronto.edu/~kriz/cifar.html`.

[3] K. He và cộng sự. *Deep Residual Learning for Image Recognition*. CVPR 2016. `https://arxiv.org/abs/1512.03385`.

[4] Z. Liu và cộng sự. *Swin Transformer: Hierarchical Vision Transformer using Shifted Windows*. ICCV 2021. `https://arxiv.org/abs/2103.14030`.

[5] Torchvision. ResNet18 và Swin-T model API; trọng số IMAGENET1K_V1. `https://docs.pytorch.org/vision/stable/models.html`.