ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



BÁO CÁO TỔNG HỢP BÀI TẬP LỚN

CO5177 · Nền tảng lập trình cho phân tích và trực quan dữ liệu

Học kỳ 261 · Năm học 2026–2027

Phân loại thu nhập, tin tức tiếng Việt và ảnh

Nhóm CTG

Huỳnh Thành Đạt	2570161 · 50%
Lương Minh Duy	2570083 · 50%
Giảng viên	Lê Thành Sách

Thành phố Hồ Chí Minh, tháng 11 năm 2026

Tóm tắt

Báo cáo tổng hợp ba nghiên cứu phân loại của nhóm CTG. Trên UCI Adult, histogram gradient boosting đạt 87,48% độ chính xác và 0,8185 macro-F1. Trên VietnamNet, PhoBERT fine-tuning với nội dung bài viết đạt 91,78% trên tập test riêng, so với 80,90% của Frozen PhoBERT + Logistic regression. Trên CIFAR-100, Swin-T full fine-tuning đạt 86,59% accuracy, so với 78,98% của ResNet18 cùng chế độ.

Trong thí nghiệm Text, hai cách tiếp cận dùng chung danh sách bài và cách chia tập. Checkpoint và tham số hiệu chỉnh được chọn trên tập validation. Thí nghiệm Image huấn luyện lại sau khi loại ảnh trùng pixel giữa các tập.

Tổng quan báo cáo

Tabular	UCI Adult. So sánh mô hình phân loại thu nhập và đo đánh đổi precision–recall khi cân bằng lớp.
Text	VietnamNet. So sánh PhoBERT fine-tuning với nội dung bài viết và các baseline chỉ dùng tiêu đề trên cùng tập test.
Image	CIFAR-100. So sánh các chế độ fine-tuning ResNet18 và Swin-T về độ chính xác, thời gian và bộ nhớ.
Tài liệu chi tiết	Notebook và báo cáo riêng trình bày dữ liệu, phương pháp, thiết lập và kết quả của từng bài.

Mục lục

Tóm tắt **i**

Tổng quan báo cáo **ii**

1 Kết quả theo loại dữ liệu **1**

1.1 Tabular — Phân loại thu nhập trên UCI Adult 1

1.2 Text — Phân loại chuyên mục VietnamNet 2

1.3 Image — Fine-tuning ResNet18 và Swin-T trên CIFAR-100 3

1.4 Tài liệu của từng bài 4

Danh sách bảng

1.1 Accuracy và macro-F1 của bốn mô hình trên 7.317 bản ghi test của Adult, với model seed 42. 1

1.2 Accuracy và macro-F1 của các mô hình trên 31.106 bài báo test của VietnamNet, với model seed 42. 2

1.3 Accuracy test (%) trên 9.998 ảnh CIFAR-100, trung bình qua seed 42, 43 và 44 sau 20 epoch. Cột full kèm SD mẫu. Full cho accuracy cao nhất ở cả hai kiến trúc. 3

Chương 1

Kết quả theo loại dữ liệu

1.1 Tabular — Phân loại thu nhập trên UCI Adult

UCI Adult lấy từ UCI Machine Learning Repository, gồm 48.842 bản ghi và 14 thuộc tính. Hai tệp dữ liệu gốc có cùng 14 thuộc tính và một nhãn thu nhập. Ba cột có giá trị thiếu là nghề nghiệp, loại hình việc làm và quốc gia xuất xứ. Sau khi loại nhóm trùng có nhãn mâu thuẫn và gộp các bản ghi lặp còn lại, 48.780 bản ghi được chia phân tầng theo tỷ lệ 70/15/15. Tham số điền thiếu, chuẩn hóa và ánh xạ mã hóa được ước lượng trên tập train.

Thí nghiệm so sánh dự đoán lớp đa số, logistic regression thường, logistic regression cân bằng lớp và histogram gradient boosting. Các mô hình logistic dùng mã hóa one-hot và chuẩn hóa thuộc tính số. Gradient boosting phân nhánh trên các thuộc tính số và thuộc tính phân loại đã mã hóa.

Tham số C điều khiển mức regularization của logistic regression được chọn theo macro-F1 validation trong ba giá trị $C \in \{0{,}1; 1; 10\}$. Gradient boosting dùng 150 vòng, tối đa 31 lá mỗi cây và mức phạt L2 bằng 1. Các mô hình được đánh giá trên test sau khi cố định cấu hình.

Mô hình	Độ chính xác (%)	Macro-F1
Dự đoán lớp đa số	76,06	0,4320
Logistic regression	85,24	0,7815
Logistic regression cân bằng lớp	81,43	0,7769
Histogram gradient boosting	87,48	0,8185

Bảng 1.1: Accuracy và macro-F1 của bốn mô hình trên 7.317 bản ghi test của Adult, với model seed 42.

Gradient boosting tăng 2,24 điểm phần trăm độ chính xác so với logistic regression. Khi thêm trọng số cân bằng lớp, logistic regression nhận ra nhiều bản ghi thu nhập trên 50.000 USD hơn. Recall tăng từ 59,08% lên 84,59% và precision giảm từ 74,03% xuống 57,64%. Đây là sự đánh đổi giữa bỏ sót lớp ít mẫu và dự đoán nhầm vào lớp đó. Dữ liệu điều tra năm 1994 giới hạn khả năng áp dụng kết quả cho phân bố thu nhập hiện nay.

1.2 Text — Phân loại chuyên mục VietnamNet

Bộ VietnamNet News được công bố trên kho Hugging Face của học viên Huỳnh Thành Đạt. Các bài báo được thu thập bằng crawling từ các trang công khai của VietnamNet. Dữ liệu lưu trong 19 tệp Parquet; mỗi bản ghi có tiêu đề, nội dung, URL và nhãn chuyên mục. Từ 212.705 bản ghi nguồn, các bước kiểm tra loại 1.167 tiêu đề rỗng, 3.636 bản ghi thuộc nhóm trùng có nhãn mâu thuẫn và 527 bản ghi trùng còn lại. Toàn bộ 207.375 bài hợp lệ thuộc 19 chuyên mục được giữ để mô hình hóa, không lấy mẫu giới hạn theo lớp.

Những bài trở thành cùng một đầu vào sau xử lý được giữ trong cùng tập để tránh trùng giữa train và test. Tập train gồm 145.162 bài báo; tập validation và tập test lần lượt gồm 31.107 và 31.106 bài. Mọi mô hình sử dụng cách chia dữ liệu này. URL và tên chuyên mục không được đưa vào đầu vào mô hình.

Bốn baseline được sử dụng:

- **Majority baseline:** dự đoán chuyên mục phổ biến nhất trong tập train.
- **Word TF-IDF + Linear SVM:** kết hợp TF-IDF theo từ với SVM tuyến tính.
- **Character TF-IDF + Linear SVM:** kết hợp TF-IDF theo ký tự với SVM tuyến tính.
- **Frozen PhoBERT + Logistic regression:** trích đặc trưng bằng PhoBERT giữ nguyên trọng số, sau đó phân loại bằng logistic regression.

PhoBERT đọc tiêu đề cùng phần đầu và cuối bài, được tách từ bằng PyVi và giới hạn ở 256 token theo cách Head–Tail. PhoBERT sử dụng đầu phân loại 19 lớp và được fine-tuning cùng encoder trong bảy epoch bằng AdamW, learning rate 2×10^{-5} và batch hiệu dụng 64. Learning rate tăng trong 200 bước warmup rồi giảm tuyến tính; checkpoint epoch 6 được chọn theo macro-F1 validation. Temperature và hệ số từng lớp được ước lượng trên validation trước khi đánh giá test.

Mô hình	Độ chính xác (%)	Macro-F1
Majority baseline	6,00	0,0060
Word TF-IDF + Linear SVM	80,18	0,7836
Character TF-IDF + Linear SVM	80,27	0,7858
Frozen PhoBERT + Logistic regression	80,90	0,7931
PhoBERT fine-tuning (argmax)	91,79	0,9103
PhoBERT fine-tuning + calibration	91,78	0,9104

Bảng 1.2: Accuracy và macro-F1 của các mô hình trên 31.106 bài báo test của VietnamNet, với model seed 42.

PhoBERT fine-tuning cao hơn Frozen PhoBERT khoảng 10,88 điểm phần trăm accuracy. Hai cách tiếp cận khác nhau ở cả lượng văn bản đầu vào và việc cập nhật encoder, nên kết quả đánh giá toàn bộ phương pháp, chưa xác định riêng đóng góp của từng yếu tố.

Hiệu chỉnh làm xác suất phù hợp hơn trên validation, nhưng ít thay đổi khả năng phân loại trên test: macro-F1 tăng nhẹ còn accuracy giảm nhẹ. Có 130 bài được sửa đúng và 131 bài từ đúng chuyển thành sai, tương ứng giảm ròng một bài đúng.

1.3 Image — Fine-tuning ResNet18 và Swin-T trên CIFAR-100

CIFAR-100 lấy từ trang của Alex Krizhevsky, University of Toronto, gồm 60.000 ảnh RGB 32×32 thuộc 100 lớp. Dữ liệu được đọc từ các tệp pickle `train`, `test` và `meta`. Ảnh trùng pixel chính xác được loại trước khi train, ưu tiên giữ ảnh trong test rồi validation. Các tập còn 44.976 ảnh train, 5.000 validation và 9.998 test.

Đầu vào được resize lên 96×96 để giữ chi phí vừa phải; đề bài khuyến nghị cạnh ngắn 128 px. Padding, random crop và random horizontal flip chỉ áp dụng cho train. Cả hai backbone dùng trọng số ImageNet pretrained và thay head thành 100 đầu ra. Ba chế độ lần lượt học head, mở khối cuối và cập nhật toàn bộ mô hình.

Sáu cấu hình dùng AdamW, batch size 128 và 20 epoch. Learning rate ban đầu là 10^{-3} ở head-only, 10^{-4} ở partial/full rồi giảm theo cosine. Checkpoint có accuracy validation cao nhất được chọn trước khi đánh giá test; nếu hòa accuracy, ưu tiên cross-entropy thấp hơn.

Kiến trúc	Head-only	Partial	Full
ResNet18	61,08	74,18	$78{,}98 \pm 0{,}34$
Swin-T	71,64	78,28	$86{,}59 \pm 0{,}24$

Bảng 1.3: Accuracy test (%) trên 9.998 ảnh CIFAR-100, trung bình qua seed 42, 43 và 44 sau 20 epoch. Cột full kèm SD mẫu. Full cho accuracy cao nhất ở cả hai kiến trúc.

Mở thêm backbone giúp cải thiện accuracy ở cả hai mô hình. Khi ghép cặp cùng seed, Swin-T full cao hơn ResNet18 full $7{,}61 \pm 0{,}42$ điểm phần trăm; macro-F1 trung bình tương ứng là 0,8658 và 0,7897. Trên RTX 5090 với số worker bằng 0, Swin-T full train mất $334{,}0 \pm 0{,}6$ giây, so với $229{,}1 \pm 0{,}1$ giây của ResNet18 full. Mức accuracy cao hơn đi kèm 1,46 lần thời gian và 5,11 lần peak memory.

Phân tích ảnh sai bổ sung góc nhìn ngoài accuracy. Swin-T full ở seed 42 sai 1.324 trong 9.998 ảnh test; 390 lỗi có confidence ít nhất 95%. Các ví dụ streetcar thành bus và bicycle thành motorcycle cho thấy mô hình vẫn nhầm những lớp có hình dạng gần nhau. Confidence cao vì vậy chưa bảo đảm nhãn đúng.

1.4 Tài liệu của từng bài

- Tabular — UCI Adult.
- Text — VietnamNet.
- Image — CIFAR-100.

Phạm vi hỗ trợ của AI được trình bày trong AI_USE_REPORT.md.