ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



BÁO CÁO TABULAR

CO5177 · Nền tảng lập trình cho phân tích và trực quan dữ liệu

Học kỳ 261 · Năm học 2026–2027

Phân loại thu nhập trên UCI Adult

Nhóm CTG

Huỳnh Thành Đạt	2570161 · 50%
Lương Minh Duy	2570083 · 50%
Giảng viên	Lê Thành Sách

Thành phố Hồ Chí Minh, tháng 11 năm 2026

Tóm tắt

Thực nghiệm dự đoán thu nhập trên 50.000 USD mỗi năm từ 14 thuộc tính trong UCI Adult. Sau khi loại các bản ghi trùng và nhóm có nhãn mâu thuẫn, dữ liệu được chia thành ba tập. Bốn cấu hình so sánh gồm dự đoán lớp đa số, hồi quy logistic thường, hồi quy logistic cân bằng lớp và histogram gradient boosting.

Histogram gradient boosting đạt độ chính xác 87,48% và macro-F1 0,8185 trên 7.317 mẫu test. Trọng số cân bằng lớp làm tăng recall của hồi quy logistic đối với nhóm thu nhập cao, đồng thời tăng số dự đoán dương tính giả.

Tổng quan báo cáo

Dữ liệu	UCI Adult với 14 thuộc tính số và phân loại.
Tiền xử lý	Loại trùng trước khi chia tập, điền giá trị thiếu và mã hóa thuộc tính phân loại.
Đối chứng	Dự đoán lớp đa số, hồi quy logistic và histogram gradient boosting.
Kết quả chính	Histogram gradient boosting đạt độ chính xác 87,48% và macro-F1 0,8185 trên 7.317 mẫu test.

Mục lục

Tóm tắt **i**

Tổng quan báo cáo **ii**

1 Bài toán và dữ liệu **1**

1.1 Mục tiêu 1

1.2 Nguồn và cấu trúc 1

1.3 Chất lượng dữ liệu và chia tập 1

1.4 Phân bố thuộc tính số 1

2 Phương pháp và thiết lập **4**

2.1 Tiền xử lý 4

2.2 Các mô hình 4

2.3 Phép đo 4

3 Kết quả và phân tích **5**

3.1 So sánh mô hình 5

3.2 Nhận xét 5

4 Kết luận và giới hạn **7**

4.1 Kết luận 7

4.2 Giới hạn 7

4.3 Hướng mở rộng 7

Tài liệu tham khảo **8**

Danh sách hình vẽ

1.1 Số giá trị thiếu theo thuộc tính trong toàn bộ dữ liệu nguồn trước khi chia tập và imputation. 2

1.2 Số bản ghi theo nhãn thu nhập sau khi loại nhóm nhãn mâu thuẫn và bản ghi trùng. 2

1.3 Phân bố sáu thuộc tính số trên train. Capital gain và capital loss tập trung ở 0, còn số giờ làm việc tập trung quanh một tuần làm việc thông thường. Trục số bản ghi dùng thang log để thể hiện các khoảng có ít mẫu; thuộc tính giữ ở thang đo gốc. 3

3.1 Histogram gradient boosting đạt accuracy 87,48% và macro-F1 0,8185, cao nhất trong bốn mô hình trên cùng tập test. Cân bằng lớp làm accuracy của logistic regression giảm từ 85,24% xuống 81,43%; kết quả ứng với một split và một seed. 5

3.2 Ma trận nhầm lẫn trên test của mô hình có macro-F1 validation cao nhất; hàng là nhãn thực, cột là nhãn dự đoán. 6

Danh sách bảng

3.1 Siêu tham số C được chọn theo macro-F1 trên validation; các cột test là kết quả trên tập giữ riêng. Accuracy trình bày theo phần trăm, macro-F1 theo thang 0–1. 5

Chương 1

Bài toán và dữ liệu

1.1 Mục tiêu

Bài toán dự đoán nhãn thu nhập lớn hơn 50.000 USD/năm từ các thuộc tính trong UCI Adult. Phần phân tích tập trung vào dữ liệu thiếu, mã hóa thuộc tính phân loại, chuẩn hóa thuộc tính số và đánh đổi giữa accuracy với chất lượng dự đoán lớp ít mẫu. Bốn đối chứng gồm dự đoán lớp đa số, logistic regression, logistic regression cân bằng lớp và histogram gradient boosting.

1.2 Nguồn và cấu trúc

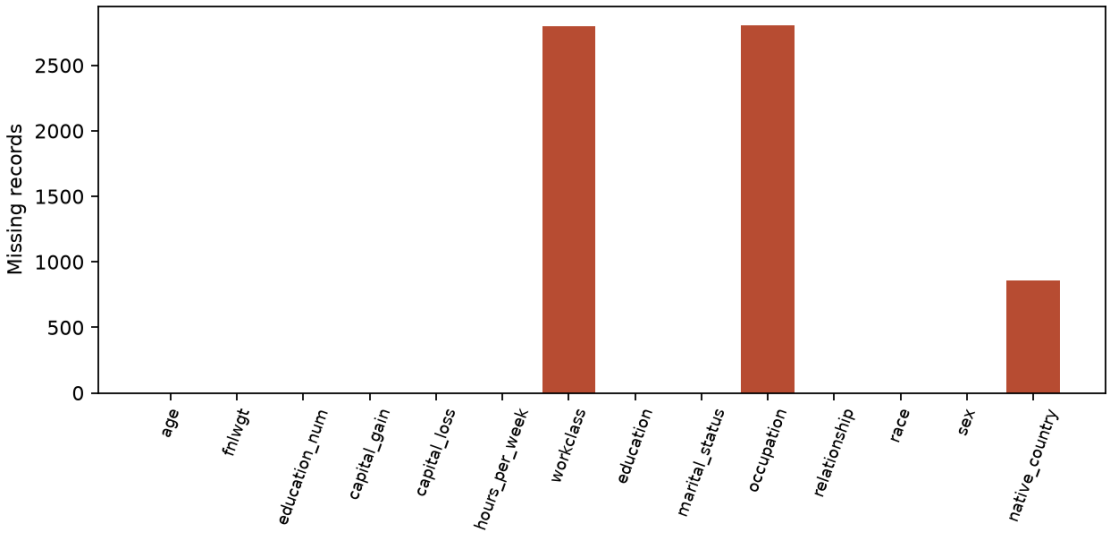
Adult gồm 48.842 bản ghi và 14 thuộc tính từ dữ liệu Census năm 1994, do Barry Becker và Ronny Kohavi cung cấp. Dữ liệu được UCI công bố theo giấy phép CC BY 4.0 [1]. Các thuộc tính số là tuổi, fnlwgt, số năm học, capital gain, capital loss và số giờ làm mỗi tuần. Tám thuộc tính còn lại là phân loại. Dấu hỏi được đọc thành giá trị thiếu. Không tạo thiếu nhân tạo.

1.3 Chất lượng dữ liệu và chia tập

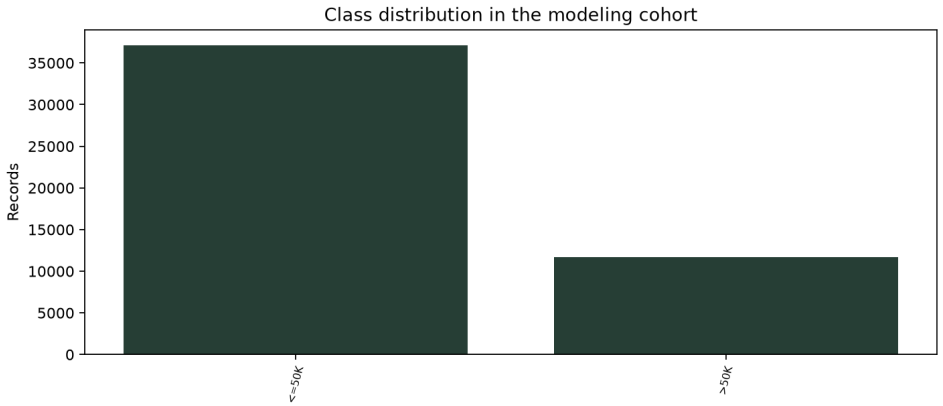
Hai tệp train/test gốc được gộp trước khi tạo một split mới. Nhóm có cùng 14 thuộc tính nhưng nhãn mâu thuẫn bị loại toàn bộ; nhóm trùng còn lại giữ một bản ghi. Quy tắc được áp dụng trước khi chia tập, nhằm tránh cùng một vector thuộc tính xuất hiện ở hai phía. Đây không phải phép đánh giá trên test gốc, nên điểm số không so trực tiếp với các benchmark dùng split đó. Hai bước làm sạch loại 10 dòng có nhãn mâu thuẫn và 52 dòng trùng. Thực nghiệm sử dụng toàn bộ 48.780 dòng còn lại. Các cột thiếu gồm workclass (2.799), occupation (2.809) và `native_country` (857).

1.4 Phân bố thuộc tính số

Khảo sát thuộc tính số chỉ sử dụng 34.146 mẫu train. Quy tắc $1{,}5\,IQR$ đánh dấu các giá trị nằm ngoài $[Q_1 - 1{,}5\,IQR;\ Q_3 + 1{,}5\,IQR]$. Cả capital gain và capital loss đều có $Q_1 = Q_3 = 0$, nên mọi giá trị dương đều bị đánh dấu, tương ứng 2.772 và 1.618 mẫu. Số

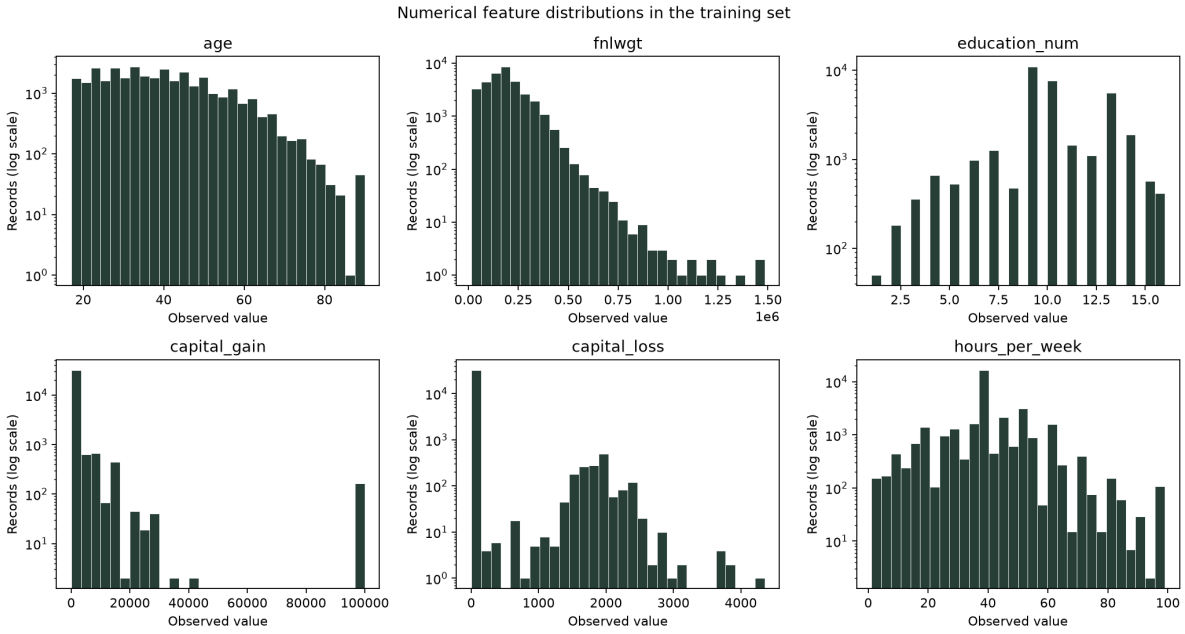


Hình 1.1: Số giá trị thiếu theo thuộc tính trong toàn bộ dữ liệu nguồn trước khi chia tập và imputation.



Hình 1.2: Số bản ghi theo nhãn thu nhập sau khi loại nhóm nhãn mâu thuẫn và bản ghi trùng.

giờ làm mỗi tuần có $Q_1 = 40$, $Q_3 = 45$; hai ngưỡng 32,5 và 52,5 giờ đánh dấu 9.461 mẫu. Các ngưỡng này mô tả độ tập trung và phần đuôi của phân phối, chưa đủ để xác định bản ghi sai. Vì vậy, thực nghiệm giữ nguyên các giá trị và không loại thêm mẫu theo IQR.



Hình 1.3: Phân bố sáu thuộc tính số trên train. Capital gain và capital loss tập trung ở 0, còn số giờ làm việc tập trung quanh một tuần làm việc thông thường. Trục số bản ghi dùng thang log để thể hiện các khoảng có ít mẫu; thuộc tính giữ ở thang đo gốc.

Chương 2

Phương pháp và thiết lập

2.1 Tiền xử lý

Split phân tầng theo nhãn với tỷ lệ 70/15/15 và seed 2026; phần 30% còn lại được chia validation/test bằng seed 2027. Median imputer cho cột số và most-frequent imputer cho cột phân loại chỉ fit trên train. Các phép biến đổi được ghép bằng Pipeline và ColumnTransformer [2, 3]. Logistic regression dùng StandardScaler và one-hot encoding, với các giá trị phân loại chưa gặp ở train được encoder bỏ qua khi biến đổi validation/test. Gradient boosting dùng ordinal encoding cho biến phân loại và khai báo đúng các vị trí categorical; mã -1 biểu diễn giá trị phân loại chưa gặp. Không chuẩn hóa các cột số cho cây.

2.2 Các mô hình

Baseline luôn dự đoán lớp phổ biến nhất. Logistic regression thường và bản có class weight balanced chọn $C \in \{0.1, 1, 10\}$ theo macro-F1 validation; khi hòa giữ ứng viên xuất hiện trước [4]. Giới hạn optimizer là 2.000 vòng. Histogram gradient boosting dùng 150 vòng, tối đa 31 lá, L2 bằng 1 và không early stopping [5]. Các cấu hình cố định trước khi mở test; không refit trên train cộng validation.

2.3 Phép đo

Accuracy, macro-F1, ma trận nhầm lẫn và precision/recall/F1 từng lớp được tính từ dự đoán trên test. Thực nghiệm sử dụng một split và model seed 42, chưa ước lượng độ biến thiên qua nhiều lượt chạy. Số mẫu train/validation/test là 34.146/7.317/7.317. ID và chữ ký nguồn được lưu cùng kết quả.

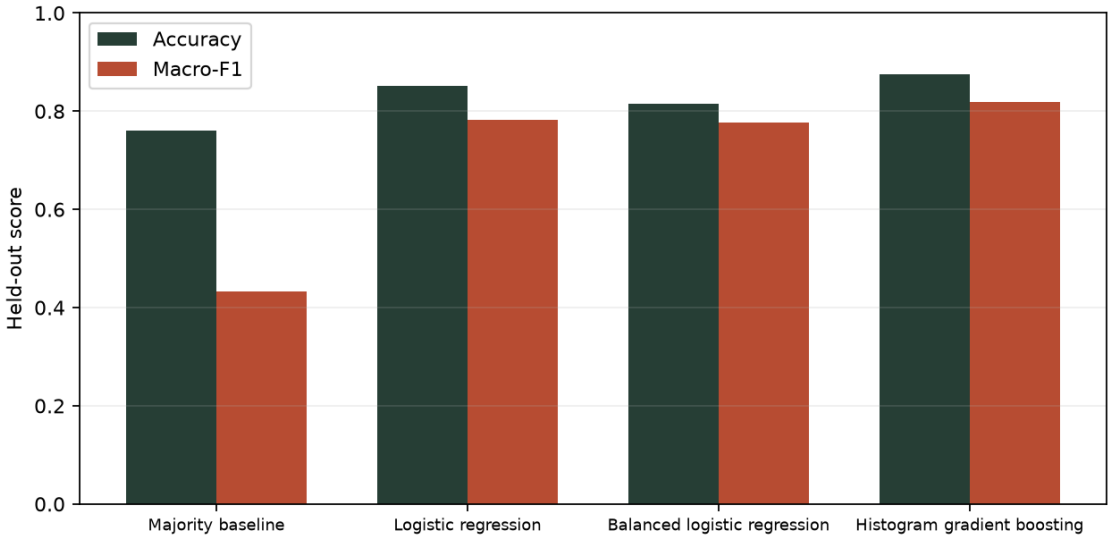
Chương 3

Kết quả và phân tích

3.1 So sánh mô hình

Mô hình	C	Val macro-F1	Test accuracy	Test macro-F1
Majority baseline	–	0.4320	76.06%	0.4320
Logistic regression	10.0	0.7803	85.24%	0.7815
Balanced logistic regression	10.0	0.7639	81.43%	0.7769
Histogram gradient boosting	–	0.8147	87.48%	0.8185

Bảng 3.1: Siêu tham số C được chọn theo macro-F1 trên validation; các cột test là kết quả trên tập giữ riêng. Accuracy trình bày theo phần trăm, macro-F1 theo thang 0–1.



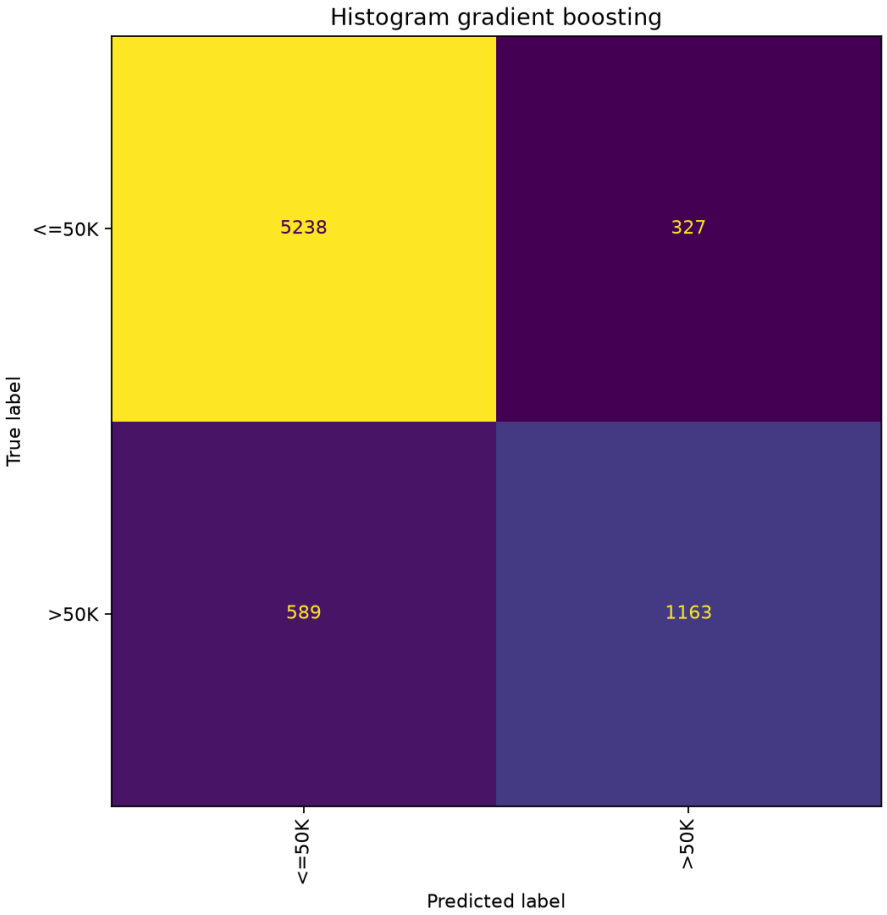
Hình 3.1: Histogram gradient boosting đạt accuracy 87,48% và macro-F1 0,8185, cao nhất trong bốn mô hình trên cùng tập test. Cân bằng lớp làm accuracy của logistic regression giảm từ 85,24% xuống 81,43%; kết quả ứng với một split và một seed.

3.2 Nhận xét

Histogram gradient boosting đạt accuracy 87,48% và macro-F1 0,8185, cao hơn logistic regression 2,24 điểm phần trăm accuracy và 0,0370 macro-F1. Trong split và các cấu hình

đã thử, boosting đạt kết quả cao hơn. Phép so sánh chưa tách riêng ảnh hưởng của dạng mô hình và cách mã hóa thuộc tính.

Thêm trọng số cân bằng lớp làm recall của nhóm thu nhập trên 50.000 USD tăng từ 0,5908 lên 0,8459, trong khi precision giảm từ 0,7403 xuống 0,5764. Số dự đoán dương tính giả tăng từ 363 với hồi quy logistic thông thường lên 1.089 với bản cân bằng lớp. Như vậy, mức giảm bỏ sót đi kèm với sự gia tăng dự đoán dương tính giả.



Hình 3.2: Ma trận nhầm lẫn trên test của mô hình có macro-F1 validation cao nhất; hàng là nhãn thực, cột là nhãn dự đoán.

Chương 4

Kết luận và giới hạn

4.1 Kết luận

Trên toàn bộ dữ liệu sau làm sạch và split đã cố định, histogram gradient boosting đạt kết quả cao nhất trong các cấu hình được khảo sát. Logistic regression cân bằng lớp tăng recall của nhóm thu nhập cao nhưng giảm precision và accuracy. Vì vậy, lựa chọn trọng số lớp cần gắn với mức chấp nhận bỏ sót và dự đoán dương tính giả của bài toán.

4.2 Giới hạn

Các kết quả phản ánh một cách chia dữ liệu và một seed. Nguồn điều tra năm 1994 giới hạn khả năng áp dụng cho thu nhập hiện nay. Dữ liệu không có mã hộ gia đình để chia tập theo hộ. Fnlwgt được dùng làm biến đầu vào, không làm trọng số mẫu. Chưa khảo sát riêng ảnh hưởng của từng chiến lược imputation, xử lý giá trị cực đoan hay hiệu quả trên từng nhóm nhân khẩu.

4.3 Hướng mở rộng

Hướng tiếp theo là so sánh các chiến lược imputation, chọn cấu hình bằng validation và đánh giá trên một tập test giữ riêng. Đây là đề xuất chưa được thực nghiệm.

Phạm vi hỗ trợ của AI được trình bày trong AI_USE_REPORT.md.

Tài liệu tham khảo

[1] B. Becker và R. Kohavi. *Adult*. UCI Machine Learning Repository, 1996. DOI: 10.24432/C5XW20. https://archive.ics.uci.edu/dataset/2/adult. License CC BY 4.0.

[2] Scikit-learn. *Pipeline*. https://scikit-learn.org/stable/modules/generated/sklearn.pipeline.Pipeline.html.

[3] Scikit-learn. *ColumnTransformer*. https://scikit-learn.org/stable/modules/generated/sklearn.compose.ColumnTransformer.html.

[4] Scikit-learn. *LogisticRegression*. https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression.html.

[5] Scikit-learn. *HistGradientBoostingClassifier*. https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.HistGradientBoostingClassifier.html.