ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



NỀN TẢNG LẬP TRÌNH CHO PHÂN TÍCH
VÀ TRỰC QUAN DỮ LIỆU
Mã môn học: CO5177

BÁO CÁO TABULAR

Phân tích và phân loại dữ liệu UCI Adult

Học kỳ 261 · Năm học 2026–2027

Nhóm: CTG
Giảng viên: Lê Thành Sách
Thành viên: Huỳnh Thành Đạt · 2570161
Lương Minh Duy · 2570083

Thành phố Hồ Chí Minh, tháng 10 năm 2026

Mục lục

1 Bài toán và dữ liệu **1**

1.1 Mục tiêu 1

1.2 Nguồn và cấu trúc 1

1.3 Chất lượng dữ liệu và chia tập 1

2 Phương pháp và thiết lập **3**

2.1 Tiền xử lý 3

2.2 Các mô hình 3

2.3 Phép đo 3

3 Kết quả và phân tích **4**

3.1 So sánh mô hình 4

3.2 Nhận xét 4

4 Kết luận và giới hạn **6**

4.1 Giới hạn 6

Tài liệu tham khảo **7**

Chương 1

Bài toán và dữ liệu

1.1 Mục tiêu

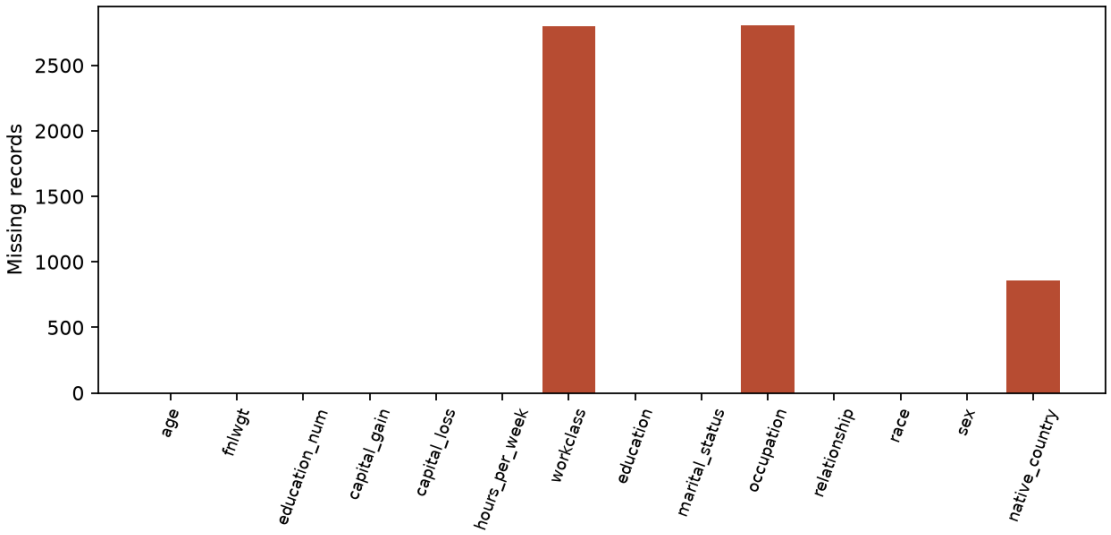
Bài toán dự đoán nhãn thu nhập lớn hơn 50.000 USD/năm từ các thuộc tính trong UCI Adult. Phần phân tích tập trung vào dữ liệu thiếu, mã hóa thuộc tính phân loại, chuẩn hóa thuộc tính số và đánh đổi giữa accuracy với chất lượng dự đoán lớp ít mẫu. Bốn đối chứng gồm dự đoán lớp đa số, logistic regression, logistic regression cân bằng lớp và histogram gradient boosting.

1.2 Nguồn và cấu trúc

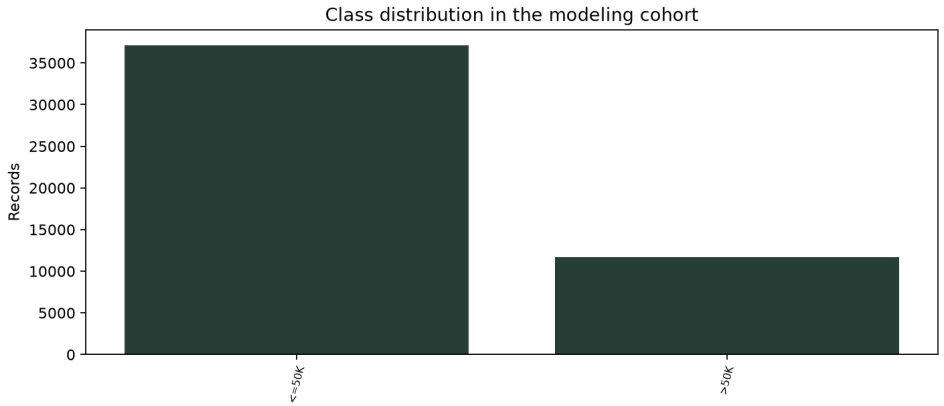
Adult gồm 48.842 bản ghi và 14 thuộc tính từ dữ liệu Census năm 1994, do Barry Becker và Ronny Kohavi cung cấp. Trang UCI công bố license CC BY 4.0 [1]. Các thuộc tính số là tuổi, fnlwgt, số năm học, capital gain, capital loss và số giờ làm mỗi tuần. Tám thuộc tính còn lại là phân loại. Dấu hỏi được đọc thành giá trị thiếu. Không tạo thiếu nhân tạo.

1.3 Chất lượng dữ liệu và chia tập

Hai tệp official train/test được gộp trước khi tạo một split mới. Nhóm có cùng 14 thuộc tính nhưng nhãn mâu thuẫn bị loại toàn bộ; nhóm trùng còn lại giữ một bản ghi. Quy tắc được áp dụng trước khi chia tập, nhằm tránh cùng một vector thuộc tính xuất hiện ở hai phía. Đây không phải phép đánh giá trên official test gốc, nên điểm số không so trực tiếp với các benchmark dùng split đó. Loại 10 dòng có nhãn mâu thuẫn và 52 dòng trùng còn lại; giữ 48,780 dòng. Các cột thiếu gồm workclass (2.799), occupation (2.809) và native-country (857).



Hình 1.1: Số giá trị thiếu theo thuộc tính trong toàn bộ dữ liệu nguồn trước khi chia tập và imputation.



Hình 1.2: Số bản ghi theo nhãn thu nhập sau khi loại nhóm nhãn mâu thuẫn và bản ghi trùng.

Chương 2

Phương pháp và thiết lập

2.1 Tiền xử lý

Split phân tầng theo nhãn với tỷ lệ 70/15/15 và seed 2026; phần 30% còn lại được chia validation/test bằng seed 2027. Median imputer cho cột số và most-frequent imputer cho cột phân loại chỉ fit trên train. Logistic regression dùng StandardScaler và one-hot encoding, với lớp mới ở validation/test được bỏ qua trong encoder. Gradient boosting dùng ordinal encoding cho biến phân loại và khai báo đúng các vị trí categorical; mã -1 biểu diễn hạng chưa gặp. Không chuẩn hóa các cột số cho cây.

2.2 Các mô hình

Baseline luôn dự đoán lớp phổ biến nhất. Logistic regression thường và bản có class weight balanced chọn $C \in \{0.1, 1, 10\}$ theo macro-F1 validation; khi hòa giữ ứng viên xuất hiện trước. Giới hạn optimizer là 2.000 vòng. Histogram gradient boosting dùng 150 vòng, tối đa 31 lá, L2 bằng 1 và không early stopping. Các cấu hình cố định trước khi mở test; không refit trên train cộng validation.

2.3 Phép đo

Accuracy, macro-F1, confusion và precision/recall/F1 từng lớp được tính từ prediction test. Thời gian fit/validation cộng các ứng viên của từng mô hình, không gồm tải dữ liệu và xuất báo cáo. Chỉ một split và model seed 42 được đo, không báo độ lệch chuẩn hoặc khoảng tin cậy từ một lượt. Các thuộc tính số được chuẩn hóa cho logistic regression; histogram gradient boosting dùng chúng ở thang đo gốc. Phân bố số liệu có thể chứa giá trị cực đoan, nhưng thí nghiệm không áp dụng bước phát hiện hoặc loại ngoại lệ riêng. Số mẫu train/validation/test là 34,146/7,317/7,317. Indices/ID và chữ ký nguồn được lưu cùng kết quả.

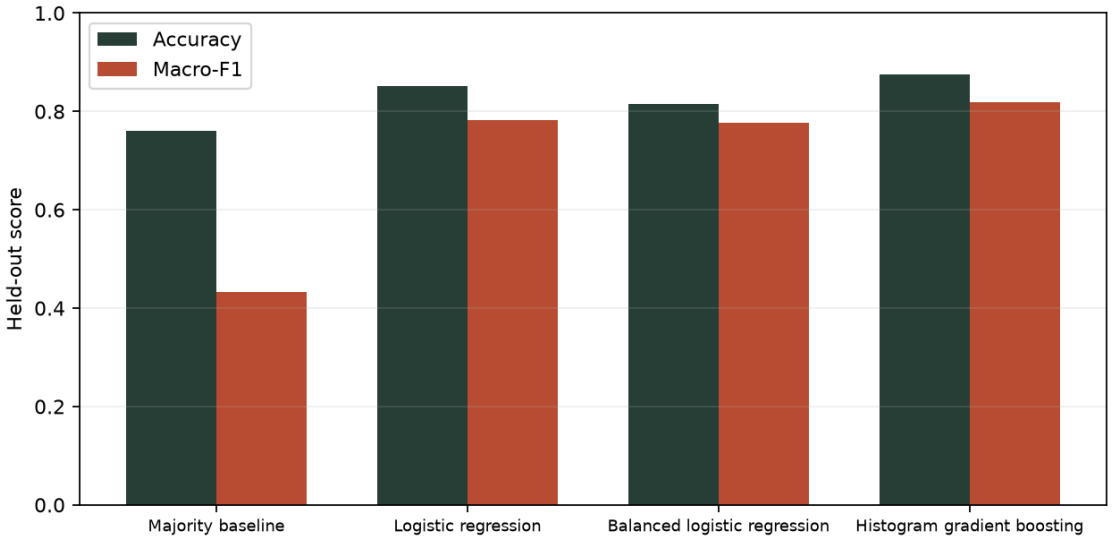
Chương 3

Kết quả và phân tích

3.1 So sánh mô hình

Mô hình	C	Val macro-F1	Test accuracy	Test macro-F1
Majority baseline	–	0.4320	76.06%	0.4320
Logistic regression	10.0	0.7803	85.24%	0.7815
Balanced logistic regression	10.0	0.7639	81.43%	0.7769
Histogram gradient boosting	–	0.8147	87.48%	0.8185

Bảng 3.1: Siêu tham số C được chọn theo macro-F1 trên validation; các cột test là kết quả trên tập giữ riêng. Accuracy trình bày theo phần trăm, macro-F1 theo thang 0–1.

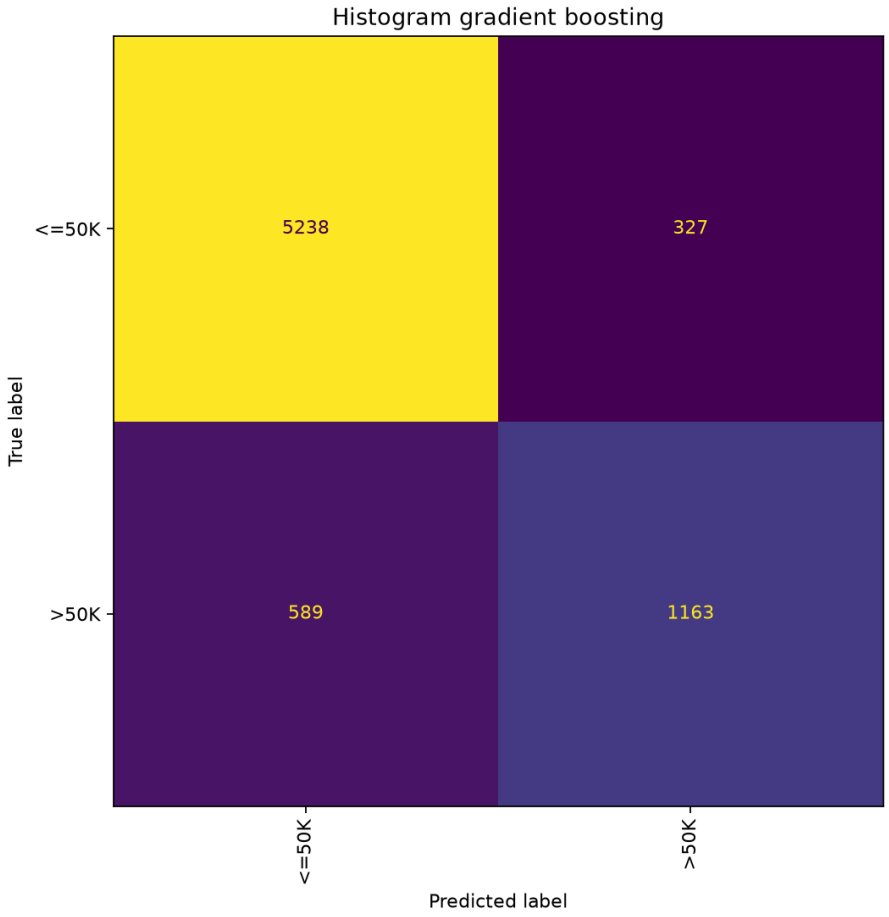


Hình 3.1: Độ chính xác và macro-F1 của bốn mô hình trên cùng tập kiểm tra. Kết quả tính trên một cách chia và một hạt giống.

3.2 Nhận xét

Histogram gradient boosting đạt accuracy 87.48% và macro-F1 0.8185, cao hơn logistic regression 2.24 điểm phần trăm accuracy và 0.0370 macro-F1. Kết quả cho thấy mô hình boosting có hiệu quả cao hơn trong split và cấu hình đã thử; phép so sánh không xác định riêng vai trò của phi tuyến tính, tương tác hay cách mã hóa.

Thêm trọng số cân bằng lớp làm recall của nhóm thu nhập trên 50.000 USD tăng từ 0.5908 lên 0.8459, trong khi precision giảm từ 0.7403 xuống 0.5764. Số dự đoán dương tính giả tăng từ 363 với hồi quy logistic thông thường lên 1,089 với bản cân bằng lớp. Trọng số lớp giúp bỏ sót ít bản ghi thu nhập cao hơn và làm tăng số bản ghi được xếp nhầm vào nhóm này.



Hình 3.2: Ma trận nhầm lẫn trên test của mô hình có macro-F1 validation cao nhất; hàng là nhãn thực, cột là nhãn dự đoán.

Chương 4

Kết luận và giới hạn

4.1 Giới hạn

Các kết quả phản ánh một cách chia dữ liệu và một hạt giống. Nguồn điều tra năm 1994 giới hạn khả năng áp dụng cho thu nhập hiện nay. Sau khi gộp các bản ghi trùng thuộc tính, dữ liệu còn thiếu mã hộ gia đình để chia theo hộ. Fnlwgt được dùng làm biến đầu vào. Các chỉ số mô tả tập mẫu đã chia. Chưa khảo sát riêng ảnh hưởng của từng chiến lược imputation, xử lý giá trị cực đoan hay hiệu quả trên từng nhóm nhân khẩu.

Phạm vi hỗ trợ của AI được trình bày trong AI_USE_REPORT.md.

Tài liệu tham khảo

[1] B. Becker và R. Kohavi. *Adult*. UCI Machine Learning Repository, 1996. DOI: 10.24432/C5XW20. `https://archive.ics.uci.edu/dataset/2/adult`. License CC BY 4.0.

[2] Scikit-learn documentation: Pipeline, ColumnTransformer, TfidfVectorizer và classification metrics. `https://scikit-learn.org/stable/`.