ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



BÁO CÁO TABULAR

CO5177 · Nền tảng lập trình cho phân tích và trực quan dữ liệu

Học kỳ 261 · Năm học 2026–2027

Phân loại thu nhập trên UCI Adult

Nhóm CTG

Huỳnh Thành Đạt	2570161 · 50%
Lương Minh Duy	2570083 · 50%
Giảng viên	Lê Thành Sách

Thành phố Hồ Chí Minh, tháng 11 năm 2026

Tóm tắt

Thực nghiệm dự đoán thu nhập trên 50.000 USD mỗi năm từ 14 thuộc tính trong UCI Adult. Sau khi loại các bản ghi trùng và nhóm có nhãn mâu thuẫn, dữ liệu được chia thành ba tập. Bốn cấu hình so sánh gồm dự đoán lớp đa số, logistic regression thường, logistic regression cân bằng lớp và histogram gradient boosting.

Histogram gradient boosting đạt độ chính xác 87,48% và macro-F1 0,8185 trên 7.317 mẫu test. Trọng số cân bằng lớp làm tăng recall của logistic regression đối với nhóm thu nhập cao, đồng thời tăng số dự đoán dương tính giả.

Tổng quan báo cáo

Dữ liệu	UCI Adult với 14 thuộc tính số và phân loại.
Tiền xử lý	Loại trùng trước khi chia tập, điền giá trị thiếu và mã hóa thuộc tính phân loại.
Đối chứng	Dự đoán lớp đa số, logistic regression và histogram gradient boosting.
Kết quả chính	Histogram gradient boosting đạt độ chính xác 87,48% và macro-F1 0,8185 trên 7.317 mẫu test.

Mục lục

Tóm tắt **i**

Tổng quan báo cáo **ii**

1 Bài toán và dữ liệu **1**

1.1 Mục tiêu 1

1.2 Nguồn và cấu trúc 1

1.3 Chất lượng dữ liệu và chia tập 1

1.4 Phân bố thuộc tính số 2

1.5 Thu nhập theo tuổi, số năm học và giờ làm 2

2 Phương pháp và thiết lập **4**

2.1 Chia tập và tiền xử lý 4

2.2 Các mô hình 5

2.3 Phép đo 5

3 Kết quả và phân tích **7**

3.1 So sánh mô hình 7

3.2 Ảnh hưởng của mất cân bằng lớp 7

3.3 Kết quả của histogram gradient boosting 8

4 Kết luận và giới hạn **10**

4.1 Kết luận 10

4.2 Giới hạn 10

4.3 Hướng mở rộng 10

Tài liệu tham khảo **11**

Danh sách hình vẽ

1.1 Phân bố hai lớp thu nhập và số giá trị thiếu theo thuộc tính trên 34.146 bản ghi train của Adult. 2

1.2 Phân bố sáu thuộc tính số trên tập train. Capital gain và capital loss tập trung ở 0, còn số giờ làm việc tập trung quanh một tuần làm việc thông thường. Trục số bản ghi dùng thang log để thể hiện các khoảng có ít mẫu; thuộc tính giữ ở thang đo gốc. 3

1.3 Tỷ lệ thu nhập trên 50.000 USD trong từng nhóm của tập train; số bản ghi được ghi phía trên mỗi cột. Các nhóm chỉ phục vụ mô tả, còn mô hình sử dụng thuộc tính đầu vào ban đầu. 3

3.1 Accuracy và macro-F1 của bốn mô hình trên 7.317 bản ghi test của Adult ở seed 42. Histogram gradient boosting đạt accuracy cao nhất (87,48%), so với 85,24% của logistic regression và 81,43% khi cân bằng lớp. 7

3.2 Confusion matrix của bốn mô hình trên 7.317 bản ghi test của Adult, với model seed 42. Hàng là nhãn thực, cột là nhãn dự đoán. 9

Danh sách bảng

3.1 Siêu tham số C được chọn theo macro-F1 trên tập validation; các cột test là kết quả trên tập test giữ riêng. Accuracy trình bày theo phần trăm, macro-F1 theo thang 0–1. 7

3.2 Thay đổi chất lượng từng lớp khi cân bằng trọng số trong logistic regression trên cùng tập test. 8

Chương 1

Bài toán và dữ liệu

1.1 Mục tiêu

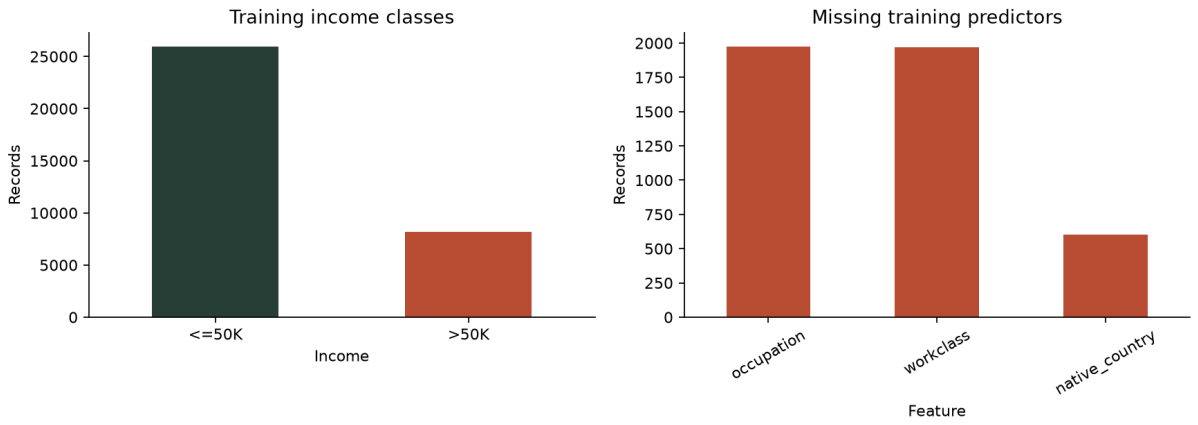
Bài toán là dự đoán một người có thu nhập trên 50.000 USD mỗi năm hay không từ 14 thuộc tính của UCI Adult. Dữ liệu có cả thuộc tính số và phân loại, giá trị thiếu và hai lớp không cân bằng. Thực nghiệm so sánh bốn mô hình, đồng thời xem cách tiền xử lý và trọng số lớp ảnh hưởng đến khả năng nhận ra nhóm thu nhập cao.

1.2 Nguồn và cấu trúc

Adult gồm 48.842 bản ghi và 14 thuộc tính từ dữ liệu Census năm 1994, do Barry Becker và Ronny Kohavi cung cấp. Dữ liệu được UCI công bố [1] dưới dạng hai tệp CSV không có hàng tên cột: `adult.data` gồm 32.561 bản ghi và `adult.test` gồm 16.281 bản ghi. Mỗi dòng chứa 14 thuộc tính đầu vào và nhãn `income`. Các thuộc tính số là tuổi, fnlwgt, số năm học, capital gain, capital loss và số giờ làm mỗi tuần. Tám thuộc tính còn lại là phân loại. Dấu hỏi biểu thị giá trị thiếu. Nhãn đích có hai giá trị: thu nhập không quá 50.000 USD và thu nhập trên mức này. Mô hình dự đoán lớp thu nhập, không dự đoán số tiền cụ thể.

1.3 Chất lượng dữ liệu và chia tập

Hai tệp train/test gốc được gộp trước khi tạo một split mới. Nhóm có cùng 14 thuộc tính nhưng nhãn mâu thuẫn bị loại toàn bộ; nhóm trùng còn lại giữ một bản ghi. Quy tắc được áp dụng trước khi chia tập, nhằm tránh cùng một vector thuộc tính xuất hiện ở hai phía. Đây không phải phép đánh giá trên test gốc, nên điểm số không so trực tiếp với các benchmark dùng split đó. Hai bước làm sạch loại 10 dòng có nhãn mâu thuẫn và 52 dòng trùng. Thực nghiệm sử dụng toàn bộ 48.780 dòng còn lại. Các cột thiếu gồm workclass (2.799), occupation (2.809) và `native_country` (857).



Hình 1.1: Phân bố hai lớp thu nhập và số giá trị thiếu theo thuộc tính trên 34.146 bản ghi train của Adult.

1.4 Phân bố thuộc tính số

Phân bố thuộc tính số được khảo sát trên 34.146 bản ghi train. Quy tắc $1{,}5\,IQR$ đánh dấu giá trị ngoài khoảng $[Q_1 - 1{,}5\,IQR; Q_3 + 1{,}5\,IQR]$, trong đó $IQR = Q_3 - Q_1$ là khoảng giữa hai tứ phân vị.

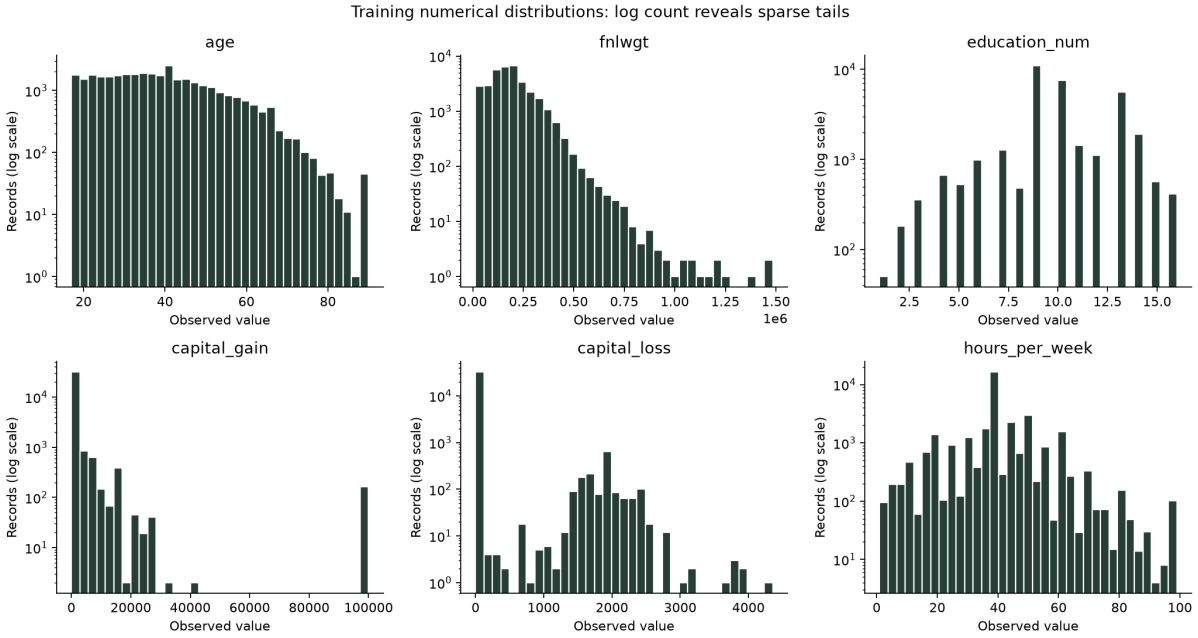
Capital gain và capital loss tập trung mạnh ở 0, đến mức cả Q_1 và Q_3 đều bằng 0. Vì vậy, mọi giá trị dương đều bị đánh dấu: 2.772 bản ghi với capital gain và 1.618 với capital loss. Đây là hệ quả của phân bố, không phải bằng chứng tất cả khoản thu hoặc lỗ dương đều sai.

Với số giờ làm mỗi tuần, $Q_1 = 40$ và $Q_3 = 45$ tạo hai ngưỡng 32,5 và 52,5 giờ. Có 9.461 bản ghi, tức 27,71% tập train, nằm ngoài khoảng này. Loại hết sẽ mất nhiều quan sát có giờ làm khác mức phổ biến. Thực nghiệm vì thế giữ các giá trị và dùng quy tắc IQR để mô tả phần đuôi phân bố.

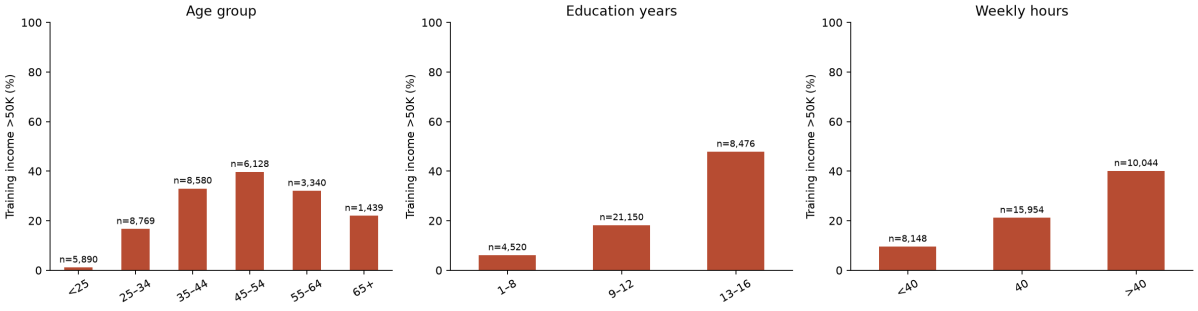
1.5 Thu nhập theo tuổi, số năm học và giờ làm

Tỷ lệ thu nhập cao tăng theo các nhóm tuổi đến 45–54 tuổi rồi giảm ở các nhóm lớn tuổi hơn. Cụ thể, tỷ lệ này là 1,10% ở nhóm dưới 25 tuổi và 39,69% ở nhóm 45–54 tuổi. Nhóm có nhiều năm học hơn và nhóm làm trên 40 giờ mỗi tuần cũng có tỷ lệ thu nhập cao lớn hơn, như thể hiện trong hình.

Đây là mối liên hệ quan sát được trên tập train. Các nhóm khác nhau cả về quy mô lẫn đặc điểm nghề nghiệp, nên không thể suy ra việc tăng số giờ làm hoặc số năm học sẽ trực tiếp tạo ra mức tăng thu nhập tương ứng.



Hình 1.2: Phân bố sáu thuộc tính số trên tập train. Capital gain và capital loss tập trung ở 0, còn số giờ làm việc tập trung quanh một tuần làm việc thông thường. Trục số bản ghi dùng thang log để thể hiện các khoảng có ít mẫu; thuộc tính giữ ở thang đo gốc.



Hình 1.3: Tỷ lệ thu nhập trên 50.000 USD trong từng nhóm của tập train; số bản ghi được ghi phía trên mỗi cột. Các nhóm chỉ phục vụ mô tả, còn mô hình sử dụng thuộc tính đầu vào ban đầu.

Chương 2

Phương pháp và thiết lập

2.1 Chia tập và tiền xử lý

Dữ liệu được chia phân tầng theo nhãn với tỷ lệ 70/15/15 và seed 2026; phần 30% còn lại được chia validation/test bằng seed 2027. Số mẫu train/validation/test lần lượt là 34.146/7.317/7.317. Phân tầng giữ tỷ lệ hai lớp gần nhau giữa các tập, giúp so sánh mô hình trên cùng một phân bố nhãn. Tập validation dùng để chọn cấu hình; tập test chỉ dùng để đánh giá sau khi các lựa chọn đã cố định.

Giá trị thiếu ở thuộc tính số được điền bằng median của tập train; thuộc tính phân loại dùng giá trị xuất hiện nhiều nhất. Cách điền đơn giản này giữ lại các bản ghi thiếu thông tin. Median ít bị chi phối bởi giá trị rất lớn, còn cách điền theo giá trị phổ biến có thể làm nhóm đó xuất hiện nhiều hơn. Validation và test dùng lại các giá trị điền đã tính từ train.

Logistic regression dùng one-hot encoding cho thuộc tính phân loại và standardization cho thuộc tính số. One-hot encoding tránh gán quan hệ thứ tự giả giữa các nhóm như nghề nghiệp hoặc tình trạng hôn nhân. Với thuộc tính số x_j, normalization có dạng

$$z_j = \frac{x_j - \mu_j}{s_j},$$

trong đó μ_j và s_j là trung bình và độ lệch chuẩn trên tập train. Phép biến đổi đưa các cột về thang đo tương đương, giúp quá trình tối ưu logistic regression ít bị chi phối bởi khác biệt đơn vị giữa các biến. Sau biến đổi, sáu cột số có trung bình xấp xỉ 0 và độ lệch chuẩn 1, nhưng vẫn giữ dạng phân bố và các giá trị ở phần đuôi. Nhóm phân loại chưa gặp trong train được biểu diễn bằng các cột one-hot bằng 0.

Với histogram gradient boosting, các giá trị phân loại được ánh xạ thành mã số bằng ordinal encoding, nhưng vẫn được mô hình xử lý như các nhóm phân loại, không có thứ tự số học. Mã -1 biểu diễn giá trị phân loại chưa gặp và được mô hình xem là giá trị thiếu, thay vì một nhóm có thứ tự thấp hơn các nhóm khác. Mô hình cây không áp dụng normalization cho thuộc tính số vì việc chia nhánh dựa trên ngưỡng, không dựa trên khoảng cách giữa các biến.

2.2 Các mô hình

Baseline luôn dự đoán lớp phổ biến nhất, cung cấp mốc so sánh để kiểm tra mức cải thiện so với việc chỉ dựa vào tỷ lệ nhãn. Hai cấu hình logistic regression dùng cùng đặc trưng và quy trình chọn siêu tham số; điểm khác nhau là trọng số lớp [2]. Với $y = 1$ ứng với thu nhập trên 50.000 USD và vector đầu vào đã tiền xử lý $\mathbf{z}$, mô hình có dạng

$$p(y = 1 \mid \mathbf{z}) = \sigma(\mathbf{w}^\top \mathbf{z} + b), \qquad \sigma(a) = \frac{1}{1 + e^{-a}}.$$

Hàm sigmoid đưa điểm tuyến tính $\mathbf{w}^\top \mathbf{z} + b$ về một xác suất trong khoảng 0–1. Mô hình dự đoán lớp thu nhập cao khi xác suất này đạt ít nhất 0,5. Thực nghiệm không bổ sung đặc trưng tương tác cho logistic regression. Tham số C điều khiển nghịch đảo mức regularization: C lớn tương ứng với phạt yếu hơn. Mỗi cấu hình chọn $C \in \{0.1, 1, 10\}$ theo macro-F1 validation; khi hòa giữ ứng viên xuất hiện trước. Quá trình tối ưu được giới hạn ở 2.000 vòng lặp cho mỗi ứng viên.

Ở cấu hình cân bằng lớp, trọng số của lớp k là

$$w_k = \frac{N}{2N_k},$$

trong đó N là số mẫu train và N_k là số mẫu thuộc lớp k trong tập này. Vì vậy, mỗi lỗi ở lớp ít mẫu đóng góp lớn hơn vào hàm mất mát. Như vậy, mô hình chịu phạt nhiều hơn khi dự đoán sai lớp ít mẫu, dù số bản ghi dùng để học vẫn giữ nguyên.

Histogram gradient boosting kết hợp tuần tự nhiều cây để tối ưu hàm mất mát, có thể biểu diễn quan hệ phi tuyến và tương tác mà logistic regression tuyến tính không mô hình hóa trực tiếp. Mô hình được huấn luyện qua 150 vòng boosting, với tối đa 31 lá mỗi cây và mức phạt L2 bằng 1. Early stopping được tắt để không tạo thêm tập validation nội bộ [3]. Các tham số boosting được giữ cố định trong phép so sánh. Sau khi lựa chọn bằng validation, mô hình được đánh giá trên test mà không huấn luyện lại trên train cộng validation.

2.3 Phép đo

Accuracy, macro-F1, confusion matrix và precision/recall/F1 từng lớp được tính từ dự đoán trên tập test. Với lớp thu nhập cao là lớp dương, TP là số dự đoán đúng lớp này, FP là số mẫu thu nhập thấp bị dự đoán thành thu nhập cao và FN là số mẫu thu nhập cao bị bỏ sót:

$$\text{precision} = \frac{TP}{TP + FP}, \qquad \text{recall} = \frac{TP}{TP + FN}, \qquad F_1 = \frac{2TP}{2TP + FP + FN}.$$

Macro-F1 là trung bình F1 của hai lớp, gán vai trò ngang nhau cho mỗi lớp dù số mẫu khác nhau. Chỉ số này được dùng để chọn C nhằm tránh việc accuracy cao che khuất khả năng dự đoán lớp thu nhập cao. Precision và recall vẫn cần được đọc riêng vì cùng một F1 có thể đi kèm những kiểu sai khác nhau. Thực nghiệm sử dụng một split và model seed 42, chưa ước lượng độ biến thiên qua nhiều lượt chạy.

Chương 3

Kết quả và phân tích

3.1 So sánh mô hình

Mô hình	C	Val macro-F1	Test accuracy	Test macro-F1
Majority baseline	–	0.4320	76.06%	0.4320
Logistic regression	10.0	0.7803	85.24%	0.7815
Balanced logistic regression	10.0	0.7639	81.43%	0.7769
Histogram gradient boosting	–	0.8147	87.48%	0.8185

Bảng 3.1: Siêu tham số C được chọn theo macro-F1 trên tập validation; các cột test là kết quả trên tập test giữ riêng. Accuracy trình bày theo phần trăm, macro-F1 theo thang 0–1.



Hình 3.1: Accuracy và macro-F1 của bốn mô hình trên 7.317 bản ghi test của Adult ở seed 42. Histogram gradient boosting đạt accuracy cao nhất (87,48%), so với 85,24% của logistic regression và 81,43% khi cân bằng lớp.

3.2 Ảnh hưởng của mất cân bằng lớp

Lớp thu nhập không quá 50.000 USD chiếm 76,06% tập test. Vì vậy, baseline luôn chọn lớp này vẫn đạt accuracy 76,06%, dù bỏ sót toàn bộ nhóm thu nhập cao. Macro-F1 chỉ đạt 0,4320, cho thấy accuracy đơn lẻ dễ che khuất lỗi ở lớp ít mẫu.

Cân bằng trọng số giúp logistic regression nhận ra nhiều bản ghi thu nhập cao hơn. Số bỏ sót giảm từ 717 xuống 270, nhưng số bản ghi thu nhập thấp bị dự đoán thành thu

nhập cao tăng từ 363 lên 1.089. Recall tăng trong khi precision giảm; đó là sự đánh đổi giữa bỏ sót và dự đoán dương tính giả.

Chỉ số trên test	Logistic regression	Cân bằng lớp
Precision lớp thu nhập cao	0,7403	0,5764
Recall lớp thu nhập cao	0,5908	0,8459
F1 lớp thu nhập cao	0,6571	0,6856
F1 lớp thu nhập thấp	0,9060	0,8682
Macro-F1	0,7815	0,7769

Bảng 3.2: Thay đổi chất lượng từng lớp khi cân bằng trọng số trong logistic regression trên cùng tập test.

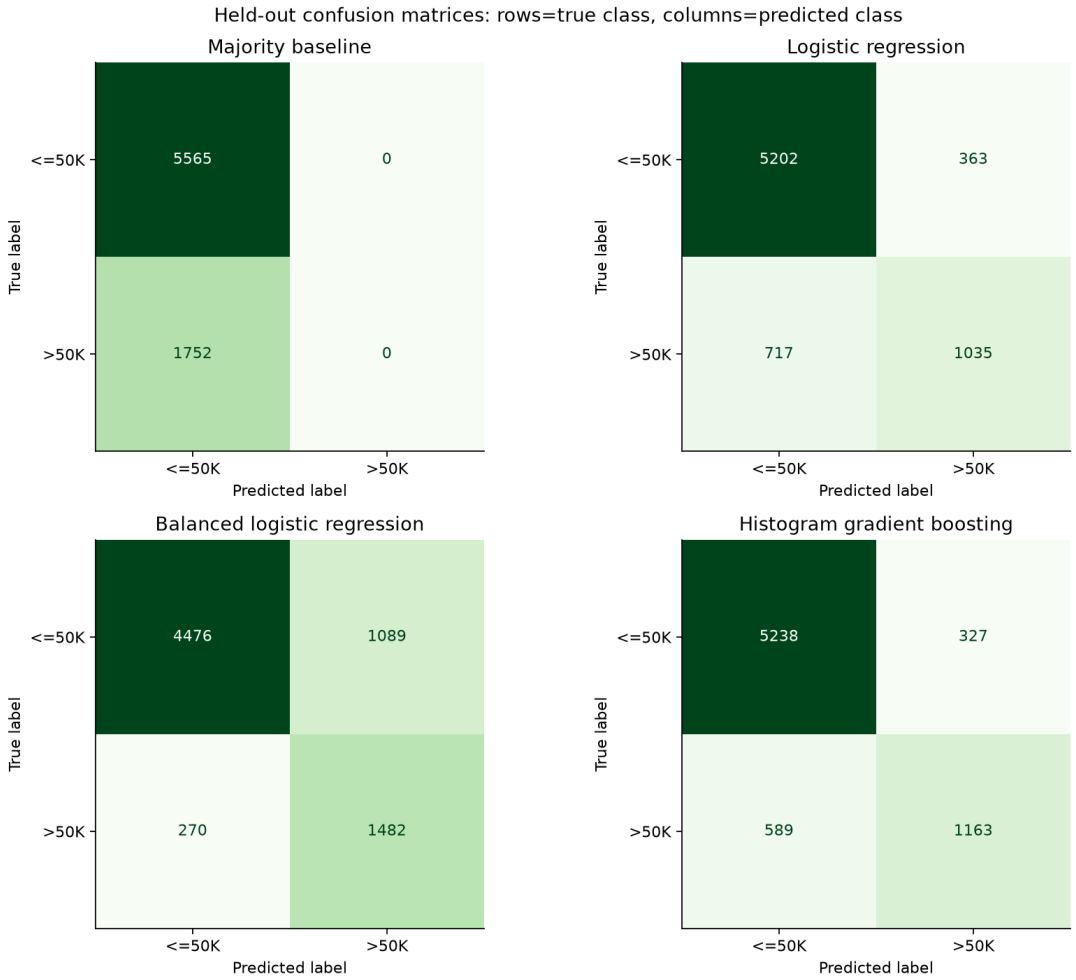
F1 của lớp thu nhập cao tăng, nhưng F1 của lớp còn lại giảm nhiều hơn, khiến macro-F1 chung giảm nhẹ. Cấu hình cân bằng lớp phù hợp hơn khi ưu tiên tránh bỏ sót; nó không phải lựa chọn tốt hơn ở mọi tiêu chí.

3.3 Kết quả của histogram gradient boosting

Histogram gradient boosting đạt kết quả tốt nhất trong bốn mô hình, với accuracy 87,48% và macro-F1 0,8185. So với logistic regression, accuracy tăng 2,24 điểm phần trăm. Boosting cũng dẫn đầu trên validation, nên thứ hạng trên test phù hợp với kết quả lựa chọn mô hình.

Mô hình dự đoán đúng 1.163 bản ghi thu nhập cao, bỏ sót 589 và tạo 327 dương tính giả. Cả hai loại lỗi đều ít hơn logistic regression thông thường. Tuy vậy, khoảng một phần ba bản ghi thu nhập cao vẫn bị bỏ sót; đây là điểm hạn chế chính dù accuracy chung khá cao.

Boosting có thể học quan hệ phi tuyến và tương tác giữa các thuộc tính. Kết quả phù hợp với khả năng này, nhưng không xác định riêng đóng góp của nó vì hai mô hình còn dùng cách mã hóa thuộc tính phân loại khác nhau.



Hình 3.2: Confusion matrix của bốn mô hình trên 7.317 bản ghi test của Adult, với model seed 42. Hàng là nhãn thực, cột là nhãn dự đoán.

Chương 4

Kết luận và giới hạn

4.1 Kết luận

Trên toàn bộ dữ liệu sau làm sạch và split đã cố định, histogram gradient boosting đạt kết quả cao nhất trong các cấu hình được khảo sát. Logistic regression cân bằng lớp tăng recall của nhóm thu nhập cao nhưng giảm precision và accuracy. Vì vậy, lựa chọn trọng số lớp cần gắn với mức chấp nhận bỏ sót và dự đoán dương tính giả của bài toán.

4.2 Giới hạn

Thực nghiệm dùng một cách chia dữ liệu và một seed, với phạm vi siêu tham số hẹp. Kết quả xác định cấu hình tốt nhất trong phép so sánh này, chưa cho biết độ biến thiên khi chia dữ liệu hoặc huấn luyện lại.

Adult dựa trên điều tra năm 1994, nên khó áp dụng trực tiếp cho thu nhập hiện nay. Dữ liệu cũng không có mã hộ gia đình để tách các bản ghi cùng hộ. Fnlwgt được dùng làm thuộc tính dự đoán, không làm trọng số mẫu; do đó, các chỉ số đánh giá các bản ghi test thay vì ước lượng cho toàn bộ dân số.

Các phân tích theo nhóm có tính mô tả, chưa đủ để đánh giá tính công bằng của mô hình. Ảnh hưởng riêng của cách điền thiếu và xử lý giá trị cực đoan cũng cần được khảo sát thêm.

4.3 Hướng mở rộng

Có thể mở rộng bằng cách lặp lại trên nhiều split, so sánh cách điền thiếu và xử lý phần đuôi phân bố. Một hướng khác là chọn ngưỡng dự đoán theo chi phí bỏ sót và dương tính giả. Các lựa chọn mới cần được đánh giá bằng validation trước khi kiểm tra trên test.

Phạm vi hỗ trợ của AI được trình bày trong AI_USE_REPORT.md.

Tài liệu tham khảo

[1] B. Becker và R. Kohavi. *Adult*. UCI Machine Learning Repository, 1996. DOI: 10.24432/C5XW20. https://archive.ics.uci.edu/dataset/2/adult.

[2] Scikit-learn. *LogisticRegression*. https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression.html.

[3] Scikit-learn. *HistGradientBoostingClassifier*. https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.HistGradientBoostingClassifier.html.