ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



BÁO CÁO TEXT

CO5177 · Nền tảng lập trình cho phân tích và trực quan dữ liệu

Học kỳ 261 · Năm học 2026–2027

Phân loại tiêu đề VietnamNet với TF-IDF và PhoBERT

Nhóm CTG

Huỳnh Thành Đạt	2570161 · 50%
Lương Minh Duy	2570083 · 50%
Giảng viên	Lê Thành Sách

Thành phố Hồ Chí Minh, tháng 10 năm 2026

Tóm tắt

Thực nghiệm so sánh các cách biểu diễn trên cùng tập 7.600 tiêu đề VietnamNet thuộc 19 chuyên mục. TF-IDF theo từ và theo ký tự được kết hợp với SVM tuyến tính. Đặc trưng từ PhoBERT đóng băng được đưa vào hồi quy logistic. Bộ phân loại được chọn bằng macro-F1 trên tập validation.

PhoBERT đóng băng kết hợp hồi quy logistic đạt độ chính xác 77,54% và macro-F1 0,7738 trên 1.140 mẫu test. Kết quả phản ánh hiệu quả của từng cặp biểu diễn và bộ phân loại. Tập tiêu đề cân bằng và cách chia riêng xác định phạm vi của phép so sánh.

Tổng quan báo cáo

Dữ liệu	7.600 tiêu đề được chọn từ bộ dữ liệu VietnamNet do nhóm thu thập.
Biểu diễn	TF-IDF theo từ, TF-IDF theo ký tự và đặc trưng PhoBERT đóng băng.
Phép đo	Độ chính xác, macro-F1 và lỗi theo chuyên mục trên tập test giữ riêng.
Kết quả chính	PhoBERT đóng băng kết hợp hồi quy logistic đạt độ chính xác 77,54% và macro-F1 0,7738 trên 1.140 mẫu test.

Mục lục

Tóm tắt **i**

Tổng quan báo cáo **ii**

1 Bài toán và dữ liệu **1**

1.1 Mục tiêu 1

1.2 Nguồn VietnamNet 1

1.3 Làm sạch và tập mô hình 1

2 Biểu diễn và mô hình **3**

2.1 Split và tách từ 3

2.2 TF-IDF và Linear SVM 3

2.3 PhoBERT đóng băng 3

2.4 Đánh giá 3

3 Kết quả và phân tích **5**

3.1 So sánh mô hình 5

3.2 Nhận xét 5

4 Kết luận và giới hạn **7**

4.1 Giới hạn 7

Tài liệu tham khảo **8**

Danh sách hình vẽ

1.1 Mỗi lớp có 400 tiêu đề trong tập mô hình. 2

3.1 Độ chính xác và macro-F1 của bốn mô hình trên cùng tập test. Kết quả tính trên một cách chia và một seed. 5

3.2 Ma trận nhầm lẫn trên test của mô hình có macro-F1 validation cao nhất; hàng là nhãn thực, cột là nhãn dự đoán. 6

Danh sách bảng

3.1 Siêu tham số C được chọn theo macro-F1 trên validation; các cột test là kết quả trên tập giữ riêng. Accuracy trình bày theo phần trăm, macro-F1 theo thang 0–1. 5

Chương 1

Bài toán và dữ liệu

1.1 Mục tiêu

Bài toán phân loại chuyên mục của bài báo từ tiêu đề tiếng Việt. Các cách biểu diễn được so sánh trên cùng dữ liệu và split: TF-IDF từ, TF-IDF ký tự và đặc trưng PhoBERT đóng băng. Baseline lớp đa số cung cấp mức đối chứng; mô hình không dùng URL, body hoặc tên chuyên mục làm input.

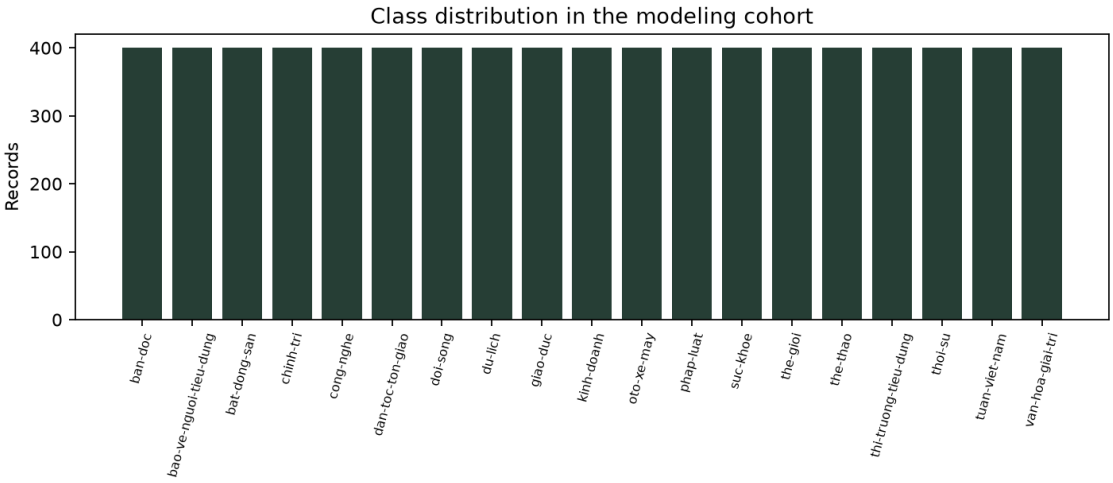
1.2 Nguồn VietnamNet

Bộ `dathuynh1108/vietnamnet-news` do nhóm thu thập chứa 212.705 bài trong 19 tệp chuyên mục. Bài này dùng các tệp parquet gốc, không dùng config NER có nhãn thực thể. Revision nguồn được cố định ở `d70a9601f36dcb1e5c534d30e2d3921c2ba16284`; SHA256 từng tệp nằm trong config. Dataset card không nêu license phân phối nội dung báo chí; tình trạng license được ghi là chưa rõ. Dữ liệu thô và trọng số mô hình không được đưa vào Git [1].

1.3 Làm sạch và tập mô hình

Tiêu đề được chuẩn hóa NFC và khoảng trắng. URL được bỏ query/fragment để nhận diện bài. Các bản ghi có cùng URL hoặc cùng tiêu đề đã casefold được nối thành nhóm liên thông; nhóm có nhiều chuyên mục bị loại toàn bộ, nhóm còn lại giữ một bản ghi. Quy tắc loại trùng được áp dụng trước bước lấy mẫu và chia tập. Có 1,167 tiêu đề rỗng, 3,628 dòng thuộc nhóm chuyên mục mâu thuẫn và 296 dòng trùng còn lại bị loại. Corpus còn 207,614 bài có thể sử dụng.

Chọn tối đa 400 bài mỗi lớp bằng thứ tự SHA256 của ID với seed 2026, trước khi xem chỉ số mô hình. Tập mô hình có 7.600 tiêu đề, đủ 19 lớp. Đây là một cohort cân bằng từ corpus đã kiểm tra đầy đủ, không phải huấn luyện trên toàn bộ 212.705 bài. Lựa chọn này giới hạn chi phí mã hóa và cho phép so sánh các cách biểu diễn trên cùng dữ liệu. Phân bố nguồn vốn không cân bằng được lưu trong audit.



Hình 1.1: Mỗi lớp có 400 tiêu đề trong tập mô hình.

Chương 2

Biểu diễn và mô hình

2.1 Split và tách từ

Split phân tầng 70/15/15 dùng seed 2026, tiếp tục chia validation/test bằng seed 2027. Ba tập có 5.320/1.140/1.140 tiêu đề; mỗi lớp có 280/60/60 mẫu. PyVi tách từ cho cùng chuỗi đầu vào của mọi mô hình. Sau tách từ còn kiểm tra tính duy nhất của input.

2.2 TF-IDF và Linear SVM

TF-IDF từ dùng unigram/bigram; bản ký tự dùng char-within-word n-gram 3–5. Mỗi vectorizer có tối đa 80.000 đặc trưng, min-df 2, max-df 0,98 và sublinear TF. Từ vựng và IDF chỉ fit trên train. Linear SVM chọn $C \in \{0.5, 1, 2\}$ bằng macro-F1 validation, tối đa 5.000 vòng, model seed 42.

2.3 PhoBERT đóng băng

Dùng `vinai/phobert-base-v2`. Revision model:

`86cd7fd4c148980922ac11a2cf5e257f2ba639e1`.

PhoBERT yêu cầu input đã tách từ [2]. Encoder ở eval, mọi trọng số requires-grad bằng false; không cập nhật backbone bằng corpus. Đặc trưng 768 chiều được mean-pool theo attention mask, gồm token BOS/EOS và không gồm padding. Input tối đa 128 token, batch 16, FP32. Không có tiêu đề nào bị cắt trong cohort đã đo. Logistic regression trên đặc trưng cố định chọn cùng tập C bằng macro-F1 validation, tối đa 2.000 vòng. Các vector test được tạo bằng encoder cố định, không dùng để học từ vựng, thống kê chuẩn hóa hoặc tham số classifier.

2.4 Đánh giá

Tất cả lựa chọn classifier hoàn tất bằng validation trước khi dự đoán test. Đo accuracy, macro-F1 và F1 theo chuyên mục trên cùng 1.140 tiêu đề; không chọn mô hình theo test. Thời gian classifier gồm toàn bộ fit/validation của các ứng viên, tách khỏi thời gian mã

hóa PhoBERT. Lần mã hóa đã đo dùng `mps` trên Apple M1 Pro, mất 19.19 giây cho 7.600 tiêu đề. Các feature được cache cùng hash; tải model, tách từ và fit classifier nằm ngoài khoảng thời gian này. Số mẫu train/validation/test là 5,320/1,140/1,140. Indices/ID và chữ ký nguồn được lưu cùng kết quả.

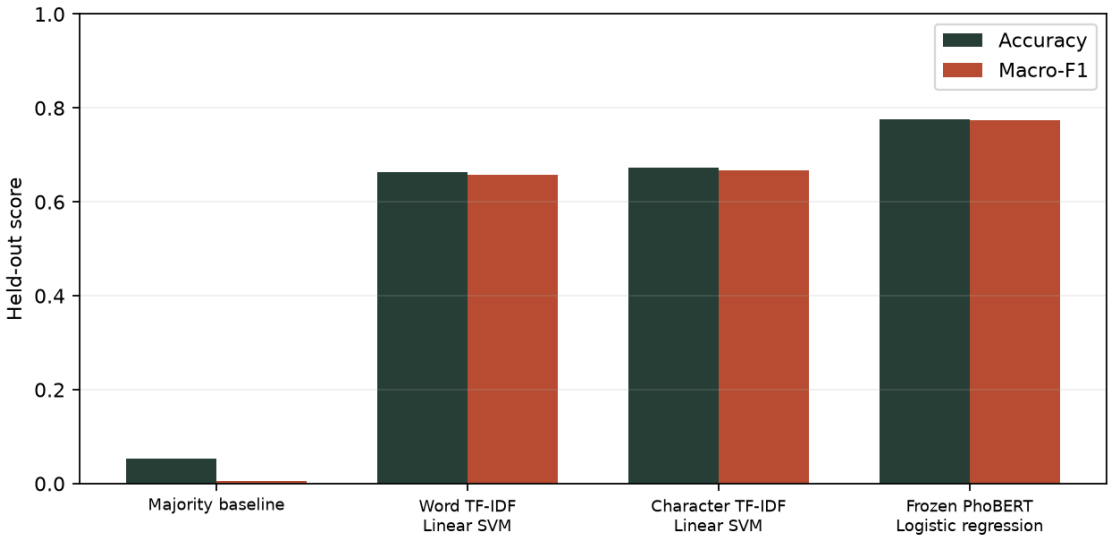
Chương 3

Kết quả và phân tích

3.1 So sánh mô hình

Mô hình	C	Val macro-F1	Test accuracy	Test macro-F1
Majority baseline	–	0.0053	5.26%	0.0053
Word TF-IDF + Linear SVM	0.5	0.6326	66.32%	0.6582
Character TF-IDF + Linear SVM	0.5	0.6435	67.28%	0.6676
Frozen PhoBERT + Logistic regression	0.5	0.7625	77.54%	0.7738

Bảng 3.1: Siêu tham số C được chọn theo macro-F1 trên validation; các cột test là kết quả trên tập giữ riêng. Accuracy trình bày theo phần trăm, macro-F1 theo thang 0–1.

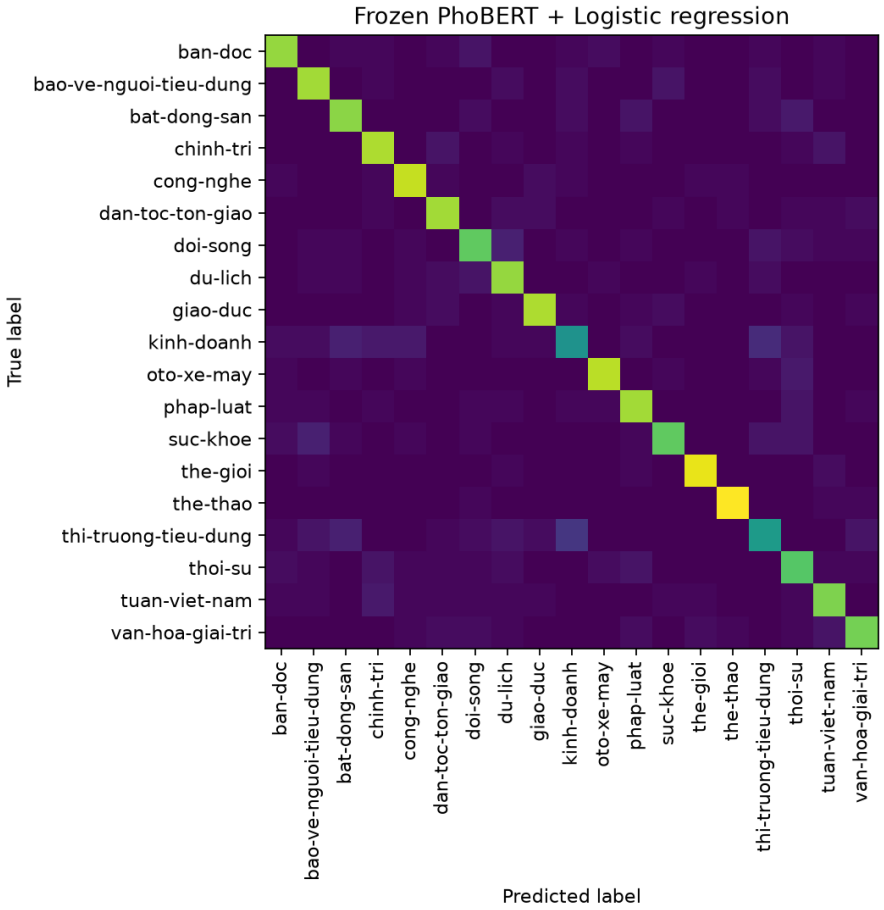


Hình 3.1: Độ chính xác và macro-F1 của bốn mô hình trên cùng tập test. Kết quả tính trên một cách chia và một seed.

3.2 Nhận xét

PhoBERT đóng băng với logistic regression đạt accuracy 77.54% và macro-F1 0.7738. So với TF-IDF ký tự, accuracy tăng 10.26 điểm phần trăm và macro-F1 tăng 0.1061. Đây là so sánh giữa toàn bộ pipeline đã đo; thí nghiệm chưa cô lập ảnh hưởng của encoder, pooling hoặc classifier.

TF-IDF ký tự đạt 67.28%, so với 66.32% của TF-IDF từ. Chênh lệch quan sát được nhỏ hơn mức tăng từ PhoBERT; một split chưa đủ để suy ra ưu thế ổn định giữa hai baseline. Ba lớp có F1 thấp nhất của mô hình chọn bằng validation là `kinh-doanh` (0.537), `thi-truong-tieu-dung` (0.554), `thoi-su` (0.667). Các chuyên mục gần nhau hoặc chuyên mục rộng có thể gây nhầm lẫn; cần đối chiếu nhãn và bài nguồn trước khi gán nguyên nhân cho mô hình.



Hình 3.2: Ma trận nhầm lẫn trên test của mô hình có macro-F1 validation cao nhất; hàng là nhãn thực, cột là nhãn dự đoán.

Chương 4

Kết luận và giới hạn

4.1 Giới hạn

Chỉ dùng tiêu đề trên cohort cân bằng, nên kết quả không mô tả việc đọc toàn bài hoặc phân bố triển khai tự nhiên. Chuyên mục nguồn có thể giao nhau; 3.628 dòng có mâu thuẫn trong nhóm trùng đã bị loại, nhưng chưa kiểm tra nhãn từng bài. Đã xử lý exact URL/headline duplicates; near duplicates và split theo thời gian chưa được khảo sát. Không có nhiều split/seed để mô tả độ bất định. PhoBERT không được fine-tune trong thực nghiệm này.

Phạm vi hỗ trợ của AI được trình bày trong AI_USE_REPORT.md.

Tài liệu tham khảo

[1] Nhóm thực hiện. *VietnamNet News*. `https://huggingface.co/datasets/dathuynh1108/vietnamnet-news`. Revision và checksums trong config.

[2] D. Q. Nguyen và A. T. Nguyen. *PhoBERT: Pre-trained language models for Vietnamese*. Findings of EMNLP, 2020. `https://huggingface.co/vinai/phobert-base-v2`. Model card nêu license AGPL-3.0 cho phiên bản base-v2.

[3] PyVi 0.1.1. Vietnamese word segmentation. `https://pypi.org/project/pyvi/`.

[4] Scikit-learn documentation: Pipeline, ColumnTransformer, TfidfVectorizer và classification metrics. `https://scikit-learn.org/stable/`.