ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH




## BÁO CÁO TEXT

**CO5177 · Nền tảng lập trình cho phân tích và trực quan dữ liệu**

Học kỳ 261 · Năm học 2026–2027

# Phân loại tiêu đề VietnamNet với TF-IDF và PhoBERT

**Nhóm CTG**

| | |
|---|---|
| Huỳnh Thành Đạt | 2570161 · 50% |
| Lương Minh Duy | 2570083 · 50% |
| Giảng viên | Lê Thành Sách |

**Thành phố Hồ Chí Minh, tháng 11 năm 2026**

# Tóm tắt

Thực nghiệm so sánh các cách biểu diễn trên toàn bộ tập tiêu đề VietnamNet hợp lệ thuộc 19 chuyên mục. TF-IDF theo từ và theo ký tự được kết hợp với SVM tuyến tính. Đặc trưng từ PhoBERT đóng băng được đưa vào hồi quy logistic. Bộ phân loại được chọn bằng macro-F1 trên tập validation.

PhoBERT đóng băng kết hợp hồi quy logistic đạt độ chính xác 80,98% và macro-F1 0,7943 trên 31.106 mẫu test. Kết quả phản ánh hiệu quả của từng cặp biểu diễn và bộ phân loại. Dữ liệu giữ phân bố chuyên mục sau làm sạch; các mô hình dùng cùng tập test được chia theo nhóm đầu vào.

# Tổng quan báo cáo

| | |
|---|---|
| **Dữ liệu** | Toàn bộ 207.375 tiêu đề hợp lệ từ VietnamNet News. |
| **Biểu diễn** | TF-IDF theo từ, TF-IDF theo ký tự và đặc trưng PhoBERT đóng băng. |
| **Phép đo** | Độ chính xác, macro-F1 và lỗi theo chuyên mục trên tập test giữ riêng. |
| **Kết quả chính** | PhoBERT đóng băng kết hợp hồi quy logistic đạt độ chính xác 80,98% và macro-F1 0,7943 trên 31.106 mẫu test. |

# Mục lục

**Tóm tắt** **i**

**Tổng quan báo cáo** **ii**

**1 Bài toán và dữ liệu** **1**

1.1 Mục tiêu và nguồn dữ liệu . . . . . 1

1.2 Làm sạch toàn bộ dữ liệu . . . . . 1

**2 Biểu diễn và mô hình** **2**

2.1 Chia tập theo nhóm đầu vào . . . . . 2

2.2 TF-IDF và SVM tuyến tính . . . . . 2

2.3 PhoBERT đóng băng . . . . . 2

2.4 Đánh giá . . . . . 3

**3 Kết quả và phân tích** **4**

3.1 So sánh mô hình . . . . . 4

3.2 Chi phí fit bộ phân loại . . . . . 4

3.3 Nhận xét . . . . . 5

**4 Kết luận và giới hạn** **7**

4.1 Giới hạn . . . . . 7

**Tài liệu tham khảo** **8**

# Danh sách hình vẽ

1.1 Phân bố chuyên mục trong toàn bộ dữ liệu nguồn và tập bài hợp lệ sau làm sạch. . . . . 1

3.1 Độ chính xác và macro-F1 của bốn mô hình trên cùng tập test. Kết quả tính trên một cách chia và một seed. . . . . 4

3.2 Ma trận nhầm lẫn trên test của mô hình có macro-F1 validation cao nhất; hàng là nhãn thực, cột là nhãn dự đoán. . . . . 6

# Danh sách bảng

3.1 Siêu tham số $C$ được chọn theo macro-F1 trên validation; các cột test là kết quả trên tập giữ riêng. Accuracy trình bày theo phần trăm, macro-F1 theo thang 0–1. . . . . 4

3.2 Tổng thời gian gọi fit của tất cả ứng viên $C$, không gồm dự đoán validation, mã hóa PhoBERT hoặc xuất hình. . . . . 5

Chương 1

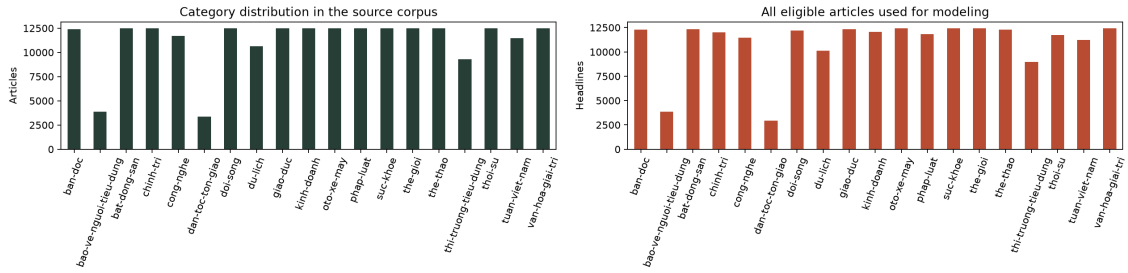
# Bài toán và dữ liệu

## 1.1 Mục tiêu và nguồn dữ liệu

Bài toán phân loại 19 chuyên mục từ tiêu đề tiếng Việt, với các đối chứng gồm lớp đa số, TF-IDF từ, TF-IDF ký tự và đặc trưng PhoBERT đóng băng. Nguồn là bộ VietnamNet News trên kho Hugging Face của sinh viên Huỳnh Thành Đạt [1]. Dữ liệu gồm tiêu đề, nội dung, URL và chuyên mục. Mô hình baseline chỉ nhận tiêu đề; nội dung và URL tham gia kiểm tra chất lượng và xác định nhóm trước khi chia tập.

## 1.2 Làm sạch toàn bộ dữ liệu

Tiêu đề và nội dung được chuẩn hóa Unicode NFC và khoảng trắng. URL được chuẩn hóa, bỏ query và fragment. Các bản ghi có cùng URL, tiêu đề chuẩn hóa không phân biệt hoa thường, hoặc nội dung không rỗng giống nhau được nối thành nhóm liên thông. Nhóm có chuyên mục mâu thuẫn bị loại toàn bộ; các nhóm còn lại giữ một bản ghi. Từ 212.705 bài nguồn, loại 1.167 tiêu đề rỗng, 3.636 dòng thuộc nhóm nhãn mâu thuẫn và 527 dòng trùng còn lại; giữ toàn bộ 207.375 bài hợp lệ. Có 7 bài không có nội dung nhưng vẫn có tiêu đề hợp lệ. Không lấy mẫu hoặc giới hạn số bài theo chuyên mục.




**Hình 1.1:** Phân bố chuyên mục trong toàn bộ dữ liệu nguồn và tập bài hợp lệ sau làm sạch.

Chương 2

# Biểu diễn và mô hình

## 2.1 Chia tập theo nhóm đầu vào

PyVi tách từ cho tiêu đề và đầu vào bài báo. Trước khi chia tập, các bài có cùng chuỗi token cuối cùng của tiêu đề (tối đa 128 token) hoặc cùng đầu vào Head–Tail của bài báo (256 token) được gộp vào cùng nhóm liên thông. Cách này giữ các đầu vào giống nhau ở cùng một phía của phép chia cho cả baseline tiêu đề và mô hình bài báo. Có 207.108 nhóm đầu vào, trong đó 50 nhóm có nhiều bài và nhóm lớn nhất có 39 bài. Bước nhóm không loại thêm bài. StratifiedGroupKFold với 20 fold và seed 2026 chia 14/3/3 fold cho train/validation/test, xấp xỉ tỷ lệ 70/15/15. Baseline và mô hình bài báo dùng cùng ID trong từng tập.

## 2.2 TF-IDF và SVM tuyến tính

TF-IDF từ dùng unigram và bigram; bản ký tự dùng char-within-word n-gram 3–5. Từ vựng và IDF chỉ được học từ train. Cả hai biểu diễn dùng min-df 2, max-df 0,98, sublinear TF và SVM tuyến tính với tối đa 5.000 vòng tối ưu. Mỗi vectorizer có tối đa 80.000 đặc trưng. Hệ số $C \in \{0{,}5; 1; 2\}$ được chọn theo macro-F1 validation; seed mô hình là 42.

## 2.3 PhoBERT đóng băng

PhoBERT Base v2 nhận tiêu đề đã tách từ [2, 3]. Encoder ở chế độ đánh giá và không cập nhật trọng số. Đặc trưng 768 chiều là trung bình có attention mask của các token, gồm BOS/EOS và không gồm padding. Hồi quy logistic được huấn luyện trên các vector này với tối đa 2.000 vòng; $C$ được chọn từ cùng tập ứng viên bằng macro-F1 validation. Đầu vào tối đa 128 token, batch mã hóa 16, FP32. Số tiêu đề bị cắt trong lần mã hóa là 0. Các vector validation/test được tạo bằng encoder cố định, không tham gia học từ vựng hoặc bộ phân loại.

## 2.4 Đánh giá

Mọi siêu tham số được chọn bằng validation trước khi dự đoán test. Accuracy, macro-F1, weighted-F1 và precision/recall/F1 theo chuyên mục được tính trên cùng tập test. Các giá trị $C$ được chọn được trình bày trong bảng kết quả. Chi phí mã hóa PhoBERT được tách khỏi thời gian fit các ứng viên của bộ phân loại. Lần trích xuất đặc trưng cho 207.375 tiêu đề trên RTX 5090 được ghi nhận là 74,12 giây; thời lượng này không gồm tải mô hình, tách từ hoặc fit bộ phân loại. Các vector cố định được dùng cho lần fit bộ phân loại trên CPU. Số mẫu train/validation/test là 145.162/31.107/31.106.

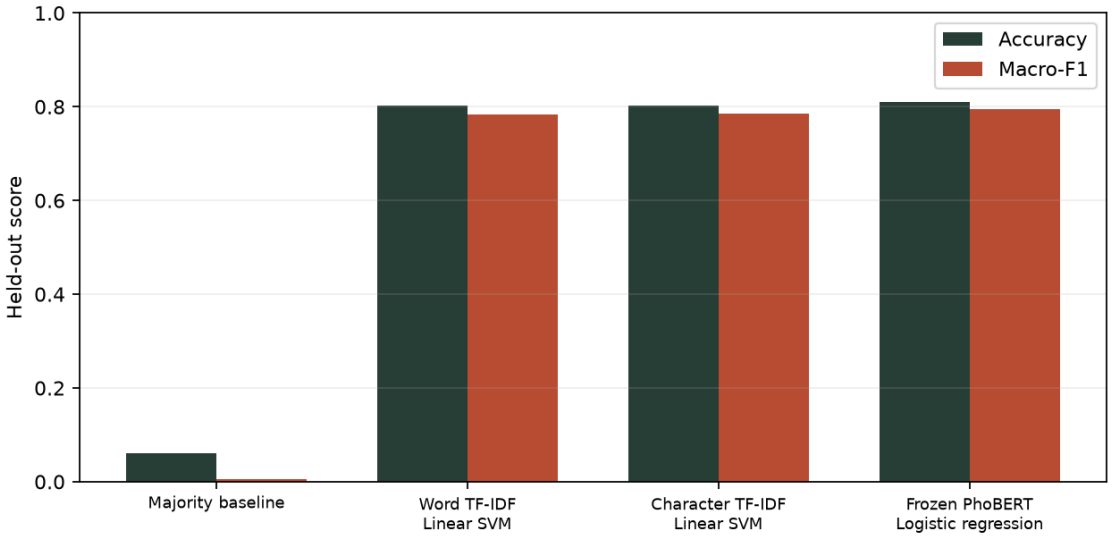
# Chương 3

# Kết quả và phân tích

## 3.1 So sánh mô hình

| Mô hình | C | Val macro-F1 | Test accuracy | Test macro-F1 |
|---|---|---|---|---|
| Lớp đa số | – | 0,0060 | 6,00% | 0,0060 |
| TF-IDF từ và SVM tuyến tính | 0,5 | 0,7904 | 80,19% | 0,7839 |
| TF-IDF ký tự và SVM tuyến tính | 0,5 | 0,7882 | 80,25% | 0,7856 |
| PhoBERT đóng băng và hồi quy logistic | 0,5 | 0,7939 | 80,98% | 0,7943 |

**Bảng 3.1:** Siêu tham số $C$ được chọn theo macro-F1 trên validation; các cột test là kết quả trên tập giữ riêng. Accuracy trình bày theo phần trăm, macro-F1 theo thang 0–1.




**Hình 3.1:** Độ chính xác và macro-F1 của bốn mô hình trên cùng tập test. Kết quả tính trên một cách chia và một seed.

## 3.2 Chi phí fit bộ phân loại

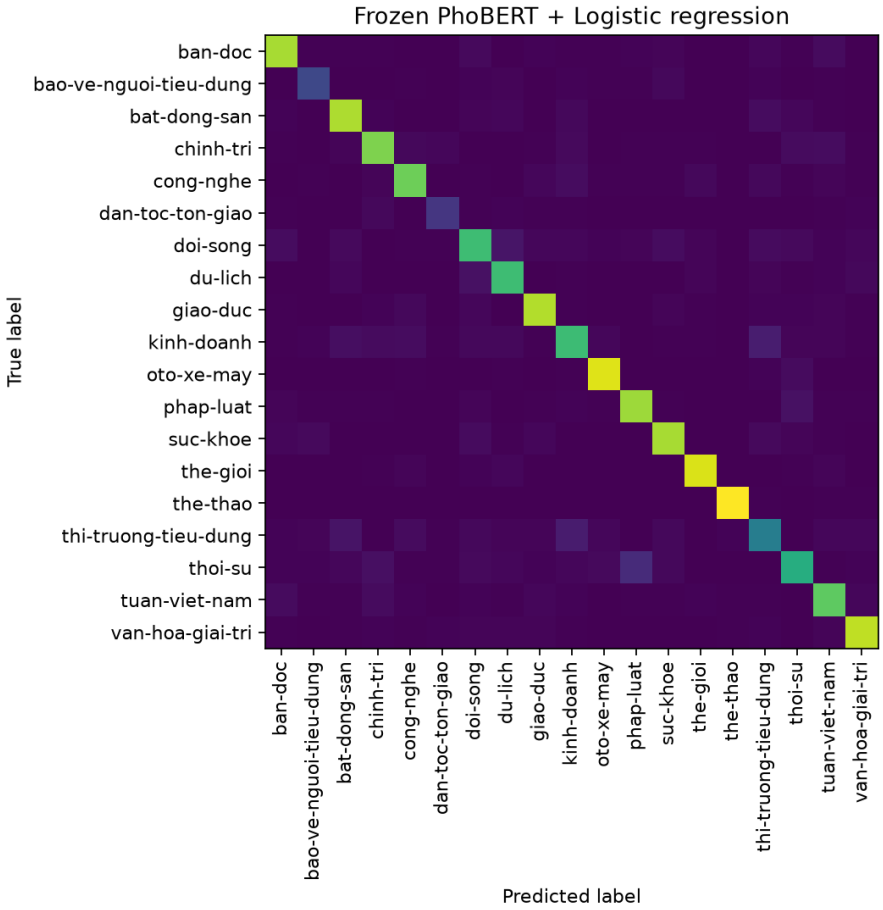
| Mô hình | Tổng thời gian fit trên CPU (giây) |
|---|---|
| Lớp đa số | 0,01 |
| TF-IDF từ và SVM tuyến tính | 50,82 |
| TF-IDF ký tự và SVM tuyến tính | 196,99 |
| PhoBERT đóng băng và hồi quy logistic | 116,83 |

**Bảng 3.2:** Tổng thời gian gọi fit của tất cả ứng viên $C$, không gồm dự đoán validation, mã hóa PhoBERT hoặc xuất hình.

## 3.3 Nhận xét

PhoBERT đóng băng với logistic regression đạt accuracy 80,98% và macro-F1 0,7943. So với TF-IDF ký tự, chênh lệch accuracy là 0,73 điểm phần trăm và chênh lệch macro-F1 là 0,0087. Đây là so sánh giữa toàn bộ pipeline đã đo; thí nghiệm chưa cô lập ảnh hưởng của encoder, pooling hoặc classifier.

TF-IDF ký tự đạt 80,25%, so với 80,19% của TF-IDF từ. Một split chưa đủ để suy ra ưu thế ổn định giữa hai baseline. Ba lớp có F1 thấp nhất của mô hình chọn bằng validation là Thị trường tiêu dùng (0,590), Dân tộc – Tôn giáo (0,664), Thời sự (0,684). Cặp nhầm lẫn nhiều nhất là Thời sự thành Pháp luật với 219/1.761 bài (12,44%). Kinh doanh thành Thị trường tiêu dùng có 143 bài, còn chiều ngược lại có 138 bài.




**Hình 3.2:** Ma trận nhầm lẫn trên test của mô hình có macro-F1 validation cao nhất; hàng là nhãn thực, cột là nhãn dự đoán.

# Chương 4

# Kết luận và giới hạn

## 4.1 Giới hạn

Kết quả phản ánh toàn bộ tập bài hợp lệ sau làm sạch, với đầu vào chỉ gồm tiêu đề. Các chuyên mục nguồn có thể giao nhau về nội dung. Nhóm token giống nhau đã được giữ cùng tập, nhưng chưa đo near duplicates hoặc khả năng khái quát sang giai đoạn xuất bản khác. Một split và seed chưa mô tả độ bất định giữa các lần chạy. PhoBERT giữ nguyên trọng số encoder trong phép so sánh này.

Phạm vi hỗ trợ của AI được trình bày trong AI_USE_REPORT.md.

# Tài liệu tham khảo

[1] *VietnamNet News*. Bộ dữ liệu trên kho Hugging Face của sinh viên Huỳnh Thành Đạt. https://huggingface.co/datasets/dathuynh1108/vietnamnet-news.

[2] Dat Quoc Nguyen và Anh Tuan Nguyen. *PhoBERT: Pre-trained language models for Vietnamese*. Trong *Findings of the Association for Computational Linguistics: EMNLP 2020*, tr. 1037–1042, Association for Computational Linguistics, 2020. DOI: 10.18653/v1/2020.findings-emnlp.92. https://aclanthology.org/2020.findings-emnlp.92/. Model card Base v2: https://huggingface.co/vinai/phobert-base-v2.

[3] PyVi 0.1.1. Vietnamese word segmentation. https://pypi.org/project/pyvi/.

[4] Scikit-learn documentation: Pipeline, ColumnTransformer, TfidfVectorizer và classification metrics. https://scikit-learn.org/stable/.