ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



BÁO CÁO TEXT

CO5177 · Nền tảng lập trình cho phân tích và trực quan dữ liệu

Học kỳ 261 · Năm học 2026–2027

Phân loại bài báo VietnamNet bằng PhoBERT

Nhóm CTG

Huỳnh Thành Đạt	2570161 · 50%
Lương Minh Duy	2570083 · 50%
Giảng viên	Lê Thành Sách

Thành phố Hồ Chí Minh, tháng 11 năm 2026

Tóm tắt

Thực nghiệm fine-tuning PhoBERT Base v2 để phân loại bài báo tiếng Việt vào 19 chuyên mục. Toàn bộ 207.375 bài hợp lệ sau làm sạch được sử dụng; các bài có đầu vào mô hình giống nhau được giữ cùng tập khi chia train, validation và test. Mô hình học từ tiêu đề kết hợp phần đầu và cuối nội dung, với cross-entropy có trọng số lớp. Trên tập test gồm 31.106 bài báo, accuracy và macro-F1 trước hiệu chỉnh đạt 91,83% và 0,9107; sau hiệu chỉnh bằng validation đạt 91,89% và 0,9112. Mức tăng nhỏ, trong khi khác biệt giữa các chuyên mục vẫn rõ: Thể thao có F1 0,9903, còn Dân tộc – Tôn giáo có F1 0,7977.

Tổng quan báo cáo

Dữ liệu	212.705 bài nguồn; giữ toàn bộ 207.375 bài hợp lệ thuộc 19 chuyên mục.
Chia tập	Train: 145.162 bài; validation: 31.107 bài; test: 31.106 bài.
Phương pháp	PhoBERT Base v2 fine-tuning end-to-end với đầu phân loại 19 lớp; Head–Tail 256 token.
Kết quả	Accuracy 91,89%, macro-F1 0,9112 sau hiệu chỉnh từ validation.
Nguồn	VietnamNet News trên kho Hugging Face của học viên Huỳnh Thành Đạt.

Mục lục

Tóm tắt **i**

Tổng quan báo cáo **ii**

1 Bài toán và dữ liệu **1**

1.1 Mục tiêu 1

1.2 Nguồn và làm sạch dữ liệu 1

1.3 Chia tập theo nhóm đầu vào 2

2 Phương pháp và thiết lập **3**

2.1 Biểu diễn Head–Tail 3

2.2 PhoBERT và hàm mất mát 3

2.3 Các baseline 4

2.4 Cấu hình và lựa chọn checkpoint 4

2.5 Hiệu chỉnh trên validation 4

3 Kết quả và phân tích **6**

3.1 Diễn biến huấn luyện 6

3.2 Kết quả trên tập test 7

3.3 Chất lượng theo chuyên mục 7

3.4 So sánh các mô hình 8

4 Kết luận và giới hạn **10**

Tài liệu tham khảo **11**

Danh sách hình vẽ

1.1 Phân bố chuyên mục trước và sau làm sạch, cùng độ dài nội dung trước rút gọn. Toàn bộ bài hợp lệ được sử dụng; sự chênh lệch số mẫu giữa các chuyên mục vẫn được giữ lại. 2

3.1 Train loss theo bước cập nhật và macro-F1 validation theo epoch. Macro-F1 cao nhất ở epoch 6; các giá trị train loss là các mốc ghi nhận trong quá trình tối ưu. 6

3.2 Confusion matrix chuẩn hóa theo hàng và F1 theo chuyên mục sau hiệu chỉnh. Hàng biểu diễn nhãn thật, cột biểu diễn nhãn dự đoán. 8

Danh sách bảng

1.1 Làm sạch toàn bộ dữ liệu trước khi chia tập. Các số bài bị loại ở ba bước là các phần rời nhau. 1

2.1 Thiết lập của lần huấn luyện trên toàn bộ tập bài hợp lệ. 5

3.1 Đánh giá sau mỗi epoch. Cross-entropy có trọng số lớp khác với NLL không trọng số dùng để chọn temperature. 6

3.2 Kết quả trước và sau hiệu chỉnh bằng validation 7

3.3 Một số chuyên mục có F1 thấp và cao sau hiệu chỉnh. Số mẫu theo lớp không bằng nhau; macro-F1 cho mỗi chuyên mục mức đóng góp ngang nhau. 7

3.4 Kết quả các mô hình 9

Chương 1

Bài toán và dữ liệu

1.1 Mục tiêu

Bài toán đặt ra là dự đoán một trong 19 chuyên mục của VietnamNet từ văn bản bài báo. Thực nghiệm đối chiếu các baseline chỉ dùng tiêu đề với PhoBERT sử dụng thêm nội dung, đồng thời phân tích chất lượng theo chuyên mục, diễn biến huấn luyện và tác động của hiệu chỉnh xác suất. PhoBERT Base v2 được fine-tuning trên toàn bộ tập bài hợp lệ. Checkpoint và tham số hiệu chỉnh được chọn trên tập validation; kết quả cuối cùng được đánh giá trên tập test.

1.2 Nguồn và làm sạch dữ liệu

Bộ dữ liệu VietnamNet News được thu thập bằng crawling từ các trang bài báo công khai của VietnamNet và công bố trên kho Hugging Face của học viên Huỳnh Thành Đạt [1]. Dữ liệu gồm 212.705 bài báo thuộc 19 chuyên mục, lưu trong 19 tệp Parquet theo chuyên mục. Mỗi bản ghi có bốn trường: `title` (tiêu đề), `content` (nội dung), `url` (đường dẫn bài báo) và `class` (nhãn chuyên mục).

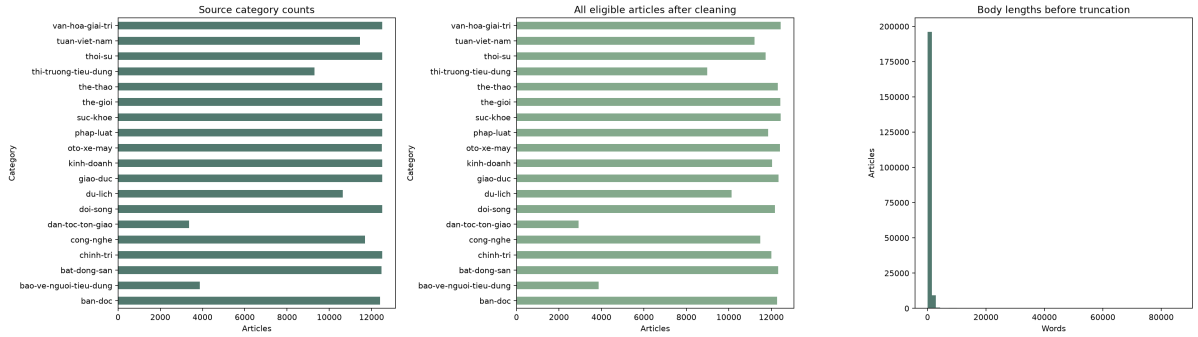
Tiêu đề và nội dung được chuẩn hóa Unicode NFC và khoảng trắng. URL được chuẩn hóa, bỏ query và fragment. Các bản ghi có cùng URL, cùng tiêu đề không phân biệt hoa thường hoặc cùng nội dung không rỗng được gộp thành nhóm; quan hệ trùng được xét bắc cầu qua các bản ghi. Nhóm chứa nhiều nhãn chuyên mục bị loại toàn bộ vì chưa có cơ sở xác định nhãn đúng; mỗi nhóm còn lại giữ một bản ghi. Bảng 1.1 tóm tắt số bài ở từng bước.

Bước xử lý	Số bài
Dữ liệu nguồn	212.705
Loại tiêu đề rỗng	1.167
Loại dòng thuộc nhóm có nhãn mâu thuẫn	3.636
Loại dòng trùng còn lại	527
Bài hợp lệ được sử dụng	207.375

Bảng 1.1: Làm sạch toàn bộ dữ liệu trước khi chia tập. Các số bài bị loại ở ba bước là các phần rời nhau.

Không giới hạn số bài theo chuyên mục. Bảy bài thiếu nội dung vẫn có tiêu đề hợp lệ

và được giữ lại. Phân bố sau làm sạch còn mất cân bằng: Sức khỏe có 12.444 bài, còn Dân tộc – Tôn giáo có 2.917 bài, chênh khoảng 4,27 lần. Accuracy cho biết tỷ lệ bài được phân loại đúng, nhưng có thể che khuất kết quả ở các lớp ít bài. Vì vậy, macro-F1, tức trung bình F1 của 19 lớp với trọng số bằng nhau, được dùng để chọn checkpoint; loss cũng được điều chỉnh theo tần suất lớp trong tập train.



Hình 1.1: Phân bố chuyên mục trước và sau làm sạch, cùng độ dài nội dung trước rút gọn. Toàn bộ bài hợp lệ được sử dụng; sự chênh lệch số mẫu giữa các chuyên mục vẫn được giữ lại.

1.3 Chia tập theo nhóm đầu vào

Chuẩn hóa văn bản và giới hạn token có thể khiến các bài khác nhau ở dữ liệu nguồn trở thành cùng một đầu vào mô hình. Vì vậy, các bài có cùng chuỗi token cuối cùng của tiêu đề tối đa 128 token hoặc cùng đầu vào Head–Tail của bài báo 256 token được gộp vào cùng nhóm. Quy tắc gộp nhóm áp dụng cho cả đầu vào của baseline và PhoBERT fine-tuning.

Có 207.108 nhóm đầu vào; 50 nhóm chứa nhiều bài, nhóm lớn nhất có 39 bài. StratifiedGroupKFold với 20 fold và seed 2026 phân bổ 14 fold cho train, ba fold cho validation và ba fold cho test, tương ứng tỷ lệ khoảng 70/15/15. Tập train gồm 145.162 bài báo; tập validation và tập test lần lượt gồm 31.107 và 31.106 bài. Các bài thuộc một nhóm được giữ trong một tập để tránh trùng đầu vào giữa các tập. Cách chia này được sử dụng cho mọi mô hình.

Chương 2

Phương pháp và thiết lập

2.1 Biểu diễn Head–Tail

Tiêu đề cung cấp thông tin ngắn gọn về bài viết, còn nội dung bổ sung ngữ cảnh khi tiêu đề chưa đủ để xác định chuyên mục. Để giới hạn độ dài xử lý, mỗi đầu vào kết hợp tiêu đề với tối đa 220 từ đầu và 80 từ cuối nội dung. Văn bản được chuyển sang chữ thường, loại dấu câu và chữ số, chuẩn hóa khoảng trắng rồi tách từ bằng PyVi [4]. PhoBERT yêu cầu văn bản đã tách từ trước bước mã hóa subword [3].

Với chuỗi vượt giới hạn đầu vào, Head–Tail giữ 127 subword token đầu và 127 token cuối, kèm hai token đặc biệt:

$$x = [\text{CLS}] \| t_{1:127} \| t_{L-126:L} \| [\text{SEP}].$$

Chuỗi ngắn hơn được bổ sung padding; attention mask phân biệt token văn bản với padding. Việc giữ đầu và cuối giúp đưa cả hai vị trí vào đầu vào 256 token, nhưng phần giữa bài viết vẫn bị bỏ. Loại chữ số cũng có thể làm mất năm, giá tiền hoặc tỷ số; thực nghiệm chưa tách riêng ảnh hưởng của bước này.

2.2 PhoBERT và hàm mất mát

PhoBERT là mô hình ngôn ngữ pretrained cho tiếng Việt [2]. Thực nghiệm dùng Base v2 qua `AutoModelForSequenceClassification`, với đầu phân loại 19 lớp theo kiến trúc RoBERTa [3]. Encoder tạo biểu diễn ngữ cảnh cho chuỗi đầu vào; đầu phân loại chuyển biểu diễn này thành 19 logits tương ứng với các chuyên mục. Đầu phân loại được khởi tạo cho bài toán này và học đồng thời với encoder theo cách end-to-end. Đây là mô hình fine-tuning trực tiếp cho bài toán phân loại, khác với baseline giữ nguyên encoder rồi huấn luyện logistic regression trên các vector đặc trưng. Trọng số lớp chỉ được tính từ tập train:

$$w_c = \frac{N_{\text{train}}}{K n_c}, \qquad K = 19,$$

trong đó n_c là số bài thuộc lớp c trong tập train. Cross-entropy trên batch B dùng trung bình có trọng số:

$$\mathcal{L}_B = -\frac{\sum_{i \in B} w_{y_i} \log p_\theta(y_i \mid x_i)}{\sum_{i \in B} w_{y_i}}.$$

Lớp ít bài có trọng số lớn hơn, làm lỗi ở lớp đó đóng góp nhiều hơn vào loss.

2.3 Các baseline

Bốn baseline dùng cùng các bài trong tập train, validation và test với mô hình chính. Đầu vào văn bản của các baseline chỉ gồm tiêu đề:

- **Majority baseline:** luôn dự đoán chuyên mục xuất hiện nhiều nhất trong tập train.
- **Word TF-IDF + Linear SVM:** biểu diễn tiêu đề bằng TF-IDF theo từ với unigram và bigram, sau đó phân loại bằng SVM tuyến tính.
- **Character TF-IDF + Linear SVM:** sử dụng TF-IDF với n-gram ký tự dài 3–5 trong phạm vi từng từ, kết hợp SVM tuyến tính.
- **Frozen PhoBERT + Logistic regression:** giữ nguyên trọng số PhoBERT và mã hóa tiêu đề với độ dài tối đa 128 token. Vector đặc trưng 768 chiều được tính bằng trung bình các vector token có attention mask hợp lệ, rồi đưa vào logistic regression.

Majority baseline cho biết kết quả khi chỉ dựa vào tần suất nhãn. Hai SVM đánh giá mức độ phân biệt chuyên mục của từ và cụm ký tự trong tiêu đề; Frozen PhoBERT đánh giá biểu diễn pretrained khi encoder chưa được cập nhật theo nhãn chuyên mục. Từ vựng và IDF chỉ được học trên tập train, với tối đa 80.000 đặc trưng cho mỗi biểu diễn TF-IDF. Hệ số C của SVM và logistic regression được chọn trong $\{0{,}5; 1; 2\}$ theo macro-F1 trên tập validation.

2.4 Cấu hình và lựa chọn checkpoint

Mô hình hoàn tất bảy epoch với 15.883 bước cập nhật trong 1.443,6 giây, tương đương 24,06 phút. Thời lượng này là phần fine-tuning, không bao gồm toàn bộ thời gian tải và chuẩn bị dữ liệu. Checkpoint epoch 6 được chọn với macro-F1 validation 0,909129; epoch 7 vẫn được huấn luyện và đánh giá đầy đủ.

2.5 Hiệu chỉnh trên validation

Với logits $z_{i,c}$, temperature scaling tạo xác suất

$$p_{i,c}(T) = \frac{\exp(z_{i,c}/T)}{\sum_{k=1}^{K} \exp(z_{i,k}/T)}, \qquad T > 0.$$

Tham số	Giá trị
Mô hình / số lớp	PhoBERT Base v2 / 19
Độ dài đầu vào	256 token
Optimizer	Fused AdamW
Learning rate / weight decay	2×10^{-5} / 0,01
Warmup	200 bước
Batch trên GPU / tích lũy gradient	32 / 2
Batch hiệu dụng	64
Số epoch tối đa / patience	7 / 3
Tiêu chí chọn checkpoint	Macro-F1 validation lớn nhất
Seed dữ liệu / mô hình	2026 / 42
Thiết bị / độ chính xác số	RTX 5090 / BF16

Bảng 2.1: Thiết lập của lần huấn luyện trên toàn bộ tập bài hợp lệ.

Tham số T được chọn để giảm negative log-likelihood trên validation. Sau đó, hệ số tương đối $t_c > 0$ cho từng lớp được chọn bằng F1 trên validation, với quy tắc

$$\widehat{y}_i = \arg\max_c \frac{p_{i,c}(T)}{t_c}.$$

Các t_c co giãn điểm tương đối giữa các lớp, không phải các ngưỡng xác suất nhị phân độc lập. Temperature riêng lẻ giữ nguyên thứ tự logits; các hệ số theo lớp có thể thay đổi nhãn dự đoán. Checkpoint, T và t_c được cố định trước khi đánh giá hai quy tắc trên test.

Chương 3

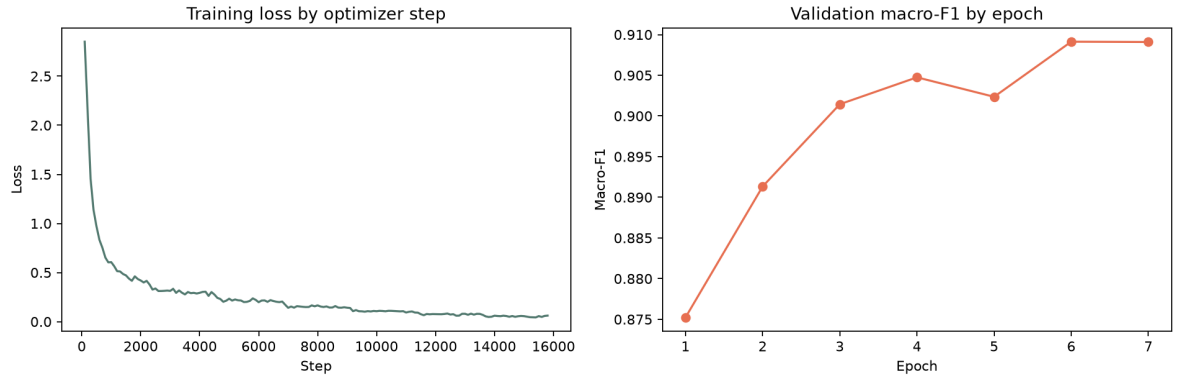
Kết quả và phân tích

3.1 Diễn biến huấn luyện

Epoch	Cross-entropy validation có trọng số	Accuracy validation	Macro-F1 validation
1	0,3871	88,72%	0,8752
2	0,3259	90,02%	0,8913
3	0,3310	91,01%	0,9014
4	0,3282	91,31%	0,9047
5	0,4005	91,01%	0,9024
6	0,3930	91,64%	0,9091
7	0,4168	91,65%	0,9091

Bảng 3.1: Đánh giá sau mỗi epoch. Cross-entropy có trọng số lớp khác với NLL không trọng số dùng để chọn temperature.

Macro-F1 validation tăng từ 0,8752 ở epoch 1 lên 0,909129 ở epoch 6, rồi giảm nhẹ còn 0,909089 ở epoch 7. Hai giá trị cuối cùng cùng làm tròn thành 0,9091 trong bảng, nhưng epoch 6 có giá trị chính xác cao hơn và được chọn. Cross-entropy validation đạt thấp nhất 0,3259 ở epoch 2 rồi tăng lên 0,4168 ở epoch 7. Loss và F1 phản ánh hai khía cạnh khác nhau: loss phụ thuộc vào xác suất dự đoán và trọng số lớp, còn F1 được tính từ nhãn phân loại. Mô hình do đó vẫn có thể tăng F1 trong khi loss xấu đi. Theo tiêu chí đã đặt ra, epoch 6 được giữ lại; diễn biến này cũng cho thấy không thể dùng F1 để kết luận rằng xác suất dự đoán đã được hiệu chỉnh tốt.



Hình 3.1: Train loss theo bước cập nhật và macro-F1 validation theo epoch. Macro-F1 cao nhất ở epoch 6; các giá trị train loss là các mốc ghi nhận trong quá trình tối ưu.

3.2 Kết quả trên tập test

Quy tắc dự đoán	Accuracy	Macro-F1	Weighted-F1
Argmax logits	91,8312%	0,910653	0,918283
Temperature và hệ số lớp	91,8890%	0,911218	0,918691

Bảng 3.2: Sau hiệu chỉnh, accuracy trên tập test tăng từ 91,8312% lên 91,8890% và macro-F1 từ 0,910653 lên 0,911218, tương ứng tăng ròng 18 bài đúng. Mức cải thiện nhỏ: 123 bài được sửa đúng, trong khi 105 bài từ đúng chuyển thành sai.

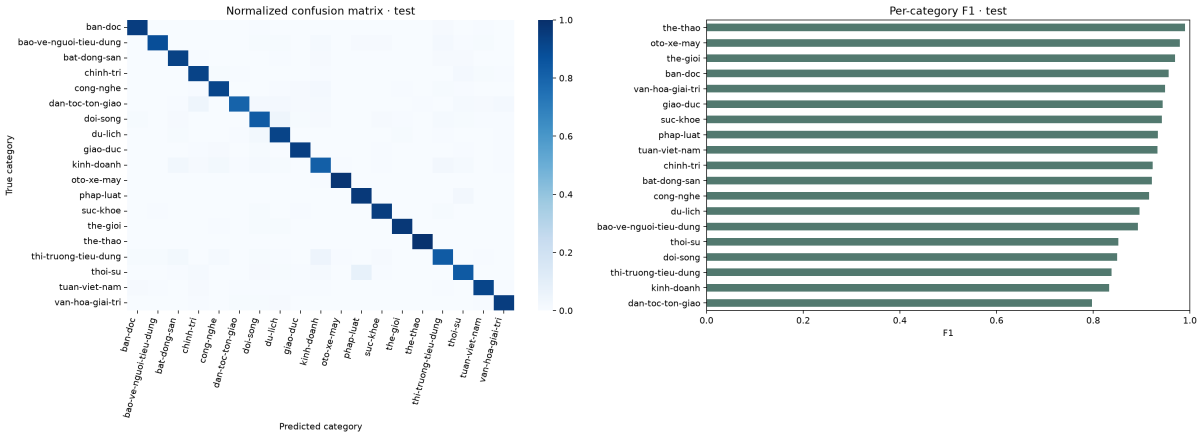
Temperature được chọn là $T = 1,4434$, làm phân bố xác suất mềm hơn. NLL validation giảm từ 0,3572 xuống 0,3018. Khi kết hợp các hệ số lớp, accuracy test tăng 0,0579 điểm phần trăm và macro-F1 tăng 0,000565. Số bài dự đoán đúng tăng từ 28.565 lên 28.583: 123 bài được sửa đúng, trong khi 105 bài từ đúng chuyển thành sai. Temperature giúp giảm NLL trên validation, còn thay đổi nhãn dự đoán đến từ các hệ số lớp. Hai kết quả này cần được đọc riêng: xác suất phù hợp hơn trên validation không đồng nghĩa với mức tăng lớn về phân loại trên test. Lợi ích về accuracy và macro-F1 trong lần chia này chỉ ở mức nhỏ.

3.3 Chất lượng theo chuyên mục

Chuyên mục	Số bài báo	Precision	Recall	F1
Dân tộc – Tôn giáo	437	0,7923	0,8032	0,7977
Kinh doanh	1.806	0,8485	0,8184	0,8331
Thị trường tiêu dùng	1.347	0,8402	0,8352	0,8377
Đời sống	1.826	0,8667	0,8335	0,8498
Thời sự	1.761	0,8681	0,8370	0,8523
Ô tô – Xe máy	1.861	0,9780	0,9796	0,9788
Thế giới	1.863	0,9714	0,9678	0,9696
Thể thao	1.846	0,9892	0,9913	0,9903

Bảng 3.3: Một số chuyên mục có F1 thấp và cao sau hiệu chỉnh. Số mẫu theo lớp không bằng nhau; macro-F1 cho mỗi chuyên mục mức đóng góp ngang nhau.

Thể thao có F1 cao nhất (0,9903), tiếp theo là Ô tô – Xe máy (0,9788) và Thế giới (0,9696). Dân tộc – Tôn giáo có F1 thấp nhất (0,7977) trên 437 bài báo trong tập test; Kinh doanh và Thị trường tiêu dùng lần lượt đạt 0,8331 và 0,8377. Weighted-F1 (0,9187) cao hơn macro-F1 (0,9112), phù hợp với việc các lớp ít bài có kết quả thấp hơn trong bảng. Tuy nhiên, số mẫu không đủ để giải thích toàn bộ chênh lệch: Kinh doanh có 1.806 bài test, gần với 1.846 bài của Thể thao, nhưng F1 thấp hơn rõ rệt. Chất lượng cần được xem theo từng chuyên mục thay vì chỉ quy về mất cân bằng lớp.



Hình 3.2: Confusion matrix chuẩn hóa theo hàng và F1 theo chuyên mục sau hiệu chỉnh. Hàng biểu diễn nhãn thật, cột biểu diễn nhãn dự đoán.

Cặp nhầm lẫn có số bài lớn nhất là Thời sự thành Pháp luật: 139/1.761 bài (7,89%). Chiều ngược lại có 49/1.778 bài (2,76%), cho thấy nhầm lẫn giữa hai lớp không đối xứng. Đời sống thành Du lịch có 79/1.826 bài (4,33%). Thị trường tiêu dùng thành Kinh doanh có 70/1.347 bài (5,20%), còn Kinh doanh thành Thị trường tiêu dùng có 54/1.806 bài (2,99%). Các cặp này xác định những ranh giới chuyên mục mà mô hình phân biệt chưa tốt. Riêng confusion matrix chưa cho biết lỗi do chủ đề giao nhau, nhãn nguồn hay thông tin bị bỏ khi rút gọn; cần đọc từng bài sai để phân biệt các khả năng đó.

3.4 So sánh các mô hình

Hệ số C được chọn theo macro-F1 trên tập validation: $C = 1$ cho logistic regression và $C = 0{,}5$ cho cả hai SVM. Frozen PhoBERT + Logistic regression đạt kết quả cao nhất trong nhóm baseline, với accuracy 80,9265% và macro-F1 0,793345 trên tập test. Character TF-IDF + Linear SVM đạt kết quả nhỉnh hơn Word TF-IDF + Linear SVM ở cả hai chỉ số trên test, nhưng chênh lệch macro-F1 chỉ là 0,002237. Trên validation, thứ tự hai SVM lại đảo ngược (0,7896 với Word TF-IDF và 0,7879 với Character TF-IDF), nên lần chia này chưa cho thấy ưu thế nhất quán của một biểu diễn TF-IDF.

So với Frozen PhoBERT + Logistic regression, PhoBERT fine-tuning trước calibration cao hơn 10,9046 điểm phần trăm accuracy và 0,117307 macro-F1. Phép so sánh thay đổi đồng thời nội dung đầu vào, độ dài token, cách tổng hợp đặc trưng và việc cập nhật encoder. Chênh lệch vì vậy mô tả hiệu quả của hai quy trình trên cùng dữ liệu, chưa tách riêng tác động của việc thêm nội dung hoặc fine-tuning.

Mô hình	Accuracy test	Macro-F1 test
Majority baseline	6,0021%	0,005960
Word TF-IDF + Linear SVM	80,1807%	0,783519
Character TF-IDF + Linear SVM	80,2643%	0,785756
Frozen PhoBERT + Logistic regression	80,9265%	0,793345
PhoBERT fine-tuning (argmax)	91,8312%	0,910653
PhoBERT fine-tuning + calibration	91,8890%	0,911218

Bảng 3.4: PhoBERT fine-tuning đạt accuracy 91,8312% và macro-F1 0,910653, cao hơn Frozen PhoBERT + Logistic regression (80,9265% và 0,793345). Kết quả được đánh giá trên tập test gồm 31.106 bài báo.

Chương 4

Kết luận và giới hạn

Trên toàn bộ 207.375 bài hợp lệ và phép chia theo nhóm đầu vào, PhoBERT đạt accuracy 91,83% và macro-F1 0,9107 trước hiệu chỉnh. Hiệu chỉnh chỉ dùng validation đưa hai chỉ số test lên 91,89% và 0,9112. Mức tăng tương ứng 18 bài đúng trên 31.106 bài test; khác biệt giữa các chuyên mục lớn hơn nhiều so với thay đổi tổng hợp này.

Thực nghiệm đánh giá một phép chia và một seed, chưa lượng hóa biến thiên giữa các lần huấn luyện. Chia theo nhóm đầu vào giống nhau hạn chế một dạng rò rỉ cụ thể nhưng không thay thế đánh giá theo thời gian hoặc đo các bài gần trùng về ngữ nghĩa. Head–Tail chỉ giữ phần đầu và cuối, còn phép loại chữ số có thể bỏ thông tin; chưa khảo sát riêng hai lựa chọn này. Vì vậy, kết quả mô tả hiệu quả của toàn bộ quy trình đã đo trên nguồn VietnamNet.

Phạm vi hỗ trợ AI được trình bày trong AI_USE_REPORT.md.

Tài liệu tham khảo

[1] *VietnamNet News*. Dữ liệu thu thập bằng crawling từ VietnamNet, công bố trên kho Hugging Face của học viên Huỳnh Thành Đạt. https://huggingface.co/datasets/dathuynh1108/vietnamnet-news.

[2] Dat Quoc Nguyen và Anh Tuan Nguyen. *PhoBERT: Pre-trained language models for Vietnamese*. Trong *Findings of the Association for Computational Linguistics: EMNLP 2020*, tr. 1037–1042, Association for Computational Linguistics, 2020. DOI: 10.18653/v1/2020.findings-emnlp.92. https://aclanthology.org/2020.findings-emnlp.92/.

[3] VinAI Research. *PhoBERT Base v2 model card*. https://huggingface.co/vinai/phobert-base-v2.

[4] PyVi 0.1.1. *Vietnamese word segmentation*. https://pypi.org/project/pyvi/.