ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



BÁO CÁO TEXT

CO5177 · Nền tảng lập trình cho phân tích và trực quan dữ liệu

Học kỳ 261 · Năm học 2026–2027

Phân loại bài báo VietnamNet bằng PhoBERT

Nhóm CTG

Huỳnh Thành Đạt	2570161 · 50%
Lương Minh Duy	2570083 · 50%
Giảng viên	Lê Thành Sách

Thành phố Hồ Chí Minh, tháng 11 năm 2026

Tóm tắt

Thực nghiệm tinh chỉnh PhoBERT Base v2 để phân loại bài báo tiếng Việt vào 19 chuyên mục. Toàn bộ 207.375 bài hợp lệ sau làm sạch được sử dụng; các bài có đầu vào mô hình giống nhau được giữ cùng tập khi chia train, validation và test. Mô hình học từ tiêu đề kết hợp phần đầu và cuối nội dung, với cross-entropy có trọng số lớp. Trên 31.106 bài test, accuracy và macro-F1 trước hiệu chỉnh đạt 91,83% và 0,9107; sau hiệu chỉnh bằng validation đạt 91,89% và 0,9112. Mức tăng nhỏ, trong khi khác biệt giữa các chuyên mục vẫn rõ: Thể thao có F1 0,9903, còn Dân tộc – Tôn giáo có F1 0,7977.

Tổng quan báo cáo

Dữ liệu	212.705 bài nguồn; giữ toàn bộ 207.375 bài hợp lệ thuộc 19 chuyên mục.
Chia tập	145.162/31.107/31.106 bài train/validation/test; chia theo nhóm đầu vào.
Phương pháp	PhoBERT Base v2 và đầu phân loại 19 lớp; Head–Tail 256 token, loss có trọng số lớp.
Kết quả	Accuracy 91,89%, macro-F1 0,9112 sau hiệu chỉnh từ validation.
Nguồn	VietnamNet News trên kho Hugging Face của sinh viên Huỳnh Thành Đạt.

Mục lục

Tóm tắt **i**

Tổng quan báo cáo **ii**

1 Bài toán và dữ liệu **1**

1.1 Mục tiêu 1

1.2 Nguồn và làm sạch dữ liệu 1

1.3 Chia tập theo nhóm đầu vào 2

2 Phương pháp và thiết lập **3**

2.1 Biểu diễn Head–Tail 3

2.2 PhoBERT và hàm mất mát 3

2.3 Các baseline 4

2.4 Cấu hình và lựa chọn checkpoint 4

2.5 Hiệu chỉnh trên validation 4

3 Kết quả và phân tích **6**

3.1 Diễn biến huấn luyện 6

3.2 Kết quả trên tập test 7

3.3 Chất lượng theo chuyên mục 7

3.4 So sánh các mô hình 8

4 Kết luận và giới hạn **9**

Tài liệu tham khảo **10**

Danh sách hình vẽ

1.1 Phân bố chuyên mục trước và sau làm sạch, cùng độ dài nội dung trước rút gọn. Toàn bộ bài hợp lệ được sử dụng; sự chênh lệch số mẫu giữa các chuyên mục vẫn được giữ lại. 2

3.1 Train loss theo bước cập nhật và macro-F1 validation theo epoch. Macro-F1 cao nhất ở epoch 6; các giá trị train loss là các mốc ghi nhận trong quá trình tối ưu. 6

3.2 Ma trận nhầm lẫn chuẩn hóa theo hàng và F1 theo chuyên mục sau hiệu chỉnh. Hàng biểu diễn nhãn thật, cột biểu diễn nhãn dự đoán. 8

Danh sách bảng

1.1 Làm sạch toàn bộ dữ liệu trước khi chia tập. Các số bài bị loại ở ba bước là các phần rời nhau. 1

2.1 Thiết lập của lần huấn luyện trên toàn bộ tập bài hợp lệ. 4

3.1 Đánh giá sau mỗi epoch. Cross-entropy có trọng số lớp khác với NLL không trọng số dùng để chọn temperature. 6

3.2 Kết quả trước và sau hiệu chỉnh bằng validation 7

3.3 Một số chuyên mục có F1 thấp và cao sau hiệu chỉnh. Số mẫu theo lớp không bằng nhau; macro-F1 cho mỗi chuyên mục mức đóng góp ngang nhau. 7

3.4 Kết quả các mô hình 8

Chương 1

Bài toán và dữ liệu

1.1 Mục tiêu

Bài toán phân loại mỗi bài báo tiếng Việt vào một trong 19 chuyên mục của VietnamNet. Thực nghiệm sử dụng tiêu đề và nội dung bài viết, tập trung vào chất lượng phân loại theo chuyên mục, diễn biến học và tác động của hiệu chỉnh xác suất. PhoBERT Base v2 được tinh chỉnh trên toàn bộ tập bài hợp lệ, với validation dùng chọn checkpoint và tham số hiệu chỉnh, còn test dùng đánh giá cuối.

1.2 Nguồn và làm sạch dữ liệu

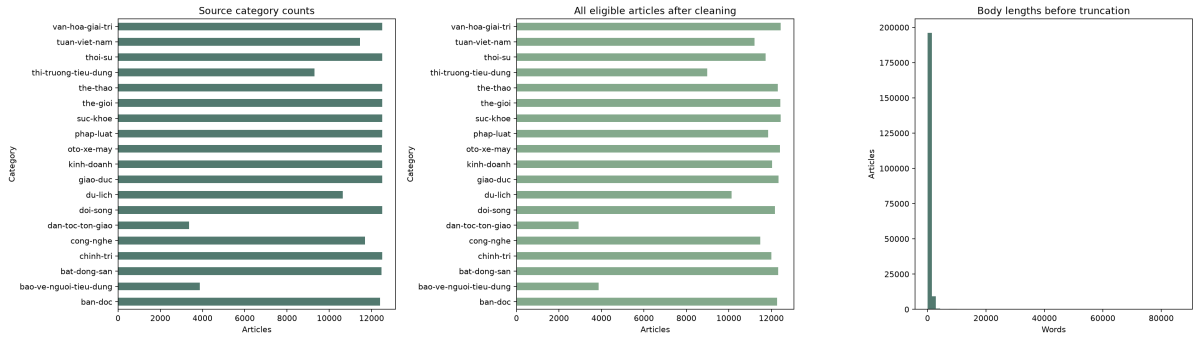
Nguồn là bộ VietnamNet News trên kho Hugging Face của sinh viên Huỳnh Thành Đạt, gồm 212.705 bài trong 19 tệp chuyên mục [1]. Mỗi bản ghi chứa tiêu đề, nội dung, URL và nhãn chuyên mục.

Tiêu đề và nội dung được chuẩn hóa Unicode NFC và khoảng trắng. URL được chuẩn hóa, bỏ query và fragment. Các bản ghi có cùng URL, cùng tiêu đề không phân biệt hoa thường hoặc cùng nội dung không rỗng được nối thành nhóm liên thông. Nhóm có chuyên mục mâu thuẫn bị loại toàn bộ; mỗi nhóm còn lại giữ một bản ghi. Bảng 1.1 tóm tắt số bài ở từng bước.

Bước xử lý	Số bài
Dữ liệu nguồn	212.705
Loại tiêu đề rỗng	1.167
Loại dòng thuộc nhóm có nhãn mâu thuẫn	3.636
Loại dòng trùng còn lại	527
Bài hợp lệ được sử dụng	207.375

Bảng 1.1: Làm sạch toàn bộ dữ liệu trước khi chia tập. Các số bài bị loại ở ba bước là các phần rời nhau.

Không giới hạn số bài theo chuyên mục. Bảy bài thiếu nội dung vẫn có tiêu đề hợp lệ và được giữ lại. Phân bố sau làm sạch còn mất cân bằng: Sức khỏe có 12.444 bài, còn Dân tộc – Tôn giáo có 2.917 bài, chênh khoảng 4,27 lần. Vì vậy, macro-F1 được dùng để chọn checkpoint, đồng thời loss được điều chỉnh theo tần suất lớp trong train.



Hình 1.1: Phân bố chuyên mục trước và sau làm sạch, cùng độ dài nội dung trước rút gọn. Toàn bộ bài hợp lệ được sử dụng; sự chênh lệch số mẫu giữa các chuyên mục vẫn được giữ lại.

1.3 Chia tập theo nhóm đầu vào

Chuẩn hóa văn bản và giới hạn token có thể khiến các bài khác nhau ở dữ liệu nguồn trở thành cùng một đầu vào mô hình. Vì vậy, các bài có cùng chuỗi token cuối cùng của tiêu đề tối đa 128 token hoặc cùng đầu vào Head–Tail của bài báo 256 token được gộp vào cùng nhóm. Quy tắc dùng cả hai dạng đầu vào để giữ chung các phân hoạch khi đối chiếu mô hình tiêu đề và mô hình bài báo.

Có 207.108 nhóm đầu vào; 50 nhóm chứa nhiều bài, nhóm lớn nhất có 39 bài. Bước nhóm không loại thêm bản ghi. StratifiedGroupKFold với 20 fold và seed 2026 chia 14/3/3 fold cho train, validation và test, xấp xỉ tỷ lệ 70/15/15. Ba tập lần lượt có 145.162/31.107/31.106 bài. Các bài cùng nhóm luôn thuộc cùng một tập; phân tầng giữ phân bố chuyên mục gần nhau giữa các tập.

Chương 2

Phương pháp và thiết lập

2.1 Biểu diễn Head–Tail

Mỗi đầu vào kết hợp tiêu đề với tối đa 220 từ đầu và 80 từ cuối nội dung. Văn bản được chuyển sang chữ thường, loại dấu câu và chữ số, chuẩn hóa khoảng trắng rồi tách từ bằng PyVi [4]. PhoBERT yêu cầu văn bản đã tách từ trước bước mã hóa subword [3].

Với chuỗi vượt giới hạn đầu vào, Head–Tail giữ 127 subword token đầu và 127 token cuối, kèm hai token đặc biệt:

$$x = [\text{CLS}] \| t_{1:127} \| t_{L-126:L} \| [\text{SEP}].$$

Chuỗi ngắn hơn được bổ sung padding; attention mask phân biệt token văn bản với padding. Việc giữ đầu và cuối giúp đưa cả hai vị trí vào đầu vào 256 token, nhưng phần giữa bài viết vẫn bị bỏ. Loại chữ số cũng có thể làm mất năm, giá tiền hoặc tỷ số; thực nghiệm chưa tách riêng ảnh hưởng của bước này.

2.2 PhoBERT và hàm mất mát

PhoBERT là mô hình ngôn ngữ tiền huấn luyện cho tiếng Việt [2]. Thực nghiệm dùng phiên bản Base v2 qua `AutoModelForSequenceClassification`, với đầu phân loại 19 lớp của kiến trúc RoBERTa và cập nhật toàn bộ encoder cùng đầu phân loại [3]. Đầu phân loại được khởi tạo cho bài toán chuyên mục; baseline Frozen PhoBERT + Logistic regression sử dụng encoder đóng băng. Trọng số lớp chỉ được tính từ train:

$$w_c = \frac{N_{\text{train}}}{K n_c}, \qquad K = 19,$$

trong đó n_c là số bài train thuộc lớp c. Cross-entropy trên batch B dùng trung bình có trọng số:

$$\mathcal{L}_B = -\frac{\sum_{i \in B} w_{y_i} \log p_\theta(y_i \mid x_i)}{\sum_{i \in B} w_{y_i}}.$$

Lớp ít bài có trọng số lớn hơn, làm lỗi ở lớp đó đóng góp nhiều hơn vào loss. Không áp dụng hệ số tăng cường thủ công theo chuyên mục.

2.3 Các baseline

Các baseline dùng cùng ID bài báo và cùng ba tập với mô hình toàn văn. Đầu vào chỉ gồm tiêu đề đã tách từ. Hai mô hình SVM tuyến tính dùng TF-IDF theo từ (unigram, bigram) hoặc ký tự (char-within-word, n-gram 3–5); từ vựng và IDF được học trên train, tối đa 80.000 đặc trưng.

Frozen PhoBERT dùng encoder đóng băng, đầu vào tối đa 128 token và trung bình có attention mask của các vector token 768 chiều. Hồi quy logistic được fit trên các vector này. Cả SVM và hồi quy logistic chọn $C \in \{0{,}5; 1; 2\}$ bằng macro-F1 validation. Dự đoán lớp đa số làm mốc tham chiếu. Các baseline chỉ dùng tiêu đề, còn mô hình chính tinh chỉnh encoder và đầu phân loại trên đầu vào bài báo; sự khác biệt kết quả phản ánh cả hai thay đổi.

2.4 Cấu hình và lựa chọn checkpoint

Tham số	Giá trị
Mô hình / số lớp	PhoBERT Base v2 / 19
Độ dài đầu vào	256 token
Optimizer	Fused AdamW
Learning rate / weight decay	2×10^{-5} / 0,01
Warmup	200 bước
Batch trên GPU / tích lũy gradient	32 / 2
Batch hiệu dụng	64
Số epoch tối đa / patience	7 / 3
Tiêu chí chọn checkpoint	Macro-F1 validation lớn nhất
Seed dữ liệu / mô hình	2026 / 42
Thiết bị / độ chính xác số	RTX 5090 / BF16

Bảng 2.1: Thiết lập của lần huấn luyện trên toàn bộ tập bài hợp lệ.

Mô hình hoàn tất bảy epoch với 15.883 bước cập nhật trong 1.443,6 giây, tương đương 24,06 phút. Thời lượng này là phần fine-tuning, không bao gồm toàn bộ thời gian tải và chuẩn bị dữ liệu. Checkpoint epoch 6 được chọn với macro-F1 validation 0,909129; epoch 7 vẫn được huấn luyện và đánh giá đầy đủ.

2.5 Hiệu chỉnh trên validation

Với logits $z_{i,c}$, temperature scaling tạo xác suất

$$p_{i,c}(T) = \frac{\exp(z_{i,c}/T)}{\sum_{k=1}^{K} \exp(z_{i,k}/T)}, \qquad T > 0.$$

Tham số T được chọn để giảm negative log-likelihood trên validation. Sau đó, hệ số tương đối $t_c > 0$ cho từng lớp được chọn bằng F1 trên validation, với quy tắc

$$\widehat{y}_i = \arg\max_c \frac{p_{i,c}(T)}{t_c}.$$

Các t_c co giãn điểm tương đối giữa các lớp, không phải các ngưỡng xác suất nhị phân độc lập. Temperature riêng lẻ giữ nguyên thứ tự logits; các hệ số theo lớp có thể thay đổi nhãn dự đoán. Checkpoint, T và t_c được cố định trước khi đánh giá hai quy tắc trên test.

Chương 3

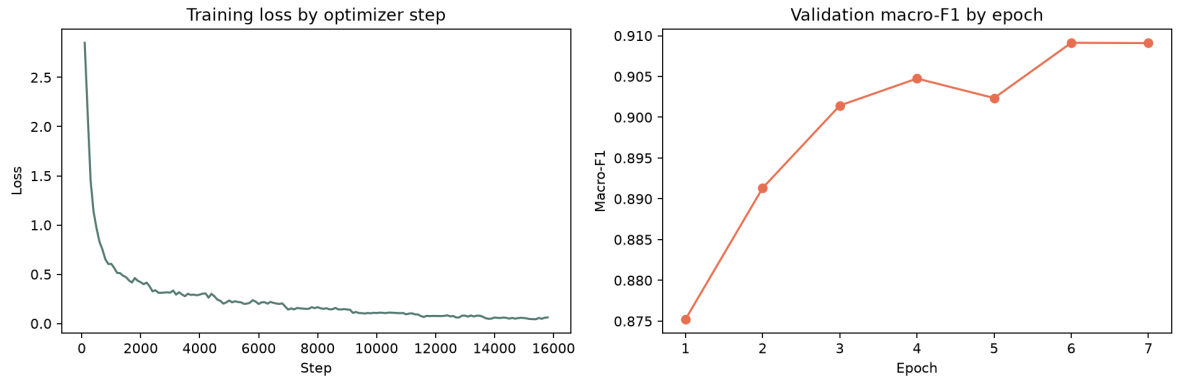
Kết quả và phân tích

3.1 Diễn biến huấn luyện

Epoch	Cross-entropy validation có trọng số	Accuracy validation	Macro-F1 validation
1	0,3871	88,72%	0,8752
2	0,3259	90,02%	0,8913
3	0,3310	91,01%	0,9014
4	0,3282	91,31%	0,9047
5	0,4005	91,01%	0,9024
6	0,3930	91,64%	0,9091
7	0,4168	91,65%	0,9091

Bảng 3.1: Đánh giá sau mỗi epoch. Cross-entropy có trọng số lớp khác với NLL không trọng số dùng để chọn temperature.

Macro-F1 validation tăng từ 0,8752 ở epoch 1 lên 0,909129 ở epoch 6, rồi giảm nhẹ còn 0,909089 ở epoch 7. Hai giá trị cuối cùng cùng làm tròn thành 0,9091 trong bảng, nhưng epoch 6 có giá trị chính xác cao hơn và được chọn. Cross-entropy validation đạt thấp nhất 0,3259 ở epoch 2 rồi tăng lên 0,4168 ở epoch 7. Hai chỉ số vì thế không cải thiện đồng thời: checkpoint có F1 cao nhất không phải checkpoint có loss thấp nhất. Đường loss cho thấy cần đánh giá thêm chất lượng xác suất dự đoán thay vì chỉ đọc nhãn đúng hoặc sai.



Hình 3.1: Train loss theo bước cập nhật và macro-F1 validation theo epoch. Macro-F1 cao nhất ở epoch 6; các giá trị train loss là các mốc ghi nhận trong quá trình tối ưu.

3.2 Kết quả trên tập test

Quy tắc dự đoán	Accuracy	Macro-F1	Weighted-F1
Argmax logits	91,8312%	0,910653	0,918283
Temperature và hệ số lớp	91,8890%	0,911218	0,918691

Bảng 3.2: Hiệu chỉnh bằng validation làm accuracy trên cùng 31.106 bài test tăng từ 91,8312% lên 91,8890% và macro-F1 từ 0,910653 lên 0,911218, tương ứng tăng ròng 18 bài đúng. Mức cải thiện nhỏ: 123 bài được sửa đúng, trong khi 105 bài từ đúng chuyển thành sai.

Temperature được chọn là $T = 1,4434$, làm phân bố xác suất mềm hơn. NLL validation giảm từ 0,3572 xuống 0,3018. Khi kết hợp các hệ số lớp, accuracy test tăng 0,0579 điểm phần trăm và macro-F1 tăng 0,000565. Số bài dự đoán đúng tăng từ 28.565 lên 28.583: 123 bài được sửa đúng, trong khi 105 bài từ đúng chuyển thành sai. Hiệu chỉnh vì thế có lợi nhỏ về chỉ số tổng hợp trong lần chia này, với thay đổi ở cả hai chiều đối với từng bài.

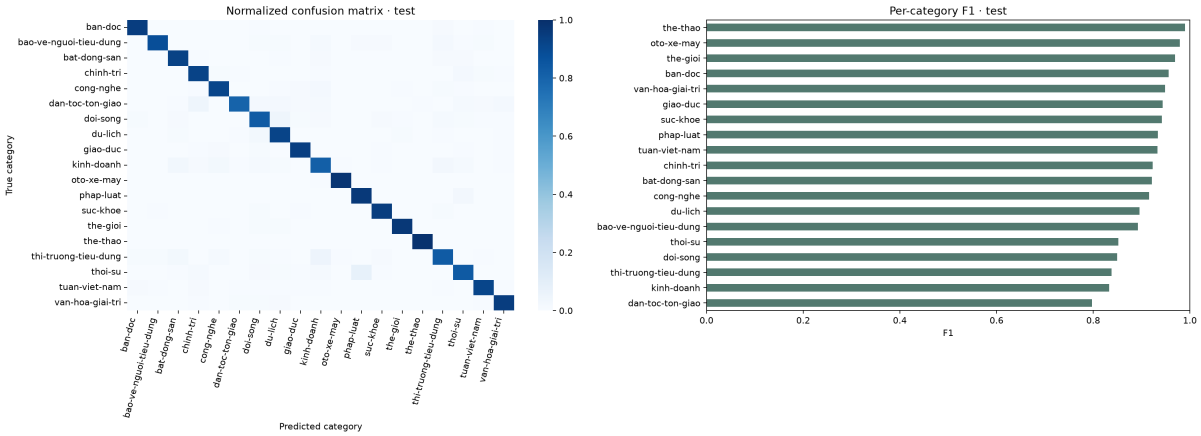
3.3 Chất lượng theo chuyên mục

Chuyên mục	Số bài test	Precision	Recall	F1
Dân tộc – Tôn giáo	437	0,7923	0,8032	0,7977
Kinh doanh	1.806	0,8485	0,8184	0,8331
Thị trường tiêu dùng	1.347	0,8402	0,8352	0,8377
Đời sống	1.826	0,8667	0,8335	0,8498
Thời sự	1.761	0,8681	0,8370	0,8523
Ô tô – Xe máy	1.861	0,9780	0,9796	0,9788
Thế giới	1.863	0,9714	0,9678	0,9696
Thể thao	1.846	0,9892	0,9913	0,9903

Bảng 3.3: Một số chuyên mục có F1 thấp và cao sau hiệu chỉnh. Số mẫu theo lớp không bằng nhau; macro-F1 cho mỗi chuyên mục mức đóng góp ngang nhau.

Thể thao có F1 cao nhất (0,9903), tiếp theo là Ô tô – Xe máy (0,9788) và Thế giới (0,9696). Dân tộc – Tôn giáo có F1 thấp nhất (0,7977) trên 437 bài test; Kinh doanh và Thị trường tiêu dùng lần lượt đạt 0,8331 và 0,8377. Chênh lệch macro-F1 0,9112 với weighted-F1 0,9187 phản ánh khác biệt giữa cách tính trung bình đều theo chuyên mục và cách tính theo số mẫu.

Cặp nhầm lẫn có số bài lớn nhất là Thời sự thành Pháp luật: 139/1.761 bài (7,89%). Chiều ngược lại có 49/1.778 bài (2,76%), cho thấy nhầm lẫn giữa hai lớp không đối xứng. Đời sống thành Du lịch có 79/1.826 bài (4,33%). Thị trường tiêu dùng thành Kinh doanh có 70/1.347 bài (5,20%), còn Kinh doanh thành Thị trường tiêu dùng có 54/1.806 bài (2,99%). Đọc đồng thời số bài và tỷ lệ giúp phân biệt số lỗi tuyệt đối với mức nhầm lẫn trong từng lớp.



Hình 3.2: Ma trận nhầm lẫn chuẩn hóa theo hàng và F1 theo chuyên mục sau hiệu chỉnh. Hàng biểu diễn nhãn thật, cột biểu diễn nhãn dự đoán.

3.4 So sánh các mô hình

Các baseline được huấn luyện lại trên cùng 145.162 bài train và chọn siêu tham số bằng cùng 31.107 bài validation. PhoBERT đóng băng kết hợp hồi quy logistic có macro-F1 validation cao nhất (0,7942), với $C = 1$. Trên cùng 31.106 ID test, mô hình này đạt accuracy 80,9265% và macro-F1 0,793345. TF-IDF từ và TF-IDF ký tự lần lượt đạt accuracy 80,1807% và 80,2643%, với macro-F1 0,783519 và 0,785756. Hai SVM đều chọn $C = 0,5$; macro-F1 validation tương ứng là 0,7896 và 0,7879.

Mô hình	Accuracy test	Macro-F1 test
Majority baseline	6,0021%	0,005960
Word TF-IDF + Linear SVM	80,1807%	0,783519
Character TF-IDF + Linear SVM	80,2643%	0,785756
Frozen PhoBERT + Logistic regression	80,9265%	0,793345
PhoBERT fine-tuning (argmax)	91,8312%	0,910653
PhoBERT fine-tuning + calibration	91,8890%	0,911218

Bảng 3.4: Trên cùng ID test, accuracy tăng từ 80,9265% với Frozen PhoBERT + Logistic regression lên 91,8312% với PhoBERT fine-tuning trước calibration; macro-F1 tăng từ 0,793345 lên 0,910653. Các mô hình được chọn bằng validation. Phép so sánh thay đổi cả đầu vào và việc cập nhật encoder, nên chưa tách riêng tác động của nội dung và fine-tuning.

So với Frozen PhoBERT + Logistic regression, PhoBERT fine-tuning trước calibration cao hơn 10,9046 điểm phần trăm accuracy và 0,117307 macro-F1. Phép so sánh thay đổi đồng thời nội dung đầu vào, độ dài token, cách tổng hợp đặc trưng và việc cập nhật encoder. Chênh lệch vì vậy mô tả hiệu quả của hai quy trình trên cùng dữ liệu, chưa tách riêng tác động của việc thêm nội dung hoặc fine-tuning.

Chương 4

Kết luận và giới hạn

Trên toàn bộ 207.375 bài hợp lệ và phép chia theo nhóm đầu vào, PhoBERT đạt accuracy 91,83% và macro-F1 0,9107 trước hiệu chỉnh. Hiệu chỉnh chỉ dùng validation đưa hai chỉ số test lên 91,89% và 0,9112. Mức tăng tương ứng 18 bài đúng trên 31.106 bài test; khác biệt giữa các chuyên mục lớn hơn nhiều so với thay đổi tổng hợp này.

Thực nghiệm đánh giá một phép chia và một seed, chưa lượng hóa biến thiên giữa các lần huấn luyện. Chia theo nhóm đầu vào giống nhau hạn chế một dạng rò rỉ cụ thể nhưng không thay thế đánh giá theo thời gian hoặc đo các bài gần trùng về ngữ nghĩa. Head–Tail chỉ giữ phần đầu và cuối, còn phép loại chữ số có thể bỏ thông tin; chưa khảo sát riêng hai lựa chọn này. Vì vậy, kết quả mô tả hiệu quả của toàn bộ quy trình đã đo trên nguồn VietnamNet.

Phạm vi hỗ trợ AI được trình bày trong AI_USE_REPORT.md.

Tài liệu tham khảo

[1] *VietnamNet News*. Bộ dữ liệu trên kho Hugging Face của sinh viên Huỳnh Thành Đạt. https://huggingface.co/datasets/dathuynh1108/vietnamnet-news.

[2] Dat Quoc Nguyen và Anh Tuan Nguyen. *PhoBERT: Pre-trained language models for Vietnamese*. Trong *Findings of the Association for Computational Linguistics: EMNLP 2020*, tr. 1037–1042, Association for Computational Linguistics, 2020. DOI: 10.18653/v1/2020.findings-emnlp.92. https://aclanthology.org/2020.findings-emnlp.92/.

[3] VinAI Research. *PhoBERT Base v2 model card*. https://huggingface.co/vinai/phobert-base-v2.

[4] PyVi 0.1.1. *Vietnamese word segmentation*. https://pypi.org/project/pyvi/.